
Cloud Computing e Cloud Storage

Estudo de caso: Amazon Web Services (AWS)

Arquitetura, serviços, segurança e análise de 3,5 PB

Grupo 3

Nome completo	DRE
Bernardo Brandão Pozzato Carvalho Costa	123289593
Enzo de Carvalho Sampaio	123386206
Gabriel Schmitz Corrêa Rizawinsk	123225573
Guilherme En Shih Hu	123224674
Raphael Henrique da Silva Pereira	123420783
Vivian Maria da Silva e Souza	123205793

Rio de Janeiro — Setembro de 2026

Resumo

Este trabalho explica computação e armazenamento em nuvem e analisa a AWS como provedor. Partimos das cinco características do NIST, distinguimos IaaS, PaaS, SaaS, DBaaS e DWaaS e comparamos nuvens pública, privada e híbrida. Em seguida relacionamos requisitos de banco de dados aos serviços EC2, S3, EBS, classes S3 Glacier, RDS, Aurora, DynamoDB e Redshift. O estudo econômico trata 3,5 PB como um problema de arquitetura, não como simples multiplicação de preço por GB: separa armazenamento, processamento, requisições, recuperação, transferência, proteção e suporte. Adotando a definição SI ($1 \text{ PB} = 10^{15} \text{ bytes}$), 3,5 PB correspondem a 3.500 TB decimais. Como o S3 contabiliza armazenamento em “GB” binários ($1 \text{ GB} = 2^{30} \text{ bytes}$), essa mesma capacidade equivale a aproximadamente 3.259.629 GB de cobrança (3.183,23 TB binários). Com preços públicos de us-east-1 consultados em setembro de 2026, custaria cerca de US\$ 69.015/mês em S3 Standard, US\$ 40.745 em Standard-IA, US\$ 11.735 em Glacier Flexible Retrieval ou US\$ 3.227 em Deep Archive. Esses valores não são alternativas equivalentes: possuem latências, cobranças de recuperação e durações mínimas distintas. Para ilustrar o custo de processamento, usamos também o preço sob demanda do Athena (US\$ 5/TB escaneado): uma consulta que leia 1% da base (35 TB) custaria aproximadamente US\$ 175, enquanto uma varredura lógica integral de 3,5 PB chegaria a cerca de US\$ 17.500, antes de custos adicionais. Propomos, por isso, um data lake em S3 com dados colunares e particionados, catálogo, políticas de ciclo de vida e computação escolhida segundo o perfil da consulta. O Post-Mortem registra prompts-chave, divisão declarada de responsabilidades e correções aplicadas sobre saídas de IA.

Palavras-chave: computação em nuvem; AWS; armazenamento de objetos; DBaaS; DWaaS; data lake; custo total de propriedade; 3,5 PB.

Sumário

Resumo	2
Introdução	4
Método e hierarquia das fontes	4
1 Bases Conceituais	4
1.1 Definição de computação em nuvem segundo o NIST	4
1.2 As cinco características essenciais	5
1.3 Cloud Storage	5
1.4 Consistência, durabilidade e disponibilidade	6
2 Modelos de implantação	7
2.1 Pública	7
2.2 Privada	7
2.3 Híbrida e Padrões de Integração	8
3 Modelos de Serviço e Critérios de Avaliação	9
3.1 O Espectro de Abstração e a Responsabilidade Compartilhada	9
3.2 Critérios Quantificáveis de Avaliação: SLAs, SLIs e RPO/RTO	9
4 Estudo de Caso: Amazon Web Services (AWS)	11
4.1 Computação — Amazon EC2	11
4.2 Armazenamento — EBS, S3 e Glacier	11
4.3 Banco de Dados — RDS, Aurora, DynamoDB e Redshift	12
5 Estudo de Custo: Armazenamento e Processamento de 3,5 Petabytes na AWS	14
5.1 Custo de armazenamento por classe do Amazon S3	14
5.2 Custos adicionais: requisições, transferência de dados (egress) e processamento	15
5.3 Por que S3 é a camada-base nessa escala	15
5.4 Vantagens de armazenar e processar 3,5 PB na AWS	15
5.5 Desvantagens de armazenar e processar 3,5 PB na AWS	16
6 Conclusão	17
7 Questões para apresentação e debate	17
8 Post-Mortem	18
8.1 Log dos prompts-chave	18
8.2 Matriz de Responsabilidades e Declaração de Autoria	18
8.3 Erros da IA e correções aplicadas	19

Introdução

A nuvem troca a compra antecipada de infraestrutura por recursos medidos, provisionados por API e compartilhados com isolamento. Para um SBD, essa troca altera o local do controle: o cliente pode administrar sistema operacional e SGBD em EC2, delegar tarefas operacionais ao RDS ou Aurora, ou usar serviços com modelos de dados próprios, como DynamoDB e Redshift. O ganho de elasticidade não elimina decisões de engenharia. Região, zonas, consistência, latência, modelo de falha, RPO, RTO, governança e custo continuam sob responsabilidade do arquiteto.

O enunciado pede também uma decisão para 3,5 PB. Sem caracterizar o conjunto de dados, não existe um único preço tecnicamente honesto: uma base transacional, um data warehouse e um arquivo regulatório exigem serviços diferentes. Este relatório explicita premissas e compara classes de armazenamento e opções de processamento adequadas a perfis distintos.

Nossa tese é que, nessa escala, a primeira decisão não é escolher uma instância: é separar a persistência durável da capacidade de computação. Objetos em S3 formam a camada de verdade para o acervo analítico; engines diferentes processam subconjuntos conforme latência e concorrência; bancos operacionais preservam apenas o estado que realmente exige transações. Essa separação evita usar EBS, RDS ou Aurora como se fossem recipientes indiferenciados de petabytes.

Tabela 1: Checklist do enunciado.

Exigência	Localização
Foundations and deployment: NIST, características e implantação	Seção 1
Service Models and Evaluation: IaaS, PaaS, SaaS e critérios	Seção 3
EC2; S3, EBS e Glacier; RDS, Aurora, DynamoDB e Redshift	Seção 4
Custo, vantagens e desvantagens para 3,5 PB	Seção 5
Post-Mortem, prompts, autoria e correções da IA	Seção 8
Folha de rosto com nomes e DRE	página 1

Método e hierarquia das fontes

O estudo combina os livros indicados no enunciado com normas e documentação operacional. Usamos o NIST para a definição de nuvem; livros-texto para modelos e implicações de SBD; documentação AWS para semântica, limites e preços. Afirmativas mutáveis registram região e data. Preço publicado é tratado como estimativa, não proposta comercial. A documentação de preços do S3 chama de “GB” uma unidade binária de 2^{30} bytes e de “TB” uma unidade de 2^{40} bytes. Por isso, partimos de PB no SI e convertemos explicitamente para a unidade de cobrança da AWS, evitando tratar PB e PiB como sinônimos [11].

As comparações seguem quatro perguntas: (1) qual abstração o consumidor recebe; (2) quem mantém cada camada; (3) qual SLO pode ser construído; e (4) quais variáveis compõem o custo total. Isso aproxima o relatório do problema de banco de dados: capacidade sem semântica de escrita, durabilidade sem recuperação e preço sem workload não permitem uma decisão.

1 Bases Conceituais

Esta seção estabelece a base conceitual para as decisões posteriores. Primeiro, apresenta a definição do NIST e suas características essenciais; depois, compara os modelos público, privado e híbrido. Esses modelos descrevem a governança e a integração da infraestrutura, e não devem ser confundidos com os modelos de serviço, que delimitam responsabilidades operacionais.

1.1 Definição de computação em nuvem segundo o NIST

O NIST define computação em nuvem como um modelo de acesso conveniente e sob demanda, pela rede, a um conjunto compartilhado de recursos configuráveis que podem ser rapidamente provisionados e liberados com pouco esforço de gestão [1]. Em outras palavras, a organização deixa de tratar servidores, redes e armazenamento apenas como ativos físicos comprados antecipadamente

e passa a consumi-los com recursos que podem ser solicitados, configurados e medidos conforme a necessidade.

Para diferenciar esse modelo de outras formas de hospedar sistemas, o NIST estabelece cinco características essenciais: autoatendimento sob demanda, amplo acesso por rede, agrupamento de recursos, elasticidade rápida e serviço mensurável. Elas descrevem tanto a experiência do consumidor quanto a forma como o provedor organiza sua infraestrutura. A virtualização é uma tecnologia que frequentemente viabiliza essa organização, pois permite criar ambientes isolados sobre o mesmo hardware. Contudo, ela não é sinônimo de nuvem: uma máquina virtual criada manualmente em um único servidor pode ser virtualizada, mas não oferece, por si só, os cinco critérios do NIST.

1.2 As cinco características essenciais

A primeira característica, o **autoatendimento sob demanda**, permite que o próprio consumidor crie, redimensione ou encerre um recurso por console, API ou código de infraestrutura, sem depender de uma solicitação manual ao operador. O **amplo acesso por rede** torna esses recursos disponíveis por protocolos padronizados a clientes diferentes, como aplicações web, notebooks e servidores. Isso não significa que o dado esteja aberto na Internet: autenticação, redes privadas e políticas continuam determinando quem pode acessar o serviço e por qual caminho.

O **agrupamento de recursos** explica como o provedor atende muitos consumidores. A virtualização abstrai CPU, memória, rede e dispositivos físicos em recursos lógicos isolados; o *pooling* administra a capacidade de muitos equipamentos como um conjunto, alocando-a conforme a demanda sem que cada cliente escolha o servidor físico exato. Essa modalidade é chamada de *multi-tenancy*: a infraestrutura é compartilhada, mas identidade, rede, execução e dados precisam permanecer isolados. Assim, o risco não desaparece com a abstração; ele passa a exigir controles lógicos, auditoria e evidências de que o isolamento é efetivo.

As duas características restantes relacionam capacidade e custo. **Elasticidade rápida** é a possibilidade de aumentar ou reduzir recursos em tempo compatível com a variação da demanda. Ela não deve ser confundida com escalabilidade: escala vertical aumenta CPU ou memória de uma única máquina, enquanto escala horizontal adiciona máquinas; elasticidade é a capacidade de executar esse ajuste de modo ágil, idealmente automático. Um sistema pode ser escalável, mas não elástico, se a expansão exigir uma janela manual de manutenção. Em sistemas de banco de dados, a escala horizontal é mais difícil porque escrita e estado exigem particionamento, coordenação, consistência e redistribuição de dados. Por fim, o **serviço mensurável** registra o consumo e o cobra em unidades como horas de computação, GB-mês ou número de requisições; portanto, a arquitetura também influencia a conta financeira.

Tabela 2: Das características NIST às consequências de arquitetura.

Característica	Mecanismo observável	Implicação para SBD
Autoatendimento	API/IaC cria e remove recursos sem chamado	velocidade exige guardrails, quotas e revisão de configuração
Amplo acesso por rede	endpoints e protocolos padronizados	latência, identidade e caminho privado entram no projeto
Pool de recursos	alocação dinâmica e isolamento entre clientes	localização física é abstraída; região e AZ continuam relevantes
Elasticidade rápida	capacidade cresce/reduz conforme demanda	conexões, réplicas e partições precisam acompanhar o compute
Serviço mensurável	consumo medido por dimensões do serviço	formato físico e padrão de acesso tornam-se variáveis financeiras

1.3 Cloud Storage

O armazenamento em nuvem (*Cloud Storage*) consiste na oferta de persistência de dados como um serviço gerenciado. Ele se divide fundamentalmente em três categorias arquiteturais, cada uma com uma forma diferente de entregar e acessar os dados:

1. **Armazenamento de Blocos:** Funciona como um "disco virtual" bruto que é conectado a um servidor (*host*), permitindo que o sistema operacional crie nele seu próprio sistema de arquivos. Na AWS, o exemplo principal é o **EBS**.
2. **Armazenamento de Arquivos:** Disponibiliza uma estrutura tradicional de pastas e diretórios compartilhados por meio de protocolos de rede (como NFS ou SMB). Na AWS, o exemplo é o **EFS**.
3. **Armazenamento de Objetos:** Organiza os dados em repositórios chamados *buckets* e gerencia cada arquivo como um "objeto" isolado, acessado por meio de chaves, metadados e chamadas de API (via HTTP). Na AWS, o principal exemplo é o **S3**. As classes do **S3 Glacier** são apenas opções de arquivamento de longo prazo e baixo custo que ficam *dentro* do próprio ecossistema do S3; elas não funcionam como discos de servidor que podem ser montados diretamente.

A diferença entre essas categorias não está apenas na velocidade, mas na **forma como os dados são lidos e gravados**:

- **Modelo de Blocos:** entrega endereços de disco brutos e deixa o controle de arquivos e concorrência por conta do servidor. Bancos de dados relacionais tradicionais dependem de gravações frequentes e alterações em pequenas partes de arquivos (páginas de dados), o que se encaixa perfeitamente nesse modelo.
- **Modelo de Objetos:** não oferece atualização parcial *in-place* como um dispositivo de blocos. Se for preciso alterar apenas uma linha de um arquivo no S3, a aplicação normalmente grava uma nova versão ou substitui o objeto por meio da API. Por isso, *data lakes* frequentemente adotam arquivos grandes tratados como imutáveis por convenção, otimizados para análises em lote.

Em suma, tentar forçar o S3 a se comportar como um disco rígido tradicional (EBS) por meio de camadas de compatibilidade não altera a sua natureza fundamental, gerando problemas de desempenho e arquitetura.

1.4 Consistência, durabilidade e disponibilidade

Em sistemas de armazenamento em nuvem e arquiteturas de banco de dados, os conceitos de consistência, durabilidade e disponibilidade representam eixos independentes, porém complementares, que definem o comportamento e as garantias operacionais de uma plataforma.

- **Consistência:** Responde à pergunta “*qual versão de um dado a leitura observa imediatamente após uma operação de escrita?*”. O Amazon S3, por exemplo, oferece consistência forte de leitura após operações de PUT e DELETE em objetos novos ou existentes [9]. Contudo, consistência técnica ao nível de infraestrutura não valida a semântica da aplicação: o sistema pode gravar com sucesso um estado logicamente inválido ou permitir a exclusão acidental de um objeto correto.
- **Durabilidade:** Responde à pergunta “*qual é a probabilidade estatística de que o dado aceito e armazenado permaneça intacto ao longo do tempo, sem corrupção ou perda?*”. É uma métrica voltada sobretudo à resistência a falhas de mídia e de infraestrutura; não protege, por si só, contra exclusão autorizada, erro lógico da aplicação ou credenciais comprometidas.
- **Disponibilidade:** Responde à pergunta “*qual é a probabilidade de que uma operação receba uma resposta bem-sucedida no momento em que é solicitada?*”. Trata-se da operacionalidade contínua do serviço sob a perspectiva do cliente, mensurada por meio de acordos de nível de serviço (SLA) e indicadores de desempenho (SLIs).

Nenhum mecanismo de proteção isolado é capaz de mitigar todas as classes de risco inerentes a um ambiente de grande escala. Cada camada de segurança e redundância endereça uma vulnerabilidade distinta:

1. *A replicação física interna do provedor* protege contra falhas de hardware e indisponibilidades de componentes de infraestrutura dentro do modelo do serviço.

2. *O versionamento* protege contra a sobrescrita indesejada ou a exclusão lógica equivocada de dados.
3. *O backup independente e isolado* mitiga perdas decorrentes de comprometimento de credenciais ou falhas no domínio administrativo principal.
4. *A replicação entre regiões geográficas* serve como barreira contra desastres de grande escala que afetem uma área inteira.

Portanto, o projeto de arquitetura exige uma definição clara de ameaças, objetivos de ponto de recuperação (*RPO*), objetivos de tempo de recuperação (*RTO*) e o rigoroso controle de privilégios sobre quem detém a permissão para apagar cópias de recuperação.

Distinção central

Durabilidade mede a probabilidade de o dado persistir; disponibilidade mede a probabilidade de o serviço responder; consistência descreve o que uma leitura pode observar. Uma porcentagem de “11 noves” de durabilidade do S3 (99,999999999%) não promete 100% de disponibilidade, nem substitui a necessidade de versionamento, cópias redundantes entre regiões e testes periódicos de restauração.

2 Modelos de implantação

A escolha de um modelo de implantação determina onde a infraestrutura física reside, quem a opera e como o acesso e a governança são estruturados. Essa classificação difere dos modelos de serviço (como IaaS, PaaS ou SaaS), pois descreve a arquitetura de propriedade e isolamento organizacional, e não o nível de abstração da plataforma.

2.1 Pública

Na **nuvem pública**, um provedor terceirizado (como AWS, Azure ou GCP) aloca recursos computacionais sob demanda, compartilhados entre múltiplos clientes por meio de virtualização e isolamento lógico (*multi-tenancy*).

- **Vantagens:** Elasticidade quase ilimitada, eliminação de CAPEX (despesa de capital) em hardware físico e acesso imediato a um vasto ecossistema de serviços gerenciados.
- **Mitigação de riscos de rede:** “Pública” refere-se à propriedade da infraestrutura e ao modelo de entrega comercial, e não à exposição desprotegida na Internet. O uso de redes virtuais isoladas (VPCs), túneis VPN, conexões dedicadas (como AWS Direct Connect) e *endpoints* privados assegura que o tráfego corporativo ocorra em canais controlados.
- **Responsabilidade do cliente:** Embora o provedor gerencie o datacenter e os hosts físicos, a organização continua inteiramente responsável pela configuração de identidades (IAM), políticas de acesso, criptografia, monitoramento de quotas e controle de custos (FinOps).

2.2 Privada

Na **nuvem privada**, a infraestrutura é dedicada de forma exclusiva a uma única organização, podendo estar localizada fisicamente em seu próprio datacenter (*on-premises*) ou operada por um fornecedor terceirizado em um ambiente hospedado.

- **Vantagens:** Máximo controle sobre a topologia de rede, segurança física direta, customização avançada de hardware e atendimento rigoroso a mandatos de conformidade ou residência de dados.
- **Limitações e custos:** A capacidade é estática e finita, exigindo planejamento financeiro antecipado e investimento de capital. A organização absorve integralmente os custos de atualização tecnológica, redundância de energia, refrigeração e manutenção de equipe especializada.
- **Segurança operacional:** Uma nuvem privada não é inerentemente mais segura que a pública; a segurança depende estritamente da rigidez dos controles físicos, segmentações lógicas e processos de auditoria aplicados internamente pela equipe da instituição.

2.3 Híbrida e Padrões de Integração

A **nuvem híbrida** integra ambientes de nuvem privada (*on-premises*) com recursos de nuvem pública em uma única arquitetura coesa. A mera existência de servidores locais e instâncias na nuvem não caracteriza um modelo híbrido; é exigida a interoperabilidade contínua.

- **Requisitos de integração:** Para funcionar de maneira eficiente, a arquitetura híbrida demanda a unificação de políticas de identidade (ex.: diretórios federados), resolução de nomes, roteamento seguro, criptografia de ponta a ponta e ferramentas centralizadas de observabilidade e gestão de falhas.
- **Casos de uso comuns:**
 1. *Residência seletiva de dados:* Manutenção de bases sensíveis sob controle estrito local, enquanto cargas analíticas ou de processamento secundário rodam na nuvem.
 2. *Cloud Bursting (Picos de demanda):* Absorção de picos operacionais sazonais na nuvem pública quando a capacidade da infraestrutura privada local é atingida.
- **Desafios técnicos:** A movimentação massiva de bases de dados entre o ambiente local e a nuvem pode introduzir gargalos severos de largura de banda, latência elevada e custos inesperados com tráfego de saída (*egress*), o que pode invalidar os benefícios esperados se o fluxo de dados não for rigorosamente projetado.

Tabela 3: Diferenças estruturais entre os modelos de implantação.

Modelo	Vantagem principal	Limitação principal	Decisão crítica
Pública	Elasticidade, agilidade e serviços prontos sem aquisição de hardware.	Custo operacional recorrente e menor controle físico direto.	Governança de gastos, isolamento lógico e escolha de região.
Privada	Domínio total da infraestrutura, isolamento e aderência regulatória.	Capacidade finita, alto CAPEX e necessidade de equipe especializada.	Dimensionamento de longo prazo sem ociosidade excessiva.
Híbrida	Flexibilidade para combinar legados locais, segurança e demanda elástica.	Alta complexidade de integração, latência de rede e governança dispersa.	Estratégia de tráfego de dados, replicação e planos de failover.

3 Modelos de Serviço e Critérios de Avaliação

Enquanto a seção anterior tratou da governança de infraestrutura e dos modelos de implantação, esta seção aprofunda o espectro de abstração tecnológica oferecido pelos provedores de nuvem. Os modelos de serviço não representam gradações de qualidade, mas sim divisões contratuais e operacionais de responsabilidade entre o provedor e a organização. Para sistemas de banco de dados (SBD), a escolha da camada de abstração define diretamente o limite entre o esforço de engenharia dedicado à operação de infraestrutura e o esforço focado na modelagem de dados e na otimização de consultas.

3.1 O Espectro de Abstração e a Responsabilidade Compartilhada

O modelo de responsabilidade compartilhada delimita que a segurança e a gestão da infraestrutura física e de virtualização pertencem ao provedor, enquanto a responsabilidade sobre os ativos lógicos, dados, acessos e configurações recai sobre o cliente [7]. No entanto, a fronteira exata dessa divisão desloca-se conforme o modelo de serviço adotado:

- **IaaS (*Infrastructure as a Service*):** O provedor entrega os componentes fundamentais de computação, rede e armazenamento virtualizado. O cliente assume a responsabilidade total sobre o sistema operacional, *patches* de segurança, configuração de rede lógica, instalação, ajuste (*tuning*) e alta disponibilidade do SGBD.
- **PaaS (*Platform as a Service*):** O provedor gerencia o sistema operacional, o *runtime* e a orquestração do ambiente, permitindo que a equipe de engenharia concentre-se no código da aplicação e na lógica de negócio, com menor controle sobre os parâmetros de baixo nível do host.
- **SaaS (*Software as a Service*):** A pilha tecnológica inteira é operada pelo fornecedor. A organização gerencia apenas identidades de usuários, permissões de acesso ao conteúdo e políticas de governança corporativa.
- **DBaaS (*Database as a Service*) e DWaaS (*Data Warehouse as a Service*):** Serviços gerenciados voltados para persistência e processamento analítico. O provedor automatiza provisionamento, manutenção, backups e, quando a configuração de alta disponibilidade é habilitada, mecanismos de replicação e failover. O cliente continua responsável pelo modelo de dados, índices, consultas, privilégios, concorrência e políticas de retenção.

Tabela 4: Fronteiras operacionais nos modelos de serviço voltados a dados.

Modelo	Exemplo AWS	O provedor gerencia	O cliente projeta e opera
IaaS	EC2 / EBS / S3	Hardware, data center, hipervisor e rede base	SO, patches, SGBD, replicação, backup e dados
PaaS	Elastic Beanstalk	Infraestrutura, runtime e balanceamento	Código-fonte, configuração e dados da aplicação
DBaaS	RDS / Aurora	Infraestrutura, backups, patches e failover nas configurações de HA	Esquema SQL, índices, privilégios e plano de capacidade
DWaaS	Redshift	Cluster MPP, nós de computação e storage	Modelo dimensional, chaves de distribuição, WLM e custos
SaaS	QuickSight	Aplicação analítica ponta a ponta	Datasets, painéis, usuários, permissões e governança

Implicação arquitetural

A adoção de serviços gerenciados (DBaaS/DWaaS) elimina o ônus operacional de tarefas repetitivas de infraestrutura, mas introduz dependência estrita dos limites de escalabilidade, dos custos subjacentes e das políticas de concorrência impostas pelo projeto do provedor.

3.2 Critérios Quantificáveis de Avaliação: SLAs, SLIs e RPO/RTO

A avaliação de arquiteturas de dados em nuvem substitui termos vagos por métricas objetivas e verificáveis. Para entender esse monitoramento, é preciso definir três conceitos fundamentais de governança de serviços:

- **SLA (*Service Level Agreement* — Acordo de Nível de Serviço):** É o contrato formal estabelecido entre o provedor de nuvem e o cliente, definindo as garantias mínimas de desempenho, disponibilidade e penalidades caso o serviço falhe (ex: 99,99% de disponibilidade anual).
- **SLI (*Service Level Indicator* — Indicador de Nível de Serviço):** É a métrica técnica real e observável que mede o desempenho do sistema na prática (ex: a taxa de sucesso ou a latência das requisições percebidas pela aplicação).
- **SLO (*Service Level Objective* — Objetivo de Nível de Serviço):** É a meta interna de desempenho que a equipe estabelece para si mesma, geralmente mais rígida do que o SLA contratual.

Além disso, a análise de uma arquitetura baseia-se em dimensões essenciais de recuperação, escala e segurança financeira:

1. **Disponibilidade e SLIs:** A disponibilidade real não deve ser deduzida apenas do contrato do provedor (SLA), mas acompanhada por SLIs ponta a ponta que medem o sucesso operacional sob a perspectiva do usuário. Ambientes críticos exigem redundância ativa em múltiplas Zonas de Disponibilidade (Multi-AZ).
2. **Confiabilidade e Recuperação (RPO/RTO):** É preciso separar durabilidade (probabilidade estatística de retenção do dado sem corrupção, como os 11 noves do Amazon S3) de recuperabilidade. Como a durabilidade física não protege contra exclusões lógicas ou falhas humanas, objetivos de **RPO** (*Recovery Point Objective* — limite de perda aceitável de dados) e **RTO** (*Recovery Time Objective* — tempo máximo de restabelecimento) devem ser sustentados por uma estratégia de backup/replicação e por testes de restauração; versionamento e *Object Lock* podem ser adicionados quando o risco exige imutabilidade.
3. **Escalabilidade e Limites Operacionais:** A elasticidade de bases de dados difere de aplicações sem estado (*stateless*). Enquanto o processamento puro escala com facilidade, sistemas de dados enfrentam restrições inerentes à consistência de transações, contenção de *locks*, replicação de estado e limites físicos de I/O por nó ou *cluster*.
4. **Segurança e Custo Total de Propriedade (TCO):** A segurança exige uma estratégia em profundidade com menor privilégio via IAM, criptografia ponta a ponta e gestão de chaves (KMS). Paralelamente, o TCO vai muito além da capacidade bruta (GB-mês), englobando chamadas de API, varreduras de consulta, tráfego de saída (*egress*), replicação entre regiões e custos de suporte técnico.

Tabela 5: Critérios de avaliação de arquiteturas em nuvem e evidências técnicas.

Critério	Foco da análise	Evidência ou métrica de verificação
Disponibilidade	Continuidade de acesso sob falhas de componentes	SLIs de sucesso por operação e testes de failover Multi-AZ.
Recuperação	Limites de perda e tempo de restabelecimento	Valores de RPO e RTO validados por simulações de <i>restore</i> .
Escalabilidade	Comportamento sob crescimento de carga e concorrência	Testes de estresse, análise de contenção de partições e quotas.
Segurança	Isolamento, criptografia e rastreabilidade de acessos	Auditoria de logs (CloudTrail), matriz de privilégios IAM e KMS.
Desempenho	Comportamento temporal sob cargas críticas	Percentis de latência (p50, p95 e p99) de consultas e transações.
Custo (FinOps)	Previsibilidade e eficiência financeira do ecossistema	Análise TCO contemplando storage, compute, requests e egress.

4 Estudo de Caso: Amazon Web Services (AWS)

A Amazon Web Services (AWS), lançada em 2006, é atualmente uma das maiores e mais completas plataformas de nuvem pública do mundo, oferecendo mais de 200 serviços em áreas como computação, armazenamento, bancos de dados, redes, machine learning, analytics e IoT. A seguir, descrevem-se os serviços indicados no roteiro da tarefa.

4.1 Computação — Amazon EC2

O Amazon EC2 (Elastic Compute Cloud) é o serviço de IaaS da AWS que fornece capacidade de processamento bruto por meio de máquinas virtuais (instâncias). Como discutido anteriormente sobre o modelo IaaS, o cliente assume a responsabilidade operacional pelo sistema operacional, segurança e instalação das aplicações.

O provisionamento envolve duas escolhas arquiteturais centrais:

- **Tipos de Instância (Famílias):** A seleção do hardware ideal para a carga de trabalho. A AWS categoriza as máquinas em diferentes famílias, variando desde instâncias de uso geral até modelos especializados. Para um banco de dados, por exemplo, o arquiteto pode escolher máquinas otimizadas para computação (para consultas complexas), otimizadas para memória (para *caching* e alto desempenho) ou otimizadas para armazenamento (focadas em alta taxa de leitura e gravação local).
- **Modelos de Pagamento:** Define como o recurso será faturado. Pode ser Sob Demanda (*On-Demand*), onde se paga apenas pelo uso exato, ou por instâncias *Spot* (capacidade ociosa com grande desconto, mas sujeita a interrupções abruptas, sendo inadequada para bancos de dados críticos). Para cargas previsíveis, há Instâncias Reservadas e *Savings Plans*, com descontos em troca de compromissos de uso. As Reservadas aplicam descontos sob atributos e escopos específicos e existem também modalidades conversíveis; os *Savings Plans* se baseiam em compromisso de gasto por hora e, em geral, oferecem maior flexibilidade de família e configuração.

Em aplicações sem estado, é comum combinar EC2 Auto Scaling e Elastic Load Balancing para escalar horizontalmente. Um SGBD auto-gerenciado, porém, não pode ser escalado de forma ingênua atrás de um balanceador: escrita e estado exigem replicação, particionamento e coordenação. Para armazenamento persistente em bloco, a opção padrão do EC2 é o Amazon EBS, embora aplicações também possam usar serviços como EFS, FSx ou S3 conforme o padrão de acesso.

4.2 Armazenamento — EBS, S3 e Glacier

Enquanto o EC2 fornece o processamento, as opções de armazenamento dividem-se fundamentalmente pela forma como o sistema operacional acessa os dados:

- **Amazon EBS (Elastic Block Store):** Como visto anteriormente, o EBS atua como armazenamento de blocos persistente para EC2 e é uma escolha comum para SGBDs auto-gerenciados. *Elastic Volumes* permite aumentar capacidade e alterar características de desempenho de volumes compatíveis sem desligar a instância, embora o sistema operacional e o sistema de arquivos possam exigir etapas adicionais. Normalmente um volume é anexado a uma instância por vez; volumes io1/io2 com *Multi-Attach* são uma exceção e podem ser compartilhados por até 16 instâncias Nitro na mesma AZ [21].
- **Amazon S3 (Simple Storage Service) e S3 Glacier:** Conforme introduzido anteriormente, o S3 é um armazenamento de objetos acessado via rede por API/SDKs e estruturado em *buckets*, atuando como a fundação de *Data Lakes* em vez de bancos transacionais. Nas classes multi-AZ, como S3 Standard e Standard-IA, os dados são armazenados redundantemente em pelo menos três Zonas de Disponibilidade; classes One Zone são a exceção e permanecem em uma única AZ [10].

O modelo de custos do ecossistema S3 varia conforme a classe de armazenamento (*tier*), separando a cobrança entre a retenção do dado e a sua recuperação. A classe **S3 Standard** utiliza três ou mais AZs e é adequada a dados acessados frequentemente; o custo de retenção é maior, mas

não há cobrança por GB de recuperação de dados (as requisições continuam sendo cobradas). A família **S3 One Zone** difere por utilizar apenas uma AZ. Dentro dessas famílias há variações: o *Express One Zone* entrega latência baixíssima por um custo de armazenamento maior, enquanto as opções *IA (Infrequent Access)* reduzem o custo de retenção, mas embutem uma taxa financeira na recuperação. Por fim, a família **S3 Glacier** foca em arquivamento (como retenção legal de longo prazo) e divide-se em três opções: *Instant Retrieval* (mantém acesso em milissegundos, mas com alta taxa financeira de leitura), *Flexible Retrieval* (armazenamento mais barato, mas a recuperação leva de minutos a horas) e *Deep Archive* (retenção com o menor custo possível, exigindo de 12 a 48 horas para recuperar os dados).

4.3 Banco de Dados — RDS, Aurora, DynamoDB e Redshift

A AWS oferece um portfólio de serviços gerenciados de banco de dados que se diferenciam pelo modelo de dados, pelo padrão de acesso que otimizam e pelo tipo de carga de trabalho ao qual se destinam — transacional (OLTP) ou analítica (OLAP). A escolha entre eles depende principalmente da estrutura dos dados (rígida ou flexível), do volume/latência exigidos e da natureza das consultas realizadas.

- **Amazon RDS (Relational Database Service):** serviço de *Database as a Service* (DBaaS) para bancos relacionais gerenciados, com suporte a Db2, MariaDB, MySQL, Oracle, PostgreSQL e SQL Server. O RDS automatiza provisionamento, *patches*, backups automáticos e restauração *point-in-time*, enquanto o cliente continua responsável por esquema, índices, consultas e privilégios. Para alta disponibilidade, configurações Multi-AZ mantêm capacidade redundante e permitem failover automático; para aumentar throughput de leitura, Read Replicas mantêm cópias assíncronas do banco [24][18].
- **Amazon Aurora:** banco relacional gerenciado compatível com MySQL e PostgreSQL cuja principal diferença arquitetural é a camada de armazenamento distribuída e compartilhada pelas instâncias do cluster. Os dados são mantidos em seis cópias distribuídas por três *Availability Zones*; o volume cresce automaticamente e o limite máximo é 128 ou 256 TiB, conforme a versão do mecanismo [16]. Um cluster pode ter até 15 Aurora Replicas compartilhando o mesmo volume lógico, além de recursos como backup contínuo/PITR, Aurora Serverless v2 e Global Database. Portanto, a distinção essencial frente ao RDS convencional não é uma contagem fixa de réplicas, mas a arquitetura de armazenamento compartilhado e sua integração com leitura e failover [19].
- **Amazon DynamoDB:** banco de dados NoSQL serverless e totalmente gerenciado, do tipo chave-valor/documento. A AWS o descreve como capaz de manter desempenho consistente de **milissegundos de um dígito** em qualquer escala. Suporta modos de capacidade *On-Demand* e *Provisioned*, leituras eventualmente consistentes ou fortemente consistentes e transações ACID. O modelo de dados é desenhado em torno dos padrões de acesso da aplicação, e o serviço não oferece operador de *JOIN*; por isso, aplicações costumam desnormalizar dados para evitar múltiplas viagens ao banco [20].
- **Amazon Redshift:** serviço de *Data Warehouse as a Service* (DWaaS), baseado em armazenamento colunar e processamento massivamente paralelo (*Massively Parallel Processing*, MPP), voltado a consultas analíticas (OLAP) sobre grandes volumes de dados históricos. O armazenamento por colunas, combinado a técnicas de compressão (*dictionary encoding*, *run-length encoding*, entre outras), permite que operações de agregação leiam apenas as colunas relevantes para a consulta, em vez de linhas inteiras, reduzindo drasticamente o volume de I/O em relação a bancos orientados a linha. O Redshift integra-se ao Amazon S3 por meio do **Redshift Spectrum**, recurso que permite consultar diretamente dados do *data lake* sem carregá-los previamente no armazenamento local do warehouse, viabilizando uma arquitetura de *lakehouse*. Tipicamente, o Redshift é alimentado por processos de ETL a partir de bancos operacionais (RDS, Aurora, DynamoDB), consolidando dados transacionais para fins de *Business Intelligence* e relatórios agregados.

Em síntese, RDS e Aurora atendem a cargas transacionais estruturadas (OLTP), com o Au-

rora otimizando desempenho e disponibilidade por meio de sua arquitetura de armazenamento distribuído; o DynamoDB atende a cargas transacionais de altíssima escala e baixa latência com dados semiestruturados; e o Redshift atende a cargas analíticas (OLAP) sobre grandes volumes de dados consolidados, completando o espectro de necessidades de armazenamento e processamento de dados oferecido pela AWS.

5 Estudo de Custo: Armazenamento e Processamento de 3,5 Petabytes na AWS

Nesta seção, estima-se o custo de armazenar e processar uma base de dados de 3,5 Petabytes (PB) na AWS, discutindo-se também vantagens e desvantagens dessa escolha. Os valores de referência foram obtidos na região us-east-1 (N. Virgínia), consultados em setembro de 2026, e representam preços públicos de lista — sem descontos privados ou contratuais por volume. Recomenda-se confirmar os valores no AWS Pricing Calculator antes da apresentação, pois preços e condições podem mudar.

Premissa de conversão: o prefixo PB é decimal no SI: $1 \text{ PB} = 10^{15} \text{ bytes}$. Portanto, $3,5 \text{ PB} = 3.500 \text{ TB decimais} = 3.500.000 \text{ GB decimais}$. O S3, entretanto, define sua unidade de cobrança “GB” como 2^{30} bytes e “TB” como 2^{40} bytes [11]. Assim, 3,5 PB correspondem a aproximadamente **3.259.629 GB de cobrança (GiB)** ou **3.183,23 TB de cobrança (TiB)**. A versão anterior do trabalho usava 3.584 TB e 3.670.016 GB; esses números correspondem a **3,5 PiB**, não a 3,5 PB.

5.1 Custo de armazenamento por classe do Amazon S3

O Amazon S3 Standard utiliza preço escalonado: US\$ 0,023/GB nos primeiros 50 TB de cobrança, US\$ 0,022/GB nos 450 TB seguintes e US\$ 0,021/GB acima de 500 TB por mês. Como a própria AWS define 1 TB de cobrança como 1.024 GB, os limites das duas primeiras faixas correspondem a 51.200 e 460.800 GB, respectivamente. Aplicando essas faixas aos 3.259.629 GB de cobrança do estudo, obtém-se a estimativa abaixo.

Tabela 6: Estimativa de custo mensal de armazenamento de 3,5 PB no Amazon S3 Standard (preços de lista, us-east-1, set/2026).

Faixa	Volume (GB de cobrança)	Preço/GB (US\$)	Custo mensal (US\$)
Primeiros 50 TB AWS	51.200	0,023	1.178
50 TB – 500 TB AWS	460.800	0,022	10.138
Acima de 500 TB AWS	2.747.629	0,021	57.700
Total (S3 Standard)	≈ 3.259.629	—	≈ 69.015 / mês (≈ US\$ 828.185 / ano)

Como esse é um valor recorrente e elevado, é comum, na prática, aplicar políticas de ciclo de vida (lifecycle policies) que movem automaticamente dados frios para classes mais baratas. A Tabela 7 compara o custo estimado da mesma base de 3,5 PB em diferentes classes de armazenamento do S3.

Tabela 7: Comparação de custo mensal estimado de 3,5 PB por classe de armazenamento do Amazon S3.

Classe de armazenamento	Preço (US\$/GB/mês)	aprox.	Custo mensal estimado (US\$)	Latência de acesso
S3 Standard	0,021 – 0,023 (escalonado)	≈ 69.015		Milissegundos
S3 Standard-IA	0,0125	≈ 40.745		Milissegundos (com taxa de recuperação)
S3 Glacier Flexible Retrieval	≈ 0,0036	≈ 11.735		Minutos a horas
S3 Glacier Deep Archive	0,00099	≈ 3.227 (≈ US\$ 38.724/ano)		Horas (restauração assíncrona)

A diferença é expressiva: S3 Glacier Deep Archive reduz o custo de capacidade em cerca de 95,3% em relação ao S3 Standard, mas não é uma alternativa equivalente. Standard-IA possui duração mínima de armazenamento de 30 dias; Glacier Flexible Retrieval, 90 dias; e Deep Archive, 180 dias.

Além disso, classes Glacier têm custos e tempos de restauração e cobram metadados adicionais por objeto arquivado [11]. Na prática, uma base de 3,5 PB tende a usar camadas: dados quentes em Standard, dados mornos em Standard-IA e dados frios em classes Glacier, com S3 Intelligent-Tiering ou políticas de ciclo de vida quando o padrão de acesso justificar.

5.2 Custos adicionais: requisições, transferência de dados (egress) e processamento

O custo de armazenamento é apenas uma das dimensões da fatura. Requisições (PUT/GET/LIST), recuperação de classes frias e transferência para a Internet podem ser cobradas separadamente. Na transferência de dados para a Internet, a AWS oferece atualmente os primeiros 100 GB/mês sem cobrança agregados entre serviços; acima disso há faixas de preço, e para volumes superiores a 500 TB/mês a própria página de preços orienta contatar a AWS, de modo que não é tecnicamente correto extrapolar uma tarifa pública única para 3,5 PB [11]. Para uma migração definitiva para fora da AWS, existe ainda um processo de isenção de Data Transfer Out elegível mediante solicitação ao suporte [22]. Portanto, egress operacional continua sendo uma variável relevante de TCO, mas não deve ser apresentado como um custo inevitável de centenas de milhares de dólares em toda migração de saída.

Para processar uma base dessa escala, a AWS oferece, entre outras opções, Amazon EMR (Hadoop/Spark) para processamento distribuído em lote, Amazon Redshift/Redshift Spectrum para cargas analíticas recorrentes e Amazon Athena para SQL ad hoc diretamente sobre o S3. No modo sob demanda, o Athena cobra atualmente US\$ 5 por TB escaneado [15]. Como esse valor depende do que cada consulta realmente lê, não existe um único “custo de processar 3,5 PB”. A Tabela 8 mostra apenas um cenário ilustrativo, mantendo o tamanho lógico do enunciado em unidades decimais e ignorando custos auxiliares de S3/Glue/resultados.

Tabela 8: Exemplo ilustrativo de custo de processamento com Amazon Athena a US\$ 5/TB escaneado.

Fração lógica da base lida	Volume escaneado	Custo por consulta	Interpretação
1%	35 TB	≈ US\$ 175	Consulta muito seletiva/particionada
10%	350 TB	≈ US\$ 1.750	Consulta analítica ampla
100%	3.500 TB	≈ US\$ 17.500	Varredura lógica integral

O exemplo evidencia por que compressão, particionamento e formatos colunares como Parquet/ORC têm efeito financeiro direto: reduzir o volume efetivamente escaneado reduz proporcionalmente o custo no modelo por consulta. Para cargas frequentes, concorrentes ou previsíveis, Redshift ou capacidade reservada do próprio Athena podem ser mais adequados; a escolha depende do *workload*, não apenas do volume total armazenado.

5.3 Por que S3 é a camada-base nessa escala

Os 3,5 PB não devem ser interpretados como tamanho de uma única instância de banco relacional. O Aurora convencional, por exemplo, limita o volume de cluster a 128 ou 256 TiB conforme a versão [16]; portanto, um conjunto de 3,5 PB exigiria particionamento entre vários domínios ou outra arquitetura. RDS e Aurora são apropriados para subconjuntos que exigem transações OLTP; o acervo analítico bruto pode permanecer no S3 e ser consultado por Athena ou Redshift Spectrum. Essa separação entre armazenamento de objetos e motores de consulta é a razão arquitetural para usar S3 como camada de persistência do estudo, e não apenas uma decisão de preço.

5.4 Vantagens de armazenar e processar 3,5 PB na AWS

- **Elasticidade:** capacidade praticamente ilimitada, sem necessidade de planejamento de capacidade física nem investimento inicial em hardware.

- **Durabilidade e disponibilidade:** 99,999999999% de durabilidade no S3 Standard, com replicação automática entre múltiplas zonas de disponibilidade.
- **Ecossistema integrado:** possibilidade de usar o mesmo dado armazenado no S3 diretamente em serviços de analytics (Athena, Redshift Spectrum), machine learning (SageMaker) e data lakes, sem necessidade de movimentação (evitando egress).
- **Granularidade de custo por camada:** uso de políticas de ciclo de vida para reduzir custo de dados frios automaticamente, algo difícil de replicar com a mesma flexibilidade em infraestrutura própria.
- **Segurança e conformidade:** criptografia, IAM, KMS e amplo conjunto de programas/certificações de conformidade. Esses recursos reduzem trabalho de infraestrutura, mas não tornam automaticamente a aplicação do cliente conforme: configuração, dados e controles do cliente continuam dentro do modelo de responsabilidade compartilhada.

5.5 Desvantagens de armazenar e processar 3,5 PB na AWS

- **Custo recorrente elevado:** a nuvem transforma grande parte do investimento em despesa operacional mensal. Infraestrutura própria também possui OPEX, renovação, energia e equipe, mas o custo de capacidade em nuvem permanece recorrente e precisa ser acompanhado continuamente.
- **Portabilidade e egress:** transferências operacionais recorrentes para fora da AWS podem ter custo relevante e APIs/serviços proprietários também criam *lock-in*. Para uma saída definitiva do provedor, a AWS atualmente oferece um processo de isenção de Data Transfer Out elegível, o que deve ser considerado separadamente do egress cotidiano [22].
- **Complexidade de otimização (FinOps):** obter o melhor custo-benefício exige monitoramento contínuo, escolha correta de classes de armazenamento, formatos de arquivo e padrões de acesso — o que demanda equipe especializada.
- **Latência em dados arquivados:** classes mais baratas (Glacier) não permitem acesso imediato, o que é inadequado caso parte da base de 3,5 PB precise ser consultada com frequência.
- **Governança e soberania de dados:** a escolha de região afeta residência, jurisdição, latência e controles de acesso. No caso da LGPD, transferências internacionais e os mecanismos jurídicos aplicáveis devem ser avaliados; não se deve resumir a exigência a uma regra genérica de “dados precisam ficar no Brasil”.

Em síntese, a AWS é tecnicamente capaz de armazenar e processar 3,5 PB, mas as classes comparadas não são equivalentes: o armazenamento puro varia, nas premissas deste estudo, de aproximadamente US\$ 3,2 mil/mês em Deep Archive a US\$ 69,0 mil/mês em S3 Standard; entre as opções de acesso em milissegundos mostradas na tabela, fica aproximadamente entre US\$ 40,7 mil e US\$ 69,0 mil/mês. Processamento, requisições, recuperação, proteção, suporte e transferência podem alterar materialmente o TCO.

6 Conclusão

A computação em nuvem oferece elasticidade e um amplo portfólio de serviços gerenciados, mas distribui responsabilidades entre provedor e cliente. No estudo da AWS, EC2/EBS representam infraestrutura como serviço; Elastic Beanstalk exemplifica PaaS; QuickSight, SaaS; RDS, Aurora e DynamoDB são bancos gerenciados; Redshift é um data warehouse gerenciado; e S3 fornece armazenamento de objetos com classes para diferentes padrões de acesso.

O estudo de custo para uma base de 3,5 Petabytes demonstrou, no entanto, que a elasticidade da nuvem tem um preço real e recorrente, e que a escolha ingênua de uma única classe de armazenamento pode custar dezenas ou centenas de milhares de dólares a mais por ano do que uma estratégia de camadas bem desenhada. Isso reforça a importância, para qualquer profissional de Banco de Dados e Engenharia de Dados, de compreender não apenas os aspectos técnicos dos serviços de nuvem, mas também seu modelo de precificação, de modo a tomar decisões de arquitetura que sejam tecnicamente adequadas e financeiramente sustentáveis.

7 Questões para apresentação e debate

1. Quando um data lake deixa de ser mais barato que um warehouse por causa do volume escaneado?
2. “Onze noves” de durabilidade justificam dispensar backup entre contas ou regiões?
3. Qual componente cria maior lock-in: formato dos dados, serviço de banco, IAM ou egress?
4. Que fração dos 3,5 PB precisa realmente de acesso em milissegundos?
5. Uma comparação justa com on-premises deve incluir energia, equipe, renovação, capacidade ociosa e risco?

8 Post-Mortem

Esta seção atende aos três elementos exigidos: log dos prompts, autoria/decisões e erros da IA com correções. Ela distingue fatos verificáveis nesta revisão de informações humanas que ainda precisam ser confirmadas. A estrutura inicial foi produzida com apoio do Claude (Anthropic), e revisões técnicas, de consistência e de apresentação foram realizadas com ferramentas da OpenAI (Codex/ChatGPT).

8.1 Log dos prompts-chave

Nº	Prompt ou instrução-chave	Efeito verificável
1	Enunciado completo e pedido de um trabalho sobre AWS com nível “nota 10”.	Definiu checklist, provedor e produtos obrigatórios.
2	Pesquisa de preços atualizados de S3 e construção de estudo para 3,5 PB.	Gerou a primeira tabela de preços e a conversão PB/PiB.
3	Pedido anterior para reforçar autoria, auditoria e arquivos editáveis.	Criou matriz, declaração e lista inicial de erros.
4	“Ajustar os trabalhos de Cloud e DAS e RAID; avaliar como professor; transformar o relatório em LaTeX e gerar o PDF; seguir NAS, SAN e AST.”	Motivou a revisão adversarial, a reconstrução em LaTeX, os novos PDFs e o alinhamento dos slides.
5	Verificação web restrita a documentação oficial da AWS para preços, limites e semântica.	Corrigiu/confirmou preços, separou durabilidade de disponibilidade e explicitou limites e custos omitidos.
6	Revisão final de consistência entre relatório, slides e Post-Mortem em 11/09/2026.	Unificou PB/PiB, sincronizou RDS/Aurora, simplificou o slide relacional e acrescentou um exemplo quantitativo de processamento com Athena.

8.2 Matriz de Responsabilidades e Declaração de Autoria

A tabela abaixo registra a divisão de trabalho declarada no material do grupo. Antes da entrega, cada integrante deve confirmar que a responsabilidade atribuída e a revisão crítica descrita correspondem ao que efetivamente realizou; Conclusão e Post-Mortem são apresentados como seções de revisão conjunta.

Integrante	Responsabilidade na versão final	Decisão e justificativa
Vivian Maria da Silva e Souza DRE 123205793	Tipos de nuvem (pública, privada, híbrida) e Modelos de serviço (IaaS, PaaS, SaaS, DBaaS, DWaaS).	Estruturou a diferença conceitual e contratual de cada modelo para alinhar com as exigências de arquitetura.
Gabriel Schmitz Corrêa Rizin DRE 123225573	Computação (EC2) e Armazenamento em Bloco (EBS).	Focou na explicação de instâncias e volumes elásticos para cargas que exigem processamento e discos diretamente atrelados.
Enzo de Carvalho Sampaio DRE 123386206	Armazenamento de Objetos (S3) e Bancos de Dados Relacionais (RDS e Aurora).	Definiu a arquitetura de data lakes e SGBDs gerenciados em contraste com a infraestrutura tradicional.

Integrante	Responsabilidade na versão final	Decisão e justificativa
Guilherme En Shih Hu DRE 123224674	Definição de Cloud Computing, Tipos de armazenamento (bloco, arquivo, objeto) e Consistência, durabilidade e disponibilidade.	Separou os eixos de garantias operacionais para demonstrar como mitigam diferentes categorias de risco.
Raphael Henrique da Silva Pereira DRE 123420783	Critérios de avaliação de cloud e Características fundamentais (acessibilidade, disponibilidade, latência, escalabilidade, segurança).	Consolidou os parâmetros do NIST e SLAs para fundamentar a avaliação quantitativa e qualitativa da nuvem.
Bernardo Brandão Pozzato Carvalho Costa DRE 123289593	Estudo de custo e arquitetura para 3,5 PB e Serviços NoSQL e DWaaS (DynamoDB e Redshift).	Conectou a precificação de altíssimo volume com as ferramentas específicas de consulta analítica e armazenamento colunar.
Claude (Anthropic) <i>IA Generativa</i>	Geração inicial declarada no DOCX anterior.	Saída submetida à revisão; não é autor acadêmico.
Ferramentas da OpenAI (Codex/ChatGPT) <i>IA Generativa</i>	Auditoria, pesquisa oficial, reestruturação, LaTeX, PDF e alinhamento entre relatório e slides.	Premissas de custo explícitas; apoio técnico submetido à revisão do grupo.

Responsáveis pelas correções

Guilherme corrigiu os itens 1 e 6; Enzo, 2 e 3; Gabriel, 4; Vivian, 5 e 9; Bernardo, 7 e 8; Raphael, 10. As ferramentas da OpenAI auxiliaram a verificação e a edição, mas a divisão e a aceitação das correções pertencem ao grupo.

8.3 Erros da IA e correções aplicadas

Nº	Erro/risco encontrado	Verificação	Correção
1	Seção “8.5” aparecia no sumário antes do corpo e referências soltas também entravam no sumário.	Inspeção do DOCX/PDF.	Documento reconstruído com hierarquia LaTeX e referências no fim.
2	Parágrafo sobre nuvem privada estava duplicado.	Comparação textual.	Duplicata removida.
3	“Cloud Storage” sugeria apenas armazenamento remoto replicado.	Taxonomia AWS e literatura.	Separação explícita entre objeto, bloco, arquivo, arquivo frio e storage gerenciado.
4	Durabilidade de 11 noves podia ser lida como disponibilidade.	Documentação S3.	As métricas e seus efeitos foram separados.
5	O custo de 3,5 PB parecia total, embora só cobrisse capacidade.	Páginas oficiais de preço.	Tabela rotulada como capacidade; compute, requests, egress, recuperação, replicação e suporte separados.

Nº	Erro/risco encontrado	Verificação	Correção
6	Inconsistência entre PB (decimal) e PiB (binário) no cálculo de custos.	Reexecução dimensional e página de preços do S3.	PB foi mantido como unidade SI: 3,5 PB = $3,5 \times 10^{15}$ bytes; a capacidade foi então convertida para aproximadamente 3.259.629 GB binários de cobrança da AWS.
7	A estimativa de 3,5 PB podia sugerir que RDS/Aurora seriam recipientes alternativos equivalentes ao S3.	Documentação oficial de limites e arquitetura.	Foi explicitado que bancos OLTP armazenam apenas os subconjuntos transacionais; o acervo analítico permanece no S3 e pode ser consultado por motores analíticos.
8	“S3 ilimitado” escondia quotas dos consumidores e impossibilidade de um único volume/cluster.	Documentação EBS/RDS/Aurora.	Arquitetura distribuída e limites por recurso explicitados.
9	“Gerenciado” sugeria que backup e failover existiam em toda configuração RDS.	Documentação RDS Multi-AZ.	Responsabilidade e modalidade Multi-AZ explicitadas.
10	O Post-Mortem dizia que humanos já haviam revisado seções, sem evidência nos arquivos.	Auditoria de autoria.	Afirmações convertidas em confirmações pendentes e ações comprovadas separadas.
11	Relatório, slides e Post-Mortem chegaram a registrar versões diferentes para PB/PiB e RDS/Aurora.	Comparação cruzada dos artefatos finais.	Uma única convenção de 3,5 PB decimal foi aplicada aos cálculos; RDS/Aurora foi sincronizado e os slides foram simplificados para resumir o relatório sem criar novas afirmações.

Consolidação do Post-Mortem coordenada por Raphael — 06/09/2026

O plano de correções descrevia uma versão anterior, ainda sem PDF e com inconsistências de unidade, custos e cobertura. A pedido de Raphael Henrique da Silva Pereira, o Codex o utilizou como checklist e conferiu o estado atual: o relatório separa PB decimal das unidades binárias de cobrança do S3, inclui EFS, estima armazenamento, quantifica um cenário de consulta no Athena e propõe uma arquitetura distribuída. A revisão final de 11/09/2026 reconciliou relatório, slides e Post-Mortem. A divisão final acima foi adotada por coerência entre as seções e as responsabilidades de revisão.

Referências

- [1] MELL, P.; GRANCE, T. *The NIST Definition of Cloud Computing*. NIST SP 800-145, 2011. <https://doi.org/10.6028/NIST.SP.800-145>.
- [2] SILBERSCHATZ, A.; KORTH, H.; SUDARSHAN, S. *Sistema de Banco de Dados*. 7. ed. Elsevier, 2020.
- [3] ELMASRI, R.; NAVATHE, S. *Sistemas de Banco de Dados*. 7. ed. Pearson, 2019.
- [4] ÖZSU, M. T.; VALDURIEZ, P. *Principles of Distributed Database Systems*. 4. ed. Springer, 2020.
- [5] ERL, T.; PUTTINI, R.; MAHMOOD, Z. *Cloud Computing: Concepts, Technology & Architecture*. Prentice Hall, 2013.
- [6] HUAWEI TECHNOLOGIES. *Cloud Computing Technology*. Springer, 2023.
- [7] AWS. *Shared Responsibility Model*. <https://aws.amazon.com/compliance/shared-responsibility-model/>. Acesso em 05 set. 2026.
- [8] AWS. *Data protection in Amazon S3*. <https://docs.aws.amazon.com/AmazonS3/latest/userguide/DataDurability.html>. Acesso em 05 set. 2026.
- [9] AWS. *Amazon S3 data consistency model*. <https://docs.aws.amazon.com/AmazonS3/latest/userguide/Welcome.html#ConsistencyModel>. Acesso em 05 set. 2026.
- [10] AWS. *Understanding and managing Amazon S3 storage classes*. <https://docs.aws.amazon.com/AmazonS3/latest/userguide/storage-class-intro.html>. Acesso em 05 set. 2026.
- [11] AWS. *Amazon S3 pricing*. <https://aws.amazon.com/s3/pricing/>. Acesso em 05 set. 2026.
- [12] AWS. *Amazon EBS pricing*. <https://aws.amazon.com/ebs/pricing/>. Acesso em 05 set. 2026.
- [13] AWS. *Amazon RDS pricing*. <https://aws.amazon.com/rds/pricing/>. Acesso em 05 set. 2026.
- [14] AWS. *Amazon Redshift pricing*. <https://aws.amazon.com/redshift/pricing/>. Acesso em 05 set. 2026.
- [15] AWS. *Amazon Athena pricing*. <https://aws.amazon.com/athena/pricing/>. Acesso em 05 set. 2026.
- [16] AWS. *Quotas and constraints for Amazon Aurora*. https://docs.aws.amazon.com/AmazonRDS/latest/AuroraUserGuide/CHAP_Limits.html. Acesso em 06 set. 2026.
- [17] AWS. *Amazon Redshift provisioned clusters: node types and managed storage limits*. <https://docs.aws.amazon.com/redshift/latest/mgmt/working-with-clusters.html>. Acesso em 06 set. 2026.
- [18] AWS. *Working with DB instance read replicas*. https://docs.aws.amazon.com/AmazonRDS/latest/UserGuide/USER_ReadRepl.html. Acesso em 11 set. 2026.
- [19] AWS. *Amazon Aurora FAQs*. <https://aws.amazon.com/rds/aurora/faqs/>. Acesso em 11 set. 2026.
- [20] AWS. *What is Amazon DynamoDB?*. <https://docs.aws.amazon.com/amazondynamodb/latest/developerguide/Introduction.html>. Acesso em 11 set. 2026.
- [21] AWS. *Attach an EBS volume to multiple EC2 instances using Multi-Attach*. <https://docs.aws.amazon.com/ebs/latest/userguide/ebs-volumes-multi.html>. Acesso em 11 set. 2026.

- [22] AWS. *Free data transfer out to internet when moving out of AWS*. <https://aws.amazon.com/blogs/aws/free-data-transfer-out-to-internet-when-moving-out-of-aws/>. Acesso em 11 set. 2026.
- [23] AWS. *Security Pillar — Shared Responsibility*. <https://docs.aws.amazon.com/wellarchitected/latest/security-pillar/shared-responsibility.html>. Acesso em 06 set. 2026.
- [24] AWS. *Multi-AZ DB instance deployments for Amazon RDS*. <https://docs.aws.amazon.com/AmazonRDS/latest/UserGuide/Concepts.MultiAZSingleStandby.html>. Acesso em 06 set. 2026.
- [25] AWS. *Amazon Redshift performance: MPP and columnar storage*. https://docs.aws.amazon.com/redshift/latest/dg/c_challenges_achieving_high_performance_queries.html. Acesso em 06 set. 2026.
- [26] AWS. *Partition your data in Amazon Athena*. <https://docs.aws.amazon.com/athena/latest/ug/partitions.html>. Acesso em 06 set. 2026.