

Dispositivos de Armazenamento Físico para Sistemas de Banco de Dados

Interfaces de Conexão e Parâmetros para o
Gerente de Armazenamento do SBD

*Atualização da Tabela 16.1 (Elmasri & Navathe, 7ª ed.)
dados consultados em 05 de setembro de 2026*

Integrantes do Grupo

Nome completo	DRE
Bernardo Brandão Pozzato Carvalho Costa	123289593
Enzo de Carvalho Sampaio	123386206
Gabriel Schmitz Corrêa Rizawinsk	123225573
Guilherme En Shih Hu	123224674
Raphael Henrique da Silva Pereira	123420783
Vivian Maria da Silva e Souza	123205793

Resumo

Este trabalho realiza um estudo sobre dispositivos de armazenamento físico para Sistemas de Banco de Dados (SBD), suas interfaces de conexão e os parâmetros relevantes para o *Gerente de Armazenamento* do SBD. Partindo do Capítulo 16 de Elmasri & Navathe (7ª ed.) e do Capítulo 12 de Silberschatz, Korth & Sudarshan (7ª ed.), o estudo entrega três produtos técnicos: (i) uma revisão dos fundamentos da hierarquia de memória, da mecânica do disco magnético, da física da memória *flash* e do estado atual da memória de classe de armazenamento; (ii) a **atualização integral da Tabela 16.1** substituindo cada categoria genérica por produtos comercialmente disponíveis em 2026, com capacidade, tempo de acesso, largura de banda *segregada em leitura e escrita*, faixa de preço corrente e uma nova coluna de **preço por kilobyte**; e (iii) uma tabela comparativa de cinquenta e seis variantes de interface de conexão (USB, SCSI, SATA, eSATA, SATA Express, SAS, PCIe/NVMe e seus fatores de forma M.2, U.2, U.3 e EDSFF, NVMe-oF, iSCSI, FireWire, HBA, Fibre Channel, FCIP, FCoE e InfiniBand), analisando serialidade, codificação de linha, latência, taxa útil, distância e portabilidade.

Os achados principais contrariam três expectativas correntes na literatura didática. Primeiro, a memória persistente byte-endereçável **desapareceu do mercado**: o Intel Optane foi descontinuado e o vazio de três ordens de grandeza entre DRAM (≈ 70 ns) e SSD NVMe (≈ 50 μ s) só é parcialmente preenchido por módulos CXL, que medem 214–271 ns — duas a duas vezes e meia a latência da DRAM local, e ainda a três ordens de grandeza do NVMe. Segundo, SSD e HDD **divergiram em vez de convergir** em custo por terabyte, com razão de $16\times$ no 2º trimestre de 2026 e $18,6\times$ na observação parcial de 05/09/2026. Terceiro, o desempenho de um SBD moderno é governado por **latência e profundidade de fila**, não por largura de banda — o que explica por que o SATA morreu tecnicamente em 6 Gb/s sem que ninguém se importasse, e por que o NVMe venceu.

O documento inclui uma seção obrigatória de **Post-Mortem** com o log dos prompts-chave utilizados, a demonstração de autoria dos participantes e o registro auditável dos erros gerados pelo assistente de IA e das respectivas correções feitas pelo grupo — entre elas a correção de uma afirmação factualmente incorreta presente no próprio enunciado da tarefa (“SATA também é conhecida como NL-SAS”).

Palavras-chave: hierarquia de memória; SSD NVMe; HAMR; LTO-10; CXL; Fibre Channel; InfiniBand; gerente de armazenamento; latência de *commit*.

Conteúdo

Resumo	2
1 Introdução	1
1.1 Motivação	1
1.2 Objetivos	1
1.3 Metodologia e critérios de seleção	1
1.4 Estrutura do documento	2
2 Fundamentos dos Sistemas de Armazenamento Físico para SBD	2
2.1 A hierarquia de memória	2
2.2 Volatilidade e a exigência de durabilidade	3
2.3 Disco magnético: a mecânica que define os parâmetros clássicos	3
2.4 Memória flash e SSD: por que a escrita é diferente da leitura	4
2.5 Memória de classe de armazenamento: a promessa e o obituário	5
2.6 Mídia óptica e fita: o estrato terciário em 2026	5
2.7 RAID e confiabilidade	6
2.8 Otimizações de acesso a bloco	6
3 A Tabela 16.1 Atualizada para 2026	7
3.1 A tabela original e o que se pede	7
3.2 Tabela 16.1 atualizada — consulta em 05/09/2026	7
3.3 Limitações dos dados comerciais	12
3.4 Justificativa das linhas acrescentadas e removidas	12
3.5 Análise: o que mudou entre 2014 e 2026	12
4 Interfaces de Conexão entre o Dispositivo Físico e o Sistema Computacional	15
4.1 Da taxa anunciada à taxa real	15
4.2 Tabela comparativa das interfaces	15
4.3 Análise por família	19
4.3.1 USB — portabilidade máxima, garantias mínimas	19
4.3.2 SCSI paralelo — a lição de engenharia que originou tudo	20
4.3.3 SATA — e por que parou em 6 Gb/s	20
4.3.4 eSATA e SATA Express — dois fracassos instrutivos	21
4.3.5 PCIe e NVMe — por que o NVMe venceu	21
4.3.6 NVMe over Fabrics, iSCSI e a escolha de <i>fabric</i>	22
4.3.7 SAS — imortal, mas fora da corrida do SSD	23
4.3.8 FireWire — e por que perdeu para o USB	23
4.3.9 HBA — esclarecimento de categoria	23
4.3.10 Fibre Channel, FCIP e FCoE	24

4.3.11	InfiniBand — o <i>fabric</i> da era da IA	24
4.4	Orçamento de latência ponta a ponta	25
5	Implicações para o Gerente de Armazenamento do SBD	26
5.1	O que é o gerente de armazenamento	26
5.2	Tamanho de bloco e de <i>extent</i>	26
5.3	<i>Buffer pool</i> : profundidade de fila é tão importante quanto tamanho	27
5.4	Latência de <i>commit</i> : o parâmetro mais importante de todos	27
5.5	O modelo de custo do otimizador envelheceu	28
5.6	<i>Tiering</i> automatizado de armazenamento	28
5.7	Evidência empírica: local $\times$ rede	29
5.8	Direções emergentes	29
6	Conclusão	30
7	Dúvidas, considerações e pontos para o debate	30
8	Referências	31
9	Post-Mortem — Uso de Assistentes de IA Generativa	34
9.1	Ferramentas utilizadas	34
9.2	Log dos <i>prompts</i> -chave	34
9.3	Demonstração de autoria — quem fez o quê e por quê	35
9.4	Erros gerados pela IA e correções aplicadas	36
9.5	A rodada de verificação adversarial	39
9.6	Um erro que não foi da IA: o livro-texto também erra	40
9.7	Lições aprendidas sobre o uso de IA neste tipo de trabalho	41
Anexo A	Glossário de siglas	42

1 Introdução

1.1 Motivação

Um Sistema de Gerência de Banco de Dados (SGBD) é, em última análise, uma máquina de transformar acessos a disco em respostas a consultas. Todas as estruturas centrais da disciplina — organização de arquivos, *hashing*, índices B⁺-tree, processamento e otimização de consultas, controle de concorrência e recuperação — existem porque o meio de armazenamento persistente é ordens de grandeza mais lento que a memória principal. O modelo de custo do otimizador de consultas conta *blocos lidos*; o gerente de *buffer* existe para evitar releituras; o *log de escrita antecipada* (WAL) existe porque a escrita no meio persistente é cara e precisa ser sequencial.

Ocorre que a razão entre essas velocidades — o parâmetro que justifica toda a arquitetura — **mudou de valor por várias ordens de grandeza** desde que os livros textos da disciplina foram escritos. A Tabela 16.1 de Elmasri & Navathe traz preços de 2014; o Capítulo 12 de Silberschatz traz números de 2018. Em 2026, o disco magnético deixou de ser “o” meio secundário de bancos de dados de produção, a memória persistente que prometia mudar tudo foi descontinuada, e apareceram interfaces que tornaram o barramento irrelevante como gargalo. Este trabalho mede essa distância.

1.2 Objetivos

- O1.** Revisar os fundamentos dos sistemas de armazenamento físico para SBD, articulando o tratamento de Elmasri & Navathe (Cap. 16), Silberschatz *et al.* (Cap. 12) e Garcia-Molina, Ullman & Widom (Cap. 13).
- O2.** Atualizar integralmente a Tabela 16.1, substituindo cada tipo genérico de *storage* por exemplos comercialmente disponíveis em 2026, com faixas de preço correntes, largura de banda segregada em leitura e escrita, e uma coluna adicional de **preço por kilobyte**.
- O3.** Elaborar uma tabela comparativa das interfaces de conexão entre o dispositivo físico e o sistema computacional, contemplando serialidade, latência, taxa máxima de transferência, portabilidade e distância máxima.
- O4.** Traduzir esses números em **parâmetros acionáveis para o Gerente de Armazenamento do SBD**: tamanho de bloco, política de *buffer*, latência de *commit*, modelo de custo do otimizador e estratégia de *tiering*.
- O5.** Registrar, em Post-Mortem auditável, o uso de assistentes de IA generativa: o que foi pedido, o que a IA errou, quem detectou e como foi corrigido.

1.3 Metodologia e critérios de seleção

A pesquisa combinou três fontes. **(a) Fontes textuais primárias:** os capítulos dos livros-texto indicados no enunciado, lidos integralmente para extrair os parâmetros originais e a taxonomia. Os três cumprem papéis distintos e complementares: Elmasri & Navathe detalham as arquiteturas modernas (SAN, NAS, iSCSI, *tiering*, armazenamento por objetos) e fornecem a Tabela 16.1 que este trabalho atualiza; Silberschatz *et al.* detalham a física do *flash*, a *Flash Translation Layer* e as métricas de disco; e Garcia-Molina, Ullman & Widom (Cap. 13) fornecem a formalização do ***I/O model of computation***, que é o elo entre os parâmetros físicos deste estudo e o modelo de custo do otimizador — e que a Seção 5.5 usa para mostrar por que esse modelo envelheceu. **(b) Especificações normativas:** documentos publicados pelos organismos que definem cada interface — USB-IF, SATA-IO, INCITS/T10 (SCSI e SAS), INCITS/T11 (Fibre Channel), NVM Express Inc., PCI-SIG, IEEE, IETF (RFC 7143), IBTA (InfiniBand), CXL Consortium, SNIA e o LTO Program. **(c) Documentação de fabricante:** *datasheets* e manuais de produto,

complementados por preços de referência consultados em 05 de setembro de 2026.

Para a escolha dos dispositivos da Tabela 16.1 atualizada, o grupo adotou três critérios, nesta ordem de precedência:

- C1. Disponibilidade das quatro informações exigidas pelo enunciado** (capacidade, tempo de acesso, largura de banda e preço). Produtos tecnicamente mais interessantes foram preteridos quando o fabricante não publica um dos quatro valores.
- C2. Representatividade de mercado:** preferência por produtos em produção corrente e com preço de varejo público verificável, e não por protótipos ou peças de demonstração.
- C3. Rastreabilidade:** cada célula tem origem declarada — *datasheet* do fabricante, medição de terceiro, derivação aritmética explícita ou estimativa.

Convenção de unidades adotada

Este documento distingue rigorosamente **bit** (b) de **byte** (B): $1\text{ GB/s} = 8\text{ Gb/s}$. Para **dispositivos de armazenamento** adota-se a convenção decimal da indústria ($1\text{ KB} = 10^3\text{ B}$, $1\text{ TB} = 10^{12}\text{ B}$); para **memórias** (SRAM, DRAM) adota-se a convenção binária JEDEC ($1\text{ KB} = 2^{10}\text{ B}$). A coluna “preço por KB” foi calculada dentro da convenção própria de cada categoria, e o resultado é apresentado em notação científica porque a faixa cobre seis ordens de grandeza.

1.4 Estrutura do documento

A Seção 2 revisa os fundamentos. A Seção 3 apresenta a Tabela 16.1 atualizada e a análise do que mudou entre 2014 e 2026. A Seção 4 trata das interfaces de conexão. A Seção 5 converte os achados em parâmetros para o gerente de armazenamento. A Seção 6 conclui, a Seção 7 lista as dúvidas que o grupo deseja levar ao debate, e a Seção 9 traz o Post-Mortem exigido pelo enunciado.

2 Fundamentos dos Sistemas de Armazenamento Físico para SBD

2.1 A hierarquia de memória

Ambos os livros-texto organizam os meios de armazenamento em uma hierarquia ordenada por velocidade e custo. Silberschatz *et al.* (Figura 12.1) elencam, do topo para a base: *cache*, memória principal, memória *flash*, disco magnético, disco óptico e fita magnética. Elmasri & Navathe usam a mesma ordenação, mas nomeiam os três estratos funcionais:

- **Armazenamento primário** — meios diretamente operáveis pela CPU: *cache* SRAM e memória principal DRAM. São **voláteis**.
- **Armazenamento secundário** (ou *online*) — *flash*/SSD e disco magnético. São **não voláteis** e de **acesso direto**: qualquer bloco pode ser lido a qualquer momento.
- **Armazenamento terciário** (ou *offline*) — mídia óptica e fita magnética, tipicamente removível. A fita é de **acesso sequencial**: é preciso percorrer a mídia desde o ponto atual até o dado desejado.

O princípio econômico que sustenta a hierarquia é, nas palavras de Silberschatz, uma tautologia útil: “*se um sistema de armazenamento fosse simultaneamente mais rápido e mais barato que outro, não haveria razão para usar o mais lento e caro*”. Cada nível existe porque ocupa um ponto não dominado na fronteira custo $\times$ velocidade. A Figura 1 mostra que essa fronteira continua existindo em 2026 — mas com um **buraco** entre o nível primário e o secundário que discutiremos na Seção 2.5.




Figura 1: Cada tecnologia da Tabela 16.1 atualizada posicionada por tempo de acesso e preço por kilobyte (ambos em escala logarítmica). A fronteira desce da esquerda superior para a direita inferior: pagar mais compra latência menor. Note o **vazio de cinco ordens de grandeza no eixo horizontal** entre a DRAM ($\sim 10^{-7}$ s) e o SSD NVMe ($\sim 5 \times 10^{-5}$ s) — exatamente a lacuna que o Intel Optane ocupava e que sua descontinuação reabriu.

2.2 Volatilidade e a exigência de durabilidade

A distinção volátil/não volátil não é um detalhe de engenharia: é a fundação da propriedade **D** (*durability*) do ACID. Um **COMMIT** só pode ser reconhecido ao cliente depois que os dados de recuperação alcançaram um meio que sobrevive a uma queda de energia. Toda a arquitetura de *log* de escrita antecipada existe para tornar essa travessia barata: em vez de escrever páginas de dados espalhadas, escreve-se um registro sequencial pequeno em um meio persistente.

A consequência prática é que o parâmetro mais importante de um dispositivo, para um SGBD transacional, não é sua largura de banda, mas a **latência de uma escrita sincronizada pequena** — o custo de um **fsync**. Voltaremos a esse ponto quantitativamente na Seção 5.4.

2.3 Disco magnético: a mecânica que define os parâmetros clássicos

O disco rígido é o único componente eletromecânico no caminho de dados de um computador moderno, e sua física dita os quatro parâmetros que aparecem em todo modelo de custo de SGBD:

- **Tempo de busca** (*seek time*) — deslocamento do braço até a trilha correta. Silberschatz reporta faixa de 2 a 20 ms conforme a distância, com médias atuais entre 4 e 10 ms. O tempo médio de busca é aproximadamente metade do máximo.
- **Latência rotacional** — espera até que o setor desejado passe sob a cabeça. É, em média, meia rotação. Um disco *nearline* de 7.200 rpm gira em 8,33 ms, portanto tem **4,16 ms** de latência rotacional média ($60/7200/2 = 4,17$ ms; a Seagate publica 4,16) — valor que a Seagate publica explicitamente no manual do Exos M.
- **Taxa de transferência** — 50 a 200 MB/s segundo Silberschatz (2018); os discos HAMR

de 2026 chegam a 275–285 MB/s sustentados nas trilhas externas, e significativamente menos nas internas, que têm menos setores por trilha.

- **IOPS** — número de acessos aleatórios por segundo. Com blocos de 4 KB, Silberschatz reporta 50 a 200 IOPS. Esse número praticamente **não melhorou** em duas décadas, porque é governado pela mecânica, não pela densidade de gravação.

O ponto que os livros-texto não enfatizam o bastante

A capacidade do HDD cresceu de 8 TB (Tabela 16.1 original, 2014) para 32–36 TB (2026), um fator de 4×. A taxa sequencial cresceu de 200 para 285 MB/s, um fator de 1,4×. E o IOPS aleatório **ficou constante**. O resultado é que o *tempo para ler o disco inteiro* piorou: varrer 8 TB a 200 MB/s levava 11 horas; varrer 32 TB a 285 MB/s leva 31 horas. Isso tem consequência direta em SBD: janelas de *backup*, tempo de reconstrução de RAID e viabilidade de *full table scan* degradaram, não melhoraram. É a principal razão pela qual RAID 5 clássico deixou de ser recomendado para discos de alta capacidade — a probabilidade de um segundo erro durante uma reconstrução de 31 horas deixou de ser desprezível.

2.4 Memória flash e SSD: por que a escrita é diferente da leitura

A memória *flash* NAND é organizada em **páginas** (tipicamente 4 KB, análogas a setores) agrupadas em **blocos de apagamento** (*erase blocks*) de 256 KB a 1 MB, contendo 128 a 256 páginas. A assimetria fundamental é esta:

- **Ler** uma página: dezenas de microssegundos.
- **Escrever** uma página *previamente apagada*: $\approx 100 \mu\text{s}$.
- **Sobrescrever** uma página: **impossível**. É preciso apagar o bloco inteiro, operação que leva 2 a 5 ms e consome um dos 10^5 a 10^6 ciclos de vida daquele bloco.

Essa impossibilidade explica todo o resto da arquitetura de um SSD. A **Flash Translation Layer (FTL)** mantém um mapeamento dinâmico de páginas lógicas para páginas físicas: ao atualizar uma página lógica, o controlador escreve em uma página física já apagada e marca a antiga como inválida. Periodicamente, um processo de *garbage collection* copia as páginas ainda válidas de um bloco quase vazio para outro lugar e apaga o bloco. O **wear leveling** distribui os apagamentos uniformemente, alocando dados “frios” aos blocos mais desgastados e dados “quentes” aos menos desgastados. Acima da FTL, o SSD apresenta exatamente a mesma interface orientada a blocos de um disco magnético — “*file systems and database storage structures can thus see an identical logical view of the underlying storage structure*” (Silberschatz, §12.4).

Três consequências para o projetista de SBD

- (1) **Amplificação de escrita.** Uma escrita lógica de 4 KB pode custar bem mais que 4 KB de escrita física, porque o *garbage collection* move dados. Índices com muitas atualizações in-place (B^+ -tree clássica) sofrem mais que estruturas *append-only* (LSM-tree). Não é coincidência que os SGBDs projetados na era do SSD (RocksDB, Cassandra, ScyllaDB) usem LSM.
- (2) **Latência de cauda.** O *garbage collection* ocorre de forma assíncrona e imprevisível. A latência mediana de um SSD é excelente; a latência de percentil 99,9 pode ser dez vezes pior. Um SLA de banco de dados quebra na cauda, não na média.
- (3) **Paralelismo interno.** Diferentemente do HDD, o SSD atende **múltiplas requisições simultâneas** — 32 é o valor comumente suportado. Um SSD SATA entrega ≈ 13 mil IOPS a QD=1 e ≈ 98 mil a QD=32. Isso muda o desenho do gerente de *buffer*: emitir uma requisição de cada vez desperdiça o dispositivo.

Os fabricantes expressam o desgaste em **DWPD** (*drive writes per day*, escritas do disco inteiro por dia ao longo da garantia) ou **TBW** (*terabytes written*). Um SSD de datacenter de 0,6 DWPD

e 61,44 TB suporta ≈ 134 PB escritos ao longo de cinco anos. Para um SGBD, esse é um parâmetro de dimensionamento tão real quanto a capacidade: um sistema de *log* intensivo pode esgotar a resistência do dispositivo antes de esgotar seu espaço.

2.5 Memória de classe de armazenamento: a promessa e o obituário

Silberschatz dedica a Nota 12.1 à *storage class memory* (SCM): memórias não voláteis endereçáveis por byte, que evitam a granularidade de página e o custo de apagamento da NAND. O exemplo citado é o **3D XPoint** da Intel/Micron, comercializado como Intel Optane a partir de 2017 em formato SSD e, a partir de 2018, como módulos de memória persistente (PMem) instalados em soquetes DIMM.

Atualização crítica: a categoria foi extinta comercialmente

A Intel anunciou a saída do negócio Optane em **julho de 2022**. A geração 300-series (*Crow Pass*) foi cancelada e nunca chegou ao mercado; os últimos embarques dos módulos PMem 200-series estavam previstos para o **fim de 2025**. Em setembro de 2026 **não existe memória persistente byte-endereçável de propósito geral em produção corrente**. O degrau da hierarquia descrito na Nota 12.1 do livro-texto simplesmente desapareceu, reabrindo um vazio de cerca de três ordens de grandeza entre a DRAM (≈ 70 ns) e o SSD NVMe mais rápido (≈ 20 – 70 μ s).

O substituto parcial é o **CXL** (*Compute Express Link*), que não é uma memória, mas um protocolo coerente sobre a camada física do PCIe. Um módulo CXL Tipo 3 (por exemplo o Samsung CMM-D MD220, de 256 GB em formato E3.S, sobre PCIe Gen5) expõe DRAM adicional ao sistema operacional com semântica de *load/store*.

A latência é o parâmetro decisivo aqui, e é preciso rigor: **a Samsung não publica latência do CMM-D**. O único valor que a empresa divulga no ecossistema CXL é **596 ns**, e refere-se ao CMM-B — a caixa com *switch*, não o módulo. Medições independentes revisadas por pares em expansores CXL 2.0 reais situam a latência ociosa entre **214 e 271 ns**, contra 111–117 ns da DDR5 local no mesmo experimento. Adotamos essa faixa medida: o CXL custa, portanto, cerca de **2 a 2,5× a latência da DRAM local** — e não os ≈ 140 ns que circulam em material promocional. O CXL não substitui a DRAM: é um **nível intermediário de memória**, e é por isso que a especificação CXL 3.2 (dezembro de 2024) introduziu a *Hot-Page Monitoring Unit*, que permite ao SO ou ao SGBD promover páginas quentes para a DRAM local e rebaixar as frias para o CXL. Para um SGBD, mais memória barata significa *buffer pool* maior e, portanto, menos I/O — o que faz do CXL a tecnologia de infraestrutura mais relevante para bancos de dados nesta década.

2.6 Mídia óptica e fita: o estrato terciário em 2026

O tratamento dos livros-texto envelheceu de forma assimétrica nesses dois meios.

Óptico. Ambos os livros descrevem CD, DVD e Blu-ray como meio de arquivamento WORM. Em 2026 a categoria está em colapso comercial: em maio de 2025 a Pioneer encerrou, após 45 anos, a fabricação de **drives ópticos para PC** (o negócio PDDM foi vendido à chinesa Shanxi Lightchain; a linha de *players* Blu-ray de mesa já havia sido descontinuada por volta de 2020), e a Sony encerrou toda a linha *Optical Disc Archive* em 31 de março de 2025. Sobrevive apenas o nicho de arquivamento WORM de longuíssimo prazo, representado pelo M-DISC BD-XL de 100 GB, cuja mídia gravada tem durabilidade declarada de séculos — atributo que nenhum outro meio oferece e que interessa a requisitos legais de retenção.

Fita. Aqui os livros subestimam a vitalidade da tecnologia. Silberschatz cita capacidades de 1 a 12 TB; a Tabela 16.1 original cita 2,5 a 8,5 TB. Em 2026 o padrão corrente é o **LTO-10**, cuja especificação foi liberada para licenciamento em agosto de 2025 com **30 TB nativos**, e

cujo cartucho de **40 TB nativos** entrou no *roadmap* em novembro de 2025, foi anunciado pela Fujifilm em dezembro e começou a ser embarcado em janeiro de 2026 — compatível com os *drives* já instalados, sem troca de hardware, graças a um filme-base de aramida mais fino que permite mais fita no mesmo cartucho. A taxa nativa de 400 MB/s supera a de um disco magnético, e o custo da mídia, em torno de **US\$ 5 a 10 por TB**, é uma ordem de grandeza inferior ao do HDD.

Duas armadilhas do *roadmap* do LTO — e por que caímos na segunda

(1) **A taxa não mudou.** O LTO-10 entrega os mesmos **400 MB/s nativos** do LTO-9. A geração 10 ganhou apenas densidade, não velocidade — o que reforça o argumento da Seção 2.3: densidade e desempenho escalam por mecanismos diferentes.

(2) **O *roadmap* publicado é em capacidade comprimida, e foi revisado para baixo.** O LTO Program divulga a coluna comprimida (razão 2,5:1) com o mesmo destaque da nativa, e em **novembro de 2025** revisou todas as projeções: o LTO-14 passou de 576 TB para **365 TB nativos** — os **≈913 TB** que circulam são $365 \times 2,5$, ou seja, **capacidade comprimida**, não nativa. As demais gerações também caíram: LTO-11 de 72 para 70 TB, LTO-12 de 144 para 120 TB, LTO-13 de 288 para 210 TB. Uma versão anterior deste trabalho apresentava “913 TB nativos no LTO-14”, combinando os dois erros — número comprimido rotulado como nativo, e a partir de um *roadmap* já revogado. O erro está registrado como E13 na Seção 9.4.

Por que a fita não morreu

A fita é o único meio da hierarquia cujo *drive* e cuja *mídia* são precificados separadamente. Isso inverte a economia: um *drive* LTO-10 custa dezenas de milhares de dólares, mas cada terabyte adicional custa US\$ 5–10. Para arquivamento em escala de petabytes, esse modelo domina qualquer alternativa. Somam-se três atributos que nenhum meio *online* oferece: consumo energético nulo quando a mídia está na estante (*cold storage* literal), imunidade a *ransomware* por desconexão física (*air gap*), e retenção declarada de 30 anos. Para o SBD, a fita não é armazenamento: é a última linha de defesa do plano de recuperação de desastres.

2.7 RAID e confiabilidade

Silberschatz dedica a Seção 12.5 ao RAID, cuja motivação é aritmética simples: se o MTTF de um disco é de 100.000 horas, um arranjo de 100 discos tem MTTF agregado de 1.000 horas — cerca de 41 dias. Sem redundância, sistemas de grande porte seriam inoperáveis.

Os níveis relevantes na prática, conforme o próprio livro, são o **RAID 1** (espelhamento — melhor desempenho em escrita, custo de 100% de *overhead*) e o **RAID 5** (paridade distribuída — 1 disco de *overhead*, mas sofre com a penalidade de escrita: atualizar um bloco exige ler o bloco antigo, ler a paridade antiga, calcular e escrever ambos, ou seja, **quatro operações de I/O por escrita lógica**). Para um SGBD com *log* intensivo, essa penalidade recai justamente sobre o caminho crítico, e é a razão pela qual a recomendação clássica separa o *log* (em RAID 1) dos dados (em RAID 5 ou 10).

Com discos de 30 TB, o RAID 5 tornou-se contraindicado, como observado na Seção 2.3: o RAID 6 (dupla paridade) ou esquemas de *erasure coding* distribuídos são hoje o padrão para capacidades altas.

2.8 Otimizações de acesso a bloco

Silberschatz (§12.6) enumera as técnicas que o sistema aplica para reduzir o custo de acesso; todas continuam válidas em 2026, mas com pesos diferentes:

- **Buffering** — manter blocos lidos em memória. *Ganhou* importância: a memória cresceu mais que o custo de acessá-la.

- **Read-ahead** — ler blocos consecutivos antecipadamente. Continua valioso para varreduras sequenciais; irrelevante para acesso aleatório.
- **Escalonamento de braço** (algoritmo do elevador) — *perdeu* sentido em SSD, que não tem braço. Continua relevante em HDD de capacidade.
- **Organização de arquivos em *extents*** — *perdeu* importância relativa em SSD, mas continua reduzindo metadados e fragmentação.
- **Buffers de escrita não voláteis (NVRAM)** — permanece essencial. É o mecanismo que permite a uma controladora confirmar uma escrita antes que ela alcance a mídia, sem violar a durabilidade. Silberschatz alerta corretamente que reordenar escritas *sem* NVRAM pode deixar o banco em estado inconsistente após uma queda.

Uma armadilha de durabilidade que vale para o hardware de 2026

Um adaptador HBA em modo RAID com *cache* de escrita **não** protegido por bateria ou *flash* pode confirmar um `fsync` antes que o dado seja persistido. O SGBD acredita que cumpriu a durabilidade; uma queda de energia prova o contrário. O mesmo vale para muitas pontes USB-SATA, que não implementam corretamente o comando FUA (*Force Unit Access*). Este é o argumento técnico — não meramente de desempenho — para **não** colocar dados de produção atrás de uma interface USB.

3 A Tabela 16.1 Atualizada para 2026

3.1 A tabela original e o que se pede

A Tabela 16.1 de Elmasri & Navathe, ao final da Seção 16.1.1, resume “*Types of Storage with Capacity, Access Time, Max Bandwidth (Transfer Speed), and Commodity Cost*”. Reproduzimos abaixo o original, cujos preços o próprio livro data de **2014**:

Type	Capacity	Access Time	Max Bandwidth	Commodity Prices (2014)
Main Memory — RAM	4 GB–1 TB	30 ns	35 GB/s	US\$100–20 K
Flash Memory — SSD	64 GB–1 TB	50 µs	750 MB/s	US\$50–600
Flash Memory — USB stick	4 GB–512 GB	100 µs	50 MB/s	US\$2–200
Magnetic Disk	400 GB–8 TB	10 ms	200 MB/s	US\$70–500
Optical Storage	50 GB–100 GB	180 ms	72 MB/s	US\$100
Magnetic Tape	2,5 TB–8,5 TB	10–80 s	40–250 MB/s	US\$2,5 K–30 K
Tape jukebox	25 TB–2,1 EB	10–80 s	250 MB/s–1,2 PB/s	US\$3 K–1 M+

O enunciado pede quatro modificações: substituir cada tipo por **exemplos comercialmente disponíveis**, atualizar capacidade e faixa de preço, **segregar a largura de banda em leitura e escrita** quando a informação existir, e acrescentar a coluna de **preço por kilobyte**. Adicionamos, por iniciativa do grupo, uma coluna de *exemplo comercial* explícito e três linhas novas (memória CXL, SSD NVMe de datacenter e LTO-10), justificadas na Seção 3.3.

3.2 Tabela 16.1 atualizada — consulta em 05/09/2026

A Tabela 1 é apresentada a seguir, em orientação paisagem. Ela deve ser lida junto com as notas metodológicas que a seguem, nas quais está registrada a origem de cada número: *datasheet* oficial do fabricante, medição publicada por terceiro, derivação aritmética nossa (com a conta explicitada) ou estimativa de ordem de grandeza. Onde nenhuma das quatro categorias se aplicava, a célula traz “n/d” em vez de um valor inventado.

Três colunas merecem atenção do leitor. A coluna **tempo de acesso** mistura grandezas que diferem por dez ordens de grandeza — de nanossegundos no *cache* a mais de um minuto na fita — e é o eixo que organiza toda a hierarquia. As colunas de **banda de leitura** e **banda de escrita** foram segregadas, conforme pede o enunciado, sempre que a assimetria é conhecida e publicada; para meios genuinamente simétricos (DRAM, disco magnético, fita) os dois valores coincidem, e isso é em si uma informação. A coluna **preço por KB** é a que torna a hierarquia comparável: ela varre seis ordens de grandeza, de $3,0 \times 10^{-3}$ na SRAM a $4,9 \times 10^{-9}$ na fita LTO-9 — uma razão de **607 mil vezes** entre o topo e a base ($199 \div 67.108,864$ contra $87,99 \div 1,8 \times 10^{10}$).

Tabela 1: Tabela 16.1 atualizada. Tipos de armazenamento com capacidade, tempo de acesso, largura de banda segregada em leitura e escrita, preços de referência e preço por kilobyte decimal. Consulta original: 05/09/2026; MSRP é histórico, não cotação atual. Fontes por linha nas notas que seguem a tabela.

Tipo	Exemplo comercial (2026)	Capacidade	Tempo de acesso	Banda máx. leitura	Banda máx. escrita	Preço (US\$)	Preço/KB (US\$)
Cache SRAM (L3)	AMD Ryzen 9 9950X3D2 (3D V-Cache) / EPYC 9755	96 MB–512 MB	$\approx 9,0\text{ ns}^\ddagger$ (L1 0,71; L2 2,50)	$\approx 1,4\text{ TB/s}$ por CCD	$\approx 1,4\text{ TB/s}$	700–14.800 (preço da CPU)	$3,0 \times 10^{-3}$
DRAM (desktop)	Corsair Vengeance DDR5-6000 CL30, kit 2×16 GB	16–96 GB (kit)	70 ns efetivo (CAS 10,0 ns)	96 GB/s (2 canais)	96 GB/s	270–1.100	$1,6 \times 10^{-5}$
DRAM (servidor)	RDIMM DDR5-6400 64 GB (Kingston / A-Tech)	32–256 GB por módulo	$\approx 75\text{ ns}$	51,2 GB/s por módulo (614 GB/s por soquete, 12 canais)	51,2 GB/s	1.000–4.000 por módulo	$4,1 \times 10^{-5}$
Memória CXL 2.0 (Tipo 3) [linha nova]	Samsung CMM-D MD220 (E3.S, PCIe Gen5)	128–256 GB	214–271 ns [†] (2–2,5× a DRAM local)	36 GB/s	36 GB/s	não público (canal OEM)	n/d
SSD NVMe PCIe 5.0 (consumidor)	Samsung 9100 PRO 1 TB (M.2 2280)	1–8 TB (dados: 1 TB)	50 μs (livro)	14,7 GB/s (1,85 M IOPS)	13,3 GB/s (2,60 M IOPS)	199,99 (1 TB, MSRP)	$2,00 \times 10^{-7}$
SSD NVMe data-center QLC [linha nova]	Solidigm D5-P5336 (U.2 / E3.S / E1.L)	7,68–122,88 TB	50 μs (livro)	7,0 GB/s (900 K IOPS)	3,0 GB/s	16.246–33.249 (61,44 TB)	$2,6 \times 10^{-7}$
SSD NVMe data-center TLC [linha nova]	Micron 9550 PRO (E1.S / U.2, PCIe 5.0)	7,68–30,72 TB	50 μs (livro)	14,0 GB/s (3,3 M IOPS)	10,0 GB/s	33.217 (30,72 TB, lista)	$1,1 \times 10^{-6}$
SSD SATA	Samsung 870 EVO (2,5 polegadas)	250 GB–4 TB	77 μs leitura 28 μs escrita	560 MB/s	530 MB/s	345 (1 TB)	$3,4 \times 10^{-7}$
Pen drive USB	Kingston DataTraveler Max (USB 3.2 Gen 2)	256 GB–1 TB	100 μs (livro)	1.000 MB/s	900 MB/s	130 (1 TB)	$1,3 \times 10^{-7}$
Disco magnético HAMR	Seagate Exos M 30 TB (ST30000NM004K)	24–36 TB (44 TB anunciado)	10 ms (livro)	275 MB/s sustentado	275 MB/s	800 (30 TB) — 1.280 (32 TB)	$2,7 \times 10^{-8}$
Óptico WORM	Verbatim M-DISC BD-XL 100 GB + Pioneer BDR-X13U	100 GB por disco	180 ms (livro)	não publicada ($\approx 36\text{ MB/s}$ no leitor, 8×)	$\approx 18\text{ MB/s}$ (4×)	12,70 por disco + 230 (leitor)	$1,3 \times 10^{-7}$
Fita LTO-9	Cartucho LTO-9 Ultrium (HPE / Fujifilm / IBM)	18 TB nativo (45 TB comp.)	25–121 s (carga + locate)	400 MB/s nativo (1.000 comp.)	400 MB/s nativo	88 por cartucho + 4 K–6 K (<i>drive</i>)	$4,9 \times 10^{-9}$
Fita LTO-10 [linha nova]	Cartucho LTO-10 Ultrium (Fujifilm, jan./2026)	30 TB → 40 TB nativo	25–121 s	400 MB/s nativo (1.200 comp., FC)	400 MB/s nativo	260–300 por cartucho + $\approx 24\text{ K}$ (<i>drive</i>)	$9,3 \times 10^{-9}$

Tipo	Exemplo comercial (2026)	Capacidade	Tempo de acesso	Banda máx. leitura	Banda máx. escrita	Preço (US\$)	Preço/KB (US\$)
<i>Tape library</i>	IBM TS4500 (23.170 cartuchos) / Quantum Scalar i6000	até 926,8 PB nativo (2,317 EB a 2,5:1)	25–121 s	≈51,2 GB/s agregado (128 drives)	≈51,2 GB/s	sob cotação (não publicado)	n/d

Notas de rodapé da Tabela 1

- N1. Preço por KB — método.** Usamos 1 KB = 1.000 bytes em todas as linhas. Para memória, convertamos a capacidade binária em bytes antes da divisão. Exemplo: 64 MiB = 67.108,864 KB; $\text{US\$ } 199 / 67.108,864 \text{ KB} = 2,97 \times 10^{-3} \text{ US\$/KB}$. O preço/KB usa a capacidade e o preço pontuais de `dados.py`; não combina os extremos das faixas de modelos.
- N2. O preço da SRAM é um *proxy*, não um preço.** Cache SRAM não é vendida como produto; o valor acima é o *delta* de preço entre duas CPUs comparadas com e sem V-Cache empilhado. Embute margem, custo de empacotamento 3D e segmentação de mercado, e deve ser lido apenas como ordem de grandeza — que é, ainda assim, $\approx 72\times$ o preço por byte da DRAM de servidor nesta base.
- N3. Tempo de acesso do *cache* (‡) — derivação, não especificação.** Nenhum fabricante publica latência de *cache* em nanossegundos; publicam-se ciclos, e mesmo esses de forma incompleta. O único valor primário do Zen 5 é **L1D = 4 ciclos** (AMD, Hot Chips 2024). Para o L3, a AMD divulgou apenas um *delta*: “3,5 ciclos a menos” que o Zen 4, cujo L3 a própria AMD documentou em 50 ciclos — donde os $\approx 46,5$ ciclos que usamos. O L2 de 14 ciclos é número do **Zen 4**: a AMD não republicou o valor para o Zen 5. A conversão para nanossegundos exige declarar o *clock*, o que raramente se faz. Adotamos o *boost* oficial de até 5,6 GHz do 9950X3D2: $4/5,6 = 0,71 \text{ ns}$ (L1), $14/5,6 = 2,50 \text{ ns}$ (L2) e $46,5/5,6 = 8,30 \text{ ns}$ (L3), com +4 ciclos (+0,71 ns) para o V-Cache empilhado, totalizando $\approx 9,02 \text{ ns}$. **Nenhum desses valores é especificação**; todos são derivações declaradas.
- N4. Tempo de acesso de SSD.** Sem valor confirmado para o modelo e a carga, usamos os 50 μs da Tabela 16.1 original, conforme o enunciado. Isso vale para o 9100 PRO, D5-P5336 e Micron 9550 nesta comparação; não é medição desses produtos. Foram retirados os números não confirmados de latência típica e percentil do D5-P5336.
- N5. Tempo de acesso do SSD SATA.** Derivado do inverso dos IOPS a QD=1 publicados no *datasheet* do 870 EVO: $1/13.000 \approx 77 \mu\text{s}$ de leitura e $1/36.000 \approx 28 \mu\text{s}$ de escrita. A escrita é *mais rápida* que a leitura porque é absorvida pelo *cache* SLC (*Turbo Write*).
- N6. Tempos de acesso mantidos do livro.** Sem valor confirmado de acesso total, mantemos HDD: 10 ms; USB: 100 μs ; óptico: 180 ms. A latência rotacional isolada não equivale ao acesso total do HDD.
- N7. Bandas de leitura e escrita da fita** referem-se a *drives* de altura integral (*full-height*). Unidades de meia altura entregam 300 MB/s nativos no LTO-9. As taxas “comprimidas” assumem razão 2,5:1, que é a convenção do LTO Program e **não é atingida** por dados já comprimidos ou cifrados.
- N8. *Tape jukebox*.** Nem a IBM nem a Quantum publicam *throughput* agregado. O valor apresentado é derivação nossa: $128 \text{ drives} \times 400 \text{ MB/s nativos} = 51,2 \text{ GB/s}$, e representa um teto teórico. Do mesmo modo, a capacidade de 926,8 PB é derivada de 23.170 cartuchos $\times 40 \text{ TB}$; a capacidade de 2,317 EB é um cenário a 2,5:1, não uma garantia para dados comprimidos/cifrados. Preços de bibliotecas de fita são exclusivamente sob cotação.
- N9. Divergência entre rastreadores de preço.** Rastreadores automatizados de preço divergem entre si por fatores de até $8\times$ para DRAM de servidor, conforme puxem de *marketplace* ou de distribuidor. Onde havia divergência, adotamos a faixa e não um ponto.
- N10. Os números do 9100 PRO são do modelo de 1 TB**, cuja capacidade e MSRP oficial de lançamento sem dissipador (US\$ 199,99) formam a base de cálculo da coluna de preço/KB. O *datasheet* Rev. 1.0 mostra que a família não é homogênea: o modelo de 4 TB atinge **14.800 MB/s** de leitura e **2.200 KIOPS** aleatórios de leitura, contra 14.700 MB/s e 1.850 KIOPS do 1 TB (a escrita é igual em ambos: 13.300–13.400 MB/s e 2.600 KIOPS). Misturar capacidades numa mesma linha — preço de uma, desempenho de outra — é um erro fácil de cometer e trivial de detectar; por isso a coluna de capacidade indica

explicitamente de qual modelo vêm os números.

- N11. Latência do módulo CXL (†). A Samsung não publica latência do CMM-D.** O único valor que a empresa divulga no ecossistema CXL é 596 ns, e refere-se ao CMM-B (a caixa com *switch*), não ao módulo. A faixa de **214–271 ns** apresentada vem de medições independentes revisadas por pares em expansores CXL 2.0, contra 111–117 ns de DDR5 local no mesmo experimento. Também não é publicada a largura de banda agregada do MD220: os 36 GB/s são estimativa nossa a partir do enlace (CXL 2.0 sobre PCIe 5.0 entrega 32 GB/s por direção em $\times 8$ e 64 GB/s em $\times 16$). Trate ambos os valores como ordem de grandeza, não como especificação.
- N12. Informações não encontradas.** Por transparência acadêmica, registramos o que **não** conseguimos obter em fonte pública: preço de módulos CXL; preço de RDIMM DDR5 de 128 GB (vendido apenas por contrato de longo prazo a hiperescaladores); preço de bibliotecas de fita; latência de pen drive; tempo de acesso de leitor Blu-ray; IOPS e latência do Samsung PM1743.

3.3 Limitações dos dados comerciais

As linhas de CXL (complementar) e biblioteca de fita não têm preço público confirmado; por isso não participam da comparação de custo. A biblioteca foi mantida por corresponder ao *tape jukebox* do livro. Não se deve interpretar “n/d” como custo zero. O MSRP histórico do SSD Samsung não substitui uma cotação atual. As faixas comerciais registradas na consulta original precisam de fonte por modelo para auditoria de preços; os cálculos verificam a aritmética, não comprovam disponibilidade ou validade da oferta.

3.4 Justificativa das linhas acrescentadas e removidas

Acrescentamos a linha de memória CXL 2.0 porque a hierarquia de 2026 tem um degrau que não existia em 2014 e que é o único candidato a ocupar o vazio deixado pelo Optane; sem ela, o salto de 70 ns para 50 μ s ficaria inexplicado. Desdobramos a linha “Flash Memory — SSD” do livro em três, uma de consumidor PCIe 5.0, uma de datacenter QLC de alta capacidade e uma de datacenter TLC de alto desempenho, porque a categoria única esconde uma variação de cerca de duas ordens de grandeza em capacidade, de 1 TB a 122,88 TB, e de mais de $5\times$ em preço por byte, e porque escolher entre QLC de capacidade e TLC de desempenho é uma decisão de projeto para um SBD. Desdobramos também a fita em LTO-9 e LTO-10, já que a transição está em curso: o LTO-10 foi lançado em 2025 com 30 TB e teve o cartucho de 40 TB especificado em novembro de 2025, com embarques a partir de janeiro de 2026.

Duas linhas ficaram de fora. O Intel Optane seria a que faria mais sentido teórico, mas não está comercialmente disponível, o que viola o critério C2, e por isso registramos sua ausência como achado e não como omissão. O Sony Optical Disc Archive saiu pela mesma razão, já que a linha foi encerrada em todas as regiões em 31 de março de 2025.

3.5 Análise: o que mudou entre 2014 e 2026

(a) Evolução de capacidade

Meio	Capacidade 2014		Capacidade 2026	Fator
DRAM (por soquete)	1 TB	4–8 TB (12 canais × RDIMM de 256 GB)		≈4–8×
SSD flash	1 TB		122,88 TB	≈123×
Pen drive USB	512 GB		2 TB	4×
Disco magnético	8 TB		36 TB	4,5×
Fita (cartucho)	8,5 TB		40 TB	4,7×

A coluna de 2014 é o topo de cada faixa da Tabela 16.1 original, que publica “Main Memory-RAM 4GB–1TB”, “Flash Memory-SSD 64 GB–1TB”, “Flash Memory-USB stick 4GB–512GB”, “Magnetic Disk 400 GB–8TB” e “Magnetic Tape 2.5TB–8.5TB” (Elmasri & Navathe, ref. [1]). Comparamos topo com topo, já que comparar a média seria mais fiel mas o livro não publica distribuição.

Os tempos de acesso mantidos do livro não permitem medir uma evolução de latência: capacidade e banda publicadas podem ser comparadas, mas uma conclusão sobre latência exigiria medições equivalentes de carga, fila e percentil, que o livro não traz.

(b) Evolução de largura de banda




Figura 2: Largura de banda de leitura e escrita por tecnologia, em escala logarítmica. O SSD NVMe PCIe 5.0 entrega 20× a banda que a Tabela 16.1 original registra para SSD, ou seja, 750 MB/s contra 14,7GB/s, enquanto o disco magnético avançou 1,4× no mesmo período. Vale notar que a fita LTO ultrapassa o disco magnético em taxa sequencial, resultado contraintuitivo que decorre de a fita não precisar posicionar um braço entre blocos consecutivos.

(c) SSD e HDD divergiram em vez de convergir

Projeções de mercado repetidas na imprensa técnica esperavam que o preço por terabyte de SSD e HDD convergissem por volta de 2026 a 2028, e convém registrar que não fixamos uma dessas

projeções com autor e data, de modo que a expectativa entra aqui como contexto e não como fonte. O que está documentado é o desfecho, e ele foi o contrário: a demanda de IA consumiu a capacidade fabril de NAND, parte dos compradores migrou de SSD de volta para HDD, e isso pressionou também o preço do disco.

Como a razão entre os dois é volátil, ela só faz sentido com data. O *Flash Volatility Index* da VDURA (ref. [29]) acompanha trimestralmente o prêmio do SSD corporativo sobre o HDD *nearline*:

Período	3T25	1T26	2T26	3T26 parcial (05/09)
Razão SSD/HDD por TB	7,0×	23,2× (pico)	16,3×	18,6×

Em agosto de 2026, um SSD TLC corporativo de 30 TB custava cerca de US\$ 22.600, ou US\$ 753/TB, contra cerca de US\$ 1.216 de um HDD de mesma capacidade, ou US\$ 41/TB. Os 18,6× são a observação parcial consultada em 05/09/2026 e não devem ser apresentados como fechamento do terceiro trimestre, enquanto os 16,3× se referem ao trimestre anterior. Quanto à proveniência da tabela, os valores de 18,6×, 23,2× e 7,0× estão na publicação de 11 de agosto de 2026 da VDURA (ref. [29]), mas o de 16,3× vem de divulgação trimestral anterior do mesmo índice, cujo comunicado específico o grupo não chegou a fixar: quem for reapresentar esta tabela deve fechar essa célula antes. Uma versão anterior deste trabalho citava “aproximadamente 16×” sem carimbo de trimestre, erro registrado como E15 na Seção 9.4, e a lição vale além do número, porque num mercado que oscilou de 7× a 23× em quatro trimestres uma razão sem data não informa nada.

(d) Limite da comparação econômica

Preço por capacidade não é custo total de propriedade, e a comparação acima não inclui energia, manutenção, redundância nem infraestrutura de rede; em mídia removível, o preço do cartucho ou do disco ainda é separado do preço do leitor. Por isso não inferimos tendências de mercado a partir de uma consulta pontual.

(e) Síntese

Mudança	Impacto na tabela e no projeto de SBD
Optane / 3D XPoint descontinuado (2022–2025)	Removeu o degrau de memória persistente; reabriu vazio de 3 ordens de grandeza entre DRAM e SSD
CXL preenche parcialmente o vazio	Novo nível de memória a 214–271 ns (2–2,5× a DRAM local); <i>buffer pool</i> pode crescer além dos slots DIMM
Sony ODA encerrado; Pioneer saiu dos leitores ópticos	Óptico virou nicho de arquivamento WORM de longuíssimo prazo
SSD SATA tornou-se legado	Interface satura em 550 MB/s; mantido só por retrofit
PCIe 5.0 é padrão de consumo; PCIe 6.0 chegou ao datacenter	14,8 GB/s (consumo) e 28 GB/s (Micron 9650: anunciado em jul./2025, em produção em massa desde fev./2026)
HAMR entrou em produção	HDD saltou de 24 TB para 32–36 TB
LTO-10 lançado (30 → 40 TB nativos)	Arquivamento a US\$ 5–10/TB; <i>roadmap</i> revisado (nov./2025) até 365 TB nativos no LTO-14
SSD e HDD divergiram em custo	Razão observada de 18,6× por TB em 05/09/2026 (3T26 ainda em curso; era 7× no 3T25)

4 Interfaces de Conexão entre o Dispositivo Físico e o Sistema Computacional

4.1 Da taxa anunciada à taxa real

Antes de qualquer comparação, é preciso fixar a aritmética, porque três fatores sucessivos separam a “velocidade” anunciada de uma interface da taxa de dados que ela efetivamente entrega.

O primeiro é a **unidade**: como 1 GB/s equivale a 8 Gb/s, uma interface de 6 Gb/s nunca entrega 6 GB/s. O próprio Silberschatz comete esse deslize na Seção 12.2 ao escrever que “*the SATA-3 version of SATA nominally supports 6 gigabytes per second*”, quando são 6 gigabits por segundo, como a frase seguinte do livro reconhece ao citar 600 MB/s. Vale notar que a mesma frase usa a unidade correta logo adiante, ao dizer que “*SAS version 3 supports data transfer rates of 12 gigabits per second*”, o que mostra tratar-se de lapso e não de convenção do texto.

O segundo fator é a **codificação de linha**. Todo enlace serial insere bits de controle para manter o balanceamento DC e permitir a recuperação do relógio a partir do próprio fluxo de dados, e a tabela a seguir reúne as codificações usadas pelas interfaces deste estudo.

Codificação	Eficiência	Overhead	Onde é usada
8b/10b	80,00%	25,0%	SATA (todas), SAS-1/2/3, PCIe 1.0/2.0, FC 1–8GFC, IB SDR-QDR, USB 3.0
64b/66b	96,97%	3,1%	FC 10/16GFC, IB FDR/EDR, Ethernet 10G+
128b/130b	98,46%	1,6%	PCIe 3.0 / 4.0 / 5.0
128b/132b	96,97%	3,1%	USB 3.1/3.2 Gen 2, USB4 Gen3
256b/257b	99,61%	0,4%	FC 32/64/128GFC, IB HDR/NDR/XDR (+ RS-FEC)
128b/150b	85,33%	17,2%	SAS-4 (22,5 Gb/s) — inclui FEC embutido
FLIT 242B/256B	94,53%	5,8%	PCIe 6.0 / 7.0 (FLIT mode + RS-FEC + CRC)

Base do overhead: bits acrescentados ÷ bits de carga útil (8b/10b: $2/8 = 25,0\%$; 64b/66b: $2/64 = 3,1\%$; 128b/130b: $2/128 = 1,6\%$; 128b/132b: $4/128 = 3,1\%$; 256b/257b: $1/256 = 0,4\%$; 128b/150b: $22/128 = 17,2\%$; FLIT: $14/242 = 5,8\%$). Sobre o quadro total os percentuais seriam menores — é a mesma armadilha de rótulo da Seção 4.1(1), aplicada a si mesma.

O terceiro fator é a **modulação**. O NRZ transmite 1 bit por símbolo, enquanto o PAM4 transmite 2, dobrando a taxa sem dobrar a frequência de sinalização, ao custo de reduzir a margem de ruído a um terço, o que torna a correção de erro obrigatória. O PAM4 é usado em FC 64/128GFC, InfiniBand HDR/NDR/XDR, PCIe 6.0/7.0 e Ethernet 400G, e o USB4 v2.0 usa PAM3, com três níveis e cerca de 1,58 bit por símbolo.

Aplicando os três fatores, o SATA 3.0 entrega 6,0 Gb/s brutos que, multiplicados por 8/10 da codificação e divididos por 8, dão os 600 MB/s de sua especificação; e o PCIe 5.0 em $\times 4$ entrega 32 GT/s por *lane* que, multiplicados por 4 *lanes* e por 128/130, e divididos por 8, dão 15,754 GB/s.

4.2 Tabela comparativa das interfaces

Tabela 2: Comparativo das interfaces de conexão de armazenamento. Taxas úteis já descontam a codificação de linha. Latências marcadas com (*) são estimativas de ordem de grandeza, sem publicação oficial de organismo normatizador. **Duas convenções de leitura:** (i) na família *Fibre Channel*, a coluna “Ano” é a **disponibilidade de mercado** segundo o *roadmap* da FCIA, não o ano de conclusão da norma — o FC-PI-8 (128GFC) fechou em 2023, mas a produtização é de ≈ 2025 ; (ii) as taxas de FC estão **por direção**, e a FCIA publica também o valor *full-duplex*, que é o dobro — citar “128GFC” sem dizer qual das duas escalas erra por $2\times$.

Interface	Ano	Ser./Par.	Taxa bruta	Taxa útil	Latência típ.	Distância máx.	Hot-plug	Topologia / nº disp.	Uso típico em SBD
Família USB									
USB 1.0 / 1.1	1996/98	Serial	1,5 / 12 Mb/s	0,19 / 1,2 MB/s	$\approx 1\text{ ms}^*$	3–5 m	Sim	Estrela hierárq., 127	Nenhum
USB 2.0 (Hi-Speed)	2000	Serial	480 Mb/s	60 MB/s teor.; 30–42 real	0,2–1 ms*	5 m	Sim	Estrela hierárq., 127	Mídia de instalação
USB 3.0 (3.2 Gen1)	2008	Serial	5 Gb/s (8b/10b)	500 MB/s; ≈ 360 real	100–200 μs^*	3 m	Sim	Estrela hierárq., 127	<i>Dump</i> , exportação
USB 3.1 Gen2 (3.2 Gen2)	2013	Serial	10 Gb/s (128b/132b)	1.212 MB/s	$\approx 100\text{ }\mu\text{s}^*$	1 m passivo	Sim	Estrela hierárq., 127	<i>Backup</i> externo
USB 3.2 Gen 2 $\times$ 2	2017	Serial 2 lanes	20 Gb/s	2.424 MB/s	$\approx 100\text{ }\mu\text{s}^*$	1 m	Sim	Só USB-C	<i>Backup</i> externo
USB4 (Gen3 $\times$ 2)	2019	Serial 2 lanes	20 / 40 Gb/s	2,4 / 4,85 GB/s	50–100 μs^*	0,8 m passivo	Sim	Roteado (<i>tunneling</i>)	SSD externo NVMe
USB4 v2.0	2022	Serial PAM3	80 (120 opcional/assim.) Gb/s	$\approx 9,6$ GB/s nominal	$\approx 50\text{ }\mu\text{s}^*$	conforme cabo certificado	Sim	Roteado	SSD externo NVMe compatível
SCSI paralelo (histórico)									
SCSI-1	1986	Paralela 8 bit	5 MB/s	5 MB/s	ms*	6 m SE / 25 m HVD	Não	Barramento, 8 IDs	Obsoleto
Fast/Wide SCSI-2	1994	Paralela 8/16	10 / 20 MB/s	idem	ms*	3 m	Não	Barramento, 8/16	Obsoleto
Ultra160	1999	Paralela 16	160 MB/s	idem	ms*	12 m LVD	Não	Barramento, 16	Obsoleto
Ultra-320	2002	Paralela 16	320 MB/s	idem	ms*	12 m LVD	Não	Barramento, 16	Obsoleto
Família SATA									
SATA 1.0	2003	Serial	1,5 Gb/s	150 MB/s	100–200 μs (SSD)	1 m	Sim (AHCI)	Ponto-a-ponto; 15 c/ <i>port multiplier</i>	Legado
SATA 2.0	2004	Serial	3,0 Gb/s	300 MB/s	100–200 μs	1 m	Sim (AHCI)	idem	Legado
SATA 3.0–3.5	2009–2020	Serial	6,0 Gb/s	600 MB/s	100–200 μs (SSD); 5–10 ms (HDD)	1 m	Sim (AHCI)	idem	Capacidade, <i>backup</i> , <i>dev</i>
eSATA	2004	Serial	3 / 6 Gb/s	300 / 600 MB/s	idem	2 m	Sim	Ponto-a-ponto	Obsoleto (sem energia no cabo)
eSATAp	≈ 2009	Serial	3 / 6 Gb/s	idem	idem	2 m	Sim	Ponto-a-ponto	Obsoleto
SATA Express	2013	Serial (PCIe $\times 2$)	10 / 16 GT/s	1,0 / 1,97 GB/s	$< 1\text{ }\mu\text{s}$	$\approx 0,3\text{ m}$	Sim	Ponto-a-ponto	Fracassou
Família SAS									
SAS-1 (3G)	2004	Serial	3 Gb/s (8b/10b)	300 MB/s	100–200 μs	10 m	Sim	<i>Fabric c/ expanders</i> , 65.535	Legado
SAS-2 (6G)	2009	Serial	6 Gb/s	600 MB/s	idem	10 m	Sim	idem	HDD corporativo
SAS-3 (12G)	2013	Serial	12 Gb/s	1.200 MB/s	idem	10 m	Sim	idem	HDD corporativo

Interface	Ano	Ser./Par.	Taxa bruta	Taxa útil	Latência típ.	Distância máx.	Hot-plug	Topologia / nº disp.	Uso típico em SBD
SAS-4 (24G)	2019	Serial	22,5 Gb/s (128b/150b)	2.400 MB/s	idem	10 m	Sim	idem	<i>Backplane</i> tri-modo
PCIe e NVMe									
PCIe 3.0 ×4 / ×16	2010	Serial (lanes)	8 GT/s por <i>lane</i>	3,94 / 15,75 GB/s	<1 µs	≈0,3 m (PCB)	Depende	Árvore ponto-a-ponto	SSD de geração anterior
PCIe 4.0 ×4 / ×16	2017	Serial	16 GT/s	7,88 / 31,51 GB/s	<1 µs	≈0,3 m	Depende	idem	SSD de datacenter
PCIe 5.0 ×4 / ×16	2019	Serial	32 GT/s	15,75 / 63,02 GB/s	<1 µs	≈0,25 m	Depende	idem	Padrão atual
PCIe 6.0 ×4 / ×16	2022	Serial PAM4	64 GT/s	30,25 / 121 GB/s	<1 µs (+FEC)	curta	Depende	idem	Fronteira (Micron 9650)
PCIe 7.0 ×4 / ×16	jun./2025	Serial PAM4	128 GT/s	60,5 / 242 GB/s	<1 µs	curta	Depende	idem	Ainda sem produtos
NVMe (local)	2011–2026	Protocolo s/ PCIe	—	= PCIe	20–70 µs	—	Depende	65.535 filas × 65.536 cmds	OLTP, redo log
Fabrics de rede									
NVMe/RoCE v2	2016	<i>Fabric</i> Ethernet	25–400 GbE	≈ Ethernet	41–163 µs (P99,99)	≤ km	Sim	<i>Fabric</i> Ethernet <i>lossless</i>	SAN de baixa latência
FC-NVMe	2017	<i>Fabric</i> FC	32 / 64 GFC	3,2 / 6,4 GB/s	50–100 µs*	10 km SMF	Sim	<i>Fabric</i> FC	SAN corporativa
NVMe/TCP	2018	<i>Fabric</i> IP	10–400 GbE	≈ Ethernet	122–177 µs (P99,99)	roteável; li- mitada por projeto/SLA ilimitada (IP)	Sim	Rede IP roteável	Alternativa moderna ao iSCSI
iSCSI	2004; norma vigente RFC 7143 (2014)	Protocolo s/ IP	1–100 GbE	110 MB/s– 11 GB/s	500–800 µs		Sim	Rede IP	PME, virtualização
FireWire (obsoleto)									
IEEE 1394a (S400)	1995/2000	Serial	400 Mb/s	≈50 MB/s	ciclo iso. 125 µs	4,5 m (72 m c/ rep.)	Sim	Árvore/ <i>daisy</i> , 63	Descontinuado
IEEE 1394b (S800)	2002	Serial (8b/10b)	800 Mb/s	≈100 MB/s	idem	4,5 m cobre / 100 m fibra	Sim	63	Descontinuado
1394-2008 S1600/S3200	2008	Serial	1,57 / 3,15 Gb/s	197 / 393 MB/s	idem	idem	Sim	63	Nunca teve volume
Fibre Channel									
16GFC (Gen 5)	2011	Serial 64b/66b	14,03 GBd	1.600 MB/s por direção	≈700 ns/ <i>switch</i>	100 m OM4 / 10 km	Sim	<i>Fabric</i> comutado, 2 ²⁴	SAN legada
32GFC (Gen 6)	2016	Serial 256b/257b	28,05 GBd	3.200 MB/s por direção	460 ns/ <i>switch</i>	100 m OM4 / 10 km	Sim	idem	SAN corporativa
64GFC (Gen 7)	2020	Serial PAM4	28,9 GBd ×2	6.400 MB/s por direção	460 ns/ <i>switch</i>	100 m OM4 / 10 km	Sim	idem	SAN de alto desempe- nho
128GFC (Gen 8)	≈2025	Serial PAM4	56,1 GBd ×2	12.425 MB/s por direção	idem	100 m OM4/OM5 / 10 km	Sim	idem	Núcleo de SAN
FCIP (RFC 3821)	2004	Túnel FC s/ TCP/IP	= WAN	= WAN	ms (WAN)	inter-sítios	—	Túnel sobre IP	Replicação entre <i>datacenters</i>

Interface	Ano	Ser./Par.	Taxa bruta	Taxa útil	Latência típ.	Distância máx.	Hot-plug	Topologia / nº disp.	Uso típico em SBD
FCoE (FC-BB-5)	2009	FC s/ Ethernet DCB	10–40 GbE	≈ Ethernet	≈ FC + DCB	L2, não roteável	Sim	Ethernet convergente	Nicho/legado em 2026
InfiniBand									
IB EDR 4×	2014	Serial 64b/66b	25,78 Gb/s por <i>lane</i>	100 Gb/s	0,5–1,5 μs	100 m AOC / 10 km	Sim	<i>Fabric</i> comutado	HPC legado
IB HDR 4×	2018	Serial PAM4	50 Gb/s por <i>lane</i>	200 Gb/s	sub-μs	idem	Sim	idem	HPC, IA
IB NDR 4×	2021	Serial PAM4	100 Gb/s por <i>lane</i>	400 Gb/s	sub-μs	idem	Sim	idem	Clusters de IA/LLM
IB XDR 4×	2023	Serial PAM4	200 Gb/s por <i>lane</i>	800 Gb/s	sub-μs	idem	Sim	idem	Clusters de IA/LLM
Fatores de forma para NVMe/PCIe (<i>conector e mecânica, não protocolo</i>)									
M.2 2280	2013	Serial (PCIe ×4)	= PCIe	= PCIe ×4	= NVMe	≈0,1 m (na placa)	Não	1 disp. por soquete	Boot, cliente, <i>cache</i>
U.2 (SFF-8639)	2015	Serial (PCIe ×4)	= PCIe	= PCIe ×4	= NVMe	<i>backplane</i>	Sim	1 disp. por baia de 2,5 pol.	Servidor, gaveta frontal
U.3 (SFF-TA-1001)	2019	Serial (PCIe ×4)	= PCIe	= PCIe ×4	= NVMe	<i>backplane</i>	Sim	Baia tri-modo: SAS, SATA ou NVMe	Servidor convergente
E1.S / E3.S (EDSFF)	2020	Serial (PCIe ×4/×8)	= PCIe	até = PCIe ×8	= NVMe	<i>backplane</i>	Sim	1 disp.; E3.S 2T aceita módulo CXL	Padrão de datacenter
Adaptador de barramento (<i>categoria de hardware, não protocolo — ver Seção 4.3.12</i>)									
HBA SAS/SATA/NVMe tri-modo	—	Placa PCIe	= PCIe 4.0 ×8	24G SAS por porta	= do meio	<i>host</i>	Sim	Ex.: Broadcom eHBA 9600-24i, 24 portas	Modo IT para ZFS, Ceph, réplica por <i>software</i>
HBA Fibre Channel	—	Placa PCIe	= PCIe 4.0 ×8	64GFC por porta	= do <i>fabric</i>	<i>host</i>	Sim	Ex.: Emulex LPe38102, QLogic 2870	SAN corporativa, <i>boot-from-SAN</i>
CNA / HBA iSCSI	—	Placa PCIe	= Ethernet	= Ethernet	= do <i>fabric</i>	<i>host</i>	Sim	NIC + <i>offload</i> numa porta	<i>Offload</i> de iSCSI e NVMe-oF
Complementares									
Thunderbolt 5	2023	Serial (USB4 v2)	80 (120 opcio- nal/assim.) Gb/s	64 Gb/s de PCIe	≈50 μs*	conforme cabo	Sim	<i>Daisy-chain</i> , 6	SSD externo profissio- nal
CXL 3.1 / 3.2	2023/24	Serial (PCIe 6.0)	64 GT/s	≈ PCIe 6.0	100–250 ns*	intra-rack	Sim	<i>Fabric</i> / <i>switch</i>	Expansão de <i>buffer pool</i>

Critérios transversais que não cabem em uma taxa de enlace

Classe	Duplex	Portabilidade	Escalabilidade	Confiabilidade/condição
USB/Thunderbolt	Bidirecional; banda agregada pode ser assimétrica	Alta, se host, cabo e dispositivo negociam o mesmo modo	Árvore/ <i>daisy-chain</i> ; não é <i>fabric</i> de produção	Vazão efetiva e flush/FUA dependem da ponte e do driver
SATA/eSATA	Full-duplex lógico	Interno/curta distância	Ponto a ponto; multiplicadores têm limites	Hot-plug depende de AHCI, backplane, firmware e sistema operacional
SAS	Full-duplex	Datacenter	<i>Expanders</i> , dual-port e muitos dispositivos	Caminhos redundantes e erro fim a fim dependem da implantação
PCIe/NVMe local	Full-duplex por <i>lane</i>	Interno; formato dependente	Árvore PCIe, filas massivamente paralelas	Hot-plug não é universal : requer suporte de plataforma, firmware, slot/backplane e formato
FC/NVMe-oF/iSCSI	Full-duplex	Datacenter/WAN conforme transporte	<i>Fabric</i> com múltiplos caminhos	Alta disponibilidade exige duas <i>fabric</i> s/redes, MPIO e alvos redundantes

Classificação. USB, SATA, SAS, PCIe, FC, Ethernet e InfiniBand definem camadas de interconexão; NVMe, iSCSI, FCP, FCIP e FCoE são protocolos/mapeamentos; M.2, U.2, U.3 e EDSFF são fatores de forma; HBA/CNA são adaptadores. Taxas nominais não devem ser interpretadas como vazão de aplicação.

Como ler as três últimas famílias da Tabela 2

As linhas de fatores de forma (M.2, U.2, U.3 e EDSFF) e de HBA são de natureza distinta das demais e estão na tabela porque constam da lista do enunciado, mas convém marcar que elas são conectores e adaptadores, e não protocolos: um M.2 não tem taxa própria, já que expõe as mesmas *lanes* PCIe da linha correspondente, e é por isso que suas colunas de taxa trazem “= PCIe”. O que distingue essas linhas são as colunas de *hot-plug*, alimentação e mecânica, onde estão as decisões de projeto que importam: o M.2 não suporta *hot-swap* e opera só em 3,3 V, o que limita a dissipação a cerca de 8 a 11 W e o inviabiliza para SSDs PCIe 5.0/6.0 de datacenter, que passam de 25 W, enquanto o EDSFF suporta *hot-swap*, 12 V e até 70 W.

4.3 Análise por família

4.3.1 USB — portabilidade máxima, garantias mínimas

O USB é a interface mais portátil já produzida: *hot-plug* nativo, alimentação pelo cabo (até 240 W com Power Delivery 3.1) e até 127 dispositivos por controlador. Duas observações importam para o estudo.

A nomenclatura é deliberadamente confusa. O USB-IF renomeia retroativamente a cada revisão: o que foi lançado como USB 3.0 (5 Gb/s) passou a chamar-se USB 3.1 Gen 1, depois USB 3.2 Gen 1×1 e, desde 2022, “USB 5Gbps”. **É o mesmo silício com três nomes.** O sufixo Gen N×M significa: N = geração do transceptor (velocidade por *lane*); M = número de *lanes*. Assim, Gen 2×2 = 2 *lanes* × 10 Gb/s = 20 Gb/s.

USB não serve para dados quentes de SBD — e a razão principal *não* é largura de banda. É que muitas pontes USB–SATA não implementam corretamente o comando FUA (*Force Unit Access*) nem o *flush* de *cache*, o que compromete a semântica de barreira de escrita e, portanto, a

durabilidade ACID. O USB é adequado para *backup*, exportação de *dumps* e mídia de instalação.

4.3.2 SCSI paralelo — a lição de engenharia que originou tudo

O SCSI paralelo morreu por uma razão física precisa: o *clock skew*. Em um barramento paralelo, os bits de uma mesma palavra percorrem trilhas de comprimentos ligeiramente diferentes e chegam em instantes diferentes. À medida que a frequência sobe, a janela de amostragem encolhe até desaparecer. O Ultra-640 chegou a ser especificado em 2003, mas **nenhum dispositivo foi produzido** — o cabo teria de encolher para centímetros.

A saída foi **serializar**: um único par diferencial, com o relógio recuperado do próprio fluxo de dados, elimina o *skew* entre bits e permite frequências muito mais altas. Foi assim que nasceram SATA, SAS, PCIe, FC e InfiniBand.

O conjunto de comandos sobreviveu ao barramento

O que morreu foi o *barramento* paralelo, não o *protocolo*. O SCSI Command Set roda hoje sobre SAS, iSCSI, FCP (Fibre Channel Protocol), USB (via UASP) e InfiniBand (via SRP). É um dos casos mais claros de separação bem-sucedida entre camada física e camada de comando — exatamente a separação que o NVMe repetiu ao definir um conjunto de comandos independente do transporte, executável sobre PCIe, RDMA, TCP ou FC.

4.3.3 SATA — e por que parou em 6 Gb/s

O SATA 3.0 é de **2009** e continua sendo a última mudança de velocidade da família: dezessete anos de estagnação deliberada. As revisões 3.1 a 3.5 adicionaram apenas recursos (*DevSleep*, *Power Disable*, *Rebuild Assist*). Quatro causas convergiram:

1. **Custo de engenharia sem retorno.** Dobrar para 12 Gb/s exigiria requalificar conector, cabo, PHY e integridade de sinal de toda a cadeia.
2. **O overhead de 25% do 8b/10b é enorme**, e trocá-lo por 128b/130b quebraria a compatibilidade.
3. **O gargalo real é o AHCI, não o fio.** O AHCI oferece **uma** fila de **32** comandos (NCQ), com registradores MMIO que exigem quatro acessos não cacheáveis por comando. O NVMe oferece **65.535 filas de 65.536 comandos**, uma fila por núcleo, com um único acesso MMIO. Aumentar a banda do SATA sem trocar o AHCI não resolveria nem latência nem IOPS.
4. **O PCIe já existia**, já era mais rápido e já era mais barato por GB/s.

Correção a uma afirmação do enunciado da tarefa: SATA não é NL-SAS

O enunciado afirma que “SATA também é conhecida como NL-SAS”. Esta afirmação é **factualmente incorreta**, e o grupo julga importante registrá-la.

NL-SAS (*Nearline SAS*) designa um disco que combina a **mecânica, a mídia, as cabeças e a rotação de 7.200rpm de um disco SATA corporativo** com a **interface elétrica e o protocolo SAS**. Não é outro nome para SATA: é um terceiro produto, distinto tanto do SATA quanto do SAS corporativo de 10 K/15 K rpm.

A diferença tem consequência prática de projeto. Um disco NL-SAS tem **duas portas** (*dual-port*), permitindo *multipath* ativo/ativo para alta disponibilidade, e aceita o **conjunto completo de comandos SCSI com tagged command queuing**. Um disco SATA tem uma única porta e o conjunto ATA com NCQ de 32 comandos. Em um *backplane* SAS, um disco SATA exige tradução por **STP** (*Serial ATA Tunneling Protocol*) ou uma placa *interposer*, e perde o caminho redundante; um NL-SAS não exige nada disso. Para um SGBD em cluster de alta disponibilidade, essa é exatamente a diferença entre poder e não poder sobreviver à falha de um controlador.

	SATA (HDD)	NL-SAS	SAS corporativo
Interface / protocolo	SATA / ATA	SAS / SCSI	SAS / SCSI
Mídia e rotação	<i>Nearline</i> 7.200 rpm	<i>Nearline</i> 7.200 rpm (a mesma)	10 K / 15 K rpm
Portas	1 (<i>single-port</i>)	2 (<i>dual-port</i>)	2 (<i>dual-port</i>)
<i>Multipath</i> / HA	Não	Sim	Sim
Comandos	ATA + NCQ (32)	SCSI TCQ completo,	SCSI completo
Exige STP/ <i>interposer</i> em <i>backplane</i> SAS	Sim	Não	Não
Taxa de erro irre recuperável (URE)	10^{-14}	10^{-15}	10^{-16}

Ressalva de rigor sobre a nossa própria correção

“NL-SAS” **não é termo normativo do T10**: não aparece nas especificações SAS como categoria definida. É **convenção de indústria**, consolidada por fabricantes e integradores para designar essa combinação de mídia *nearline* com interface SAS. A correção ao enunciado permanece válida — SATA e NL-SAS não são a mesma coisa, e a diferença tem consequência de projeto — mas o grupo a apresenta como uso de mercado, e não como definição de norma. Pela mesma razão, o *dual-port* da terceira linha da tabela está sustentado na documentação de fabricantes de *array* e na literatura de integração, não no material da Dell citado nas referências, que descreve o ganho de desempenho e a rotação de 7.200 rpm mas não menciona a segunda porta.

4.3.4 eSATA e SATA Express — dois fracassos instrutivos

O **eSATA** (2004) oferecia a mesma taxa do SATA interno com 2 m de cabo e conector robusto, sem tradução de protocolo. Foi extinto por um detalhe: **não fornecia alimentação pelo cabo**, exigindo fonte externa mesmo em discos portáteis de 2,5”. O eSATAp tentou corrigir isso combinando pinos de USB e de eSATA, mas nunca foi ratificado e era eletricamente incompatível entre fabricantes. O USB 3.0, com banda equivalente, alimentação embutida e um único conector, encerrou a discussão.

O **SATA Express** (2013) é um caso ainda mais didático. Nasceu obsoleto: o M.2 e o NVMe foram publicados no mesmo ano. Oferecia apenas **×2 lanes** PCIe enquanto M.2 e U.2 ofereciam ×4. Exigia um conector enorme empilhado sobre duas portas SATA legadas, mais cabo de dados largo, mais cabo de alimentação separado — contra um M.2 que se aparafusa direto na placa sem cabo algum. Praticamente nenhum SSD SATAe chegou ao varejo, e as portas desapareceram das placas-mãe.

A lição comum aos dois fracassos

Tanto o eSATA quanto o SATA Express tentaram **preservar compatibilidade legada** — o primeiro mantendo o protocolo SATA fora da caixa, o segundo empilhando o conector SATA — e por isso ficaram piores que as alternativas que romperam com o legado (USB 3.0 e M.2/NVMe). É o mesmo padrão que se observa no SATA 3.0 preso ao AHCI: o custo de compatibilidade acaba maior que o custo de recomeçar.

4.3.5 PCIe e NVMe — por que o NVMe venceu

A vantagem do NVMe sobre o AHCI/SATA é **estrutural, não de banda**:

	AHCI / SATA	NVMe
Filas de submissão	1	65.535
Comandos por fila	32	65.536
Registradores MMIO por comando	4 (não cacheáveis)	1
Afinidade de núcleo	Não	Uma fila por núcleo — sem contenção de <i>lock</i>
Conjunto de comandos	ATA (herdado do disco rotativo)	Enxuto, projetado para <i>flash</i>

Para um SGBD com alta concorrência, o gargalo do AHCI não são os 600 MB/s: é o *lock* na fila única. Cada núcleo que quer emitir I/O disputa a mesma estrutura. O NVMe elimina essa disputa por construção.

Fatores de forma. O M.2 2280 domina o lado cliente, mas **não suporta *hot-swap*** e opera apenas em 3,3 V, o que limita a dissipação a $\approx 8\text{--}11\text{ W}$ — insuficiente para SSDs PCIe 5.0/6.0, que passam de 25 W. O U.2 (SFF-8639) e o U.3 (*backplane* tri-modo, que aceita SAS, SATA ou NVMe na mesma baia) resolveram isso no servidor, e estão sendo substituídos pela família **EDSFF**: E1.S (substitui o M.2 em 1U), E1.L (“régua”, densidade de capacidade), E3.S (sucessor do U.2, $\times 4$ ou $\times 8$) e E3.S 2T (até 70 W, usado para módulos de memória CXL). O EDSFF suporta *hot-swap* e 12 V, e projeta-se dominante no datacenter até 2028.

4.3.6 NVMe over Fabrics, iSCSI e a escolha de *fabric*

O NVMe-oF leva o conjunto de comandos NVMe para fora da máquina. As medições da Western Digital sobre a mesma mídia tornam a comparação limpa — desde que se leia o rótulo certo. As condições são **4 KB aleatório, QD=1, um *job*, 20 minutos**, e os valores publicados são de **percentil 99,99** (“quatro noes”), **não médias**:

Transporte	Escrita (P99,99)	Leitura (P99,99)	Exigência operacional
NVMe/RoCE v2	41,22 μs	162,82 μs	Ethernet <i>lossless</i> (PFC/DCB/ECN) configurada corretamente
NVMe/TCP	122,37 μs	177,15 μs	Qualquer rede IP; nenhuma configuração especial
iSCSI	500–800 μs (típica)		Qualquer rede IP; camada extra de tradução SCSI

O *trade-off* é nítido. O RoCE exige rede sem perdas; se o PFC for mal configurado, produz *congestion spreading* e *head-of-line blocking* — o pesadelo operacional clássico de SAN Ethernet. O NVMe/TCP roda em redes IP convencionais e reduz requisitos operacionais, ao preço de 80–150 μs adicionais neste ensaio e maior consumo de CPU. **Para muitos SBDs que priorizam simplicidade operacional, NVMe/TCP é uma escolha plausível**; RoCE justifica-se quando P99 abaixo de 150 μs for requisito duro.

Por que insistimos no rótulo “P99,99”

Os quatro valores acima são frequentemente citados como “latência do NVMe/TCP” sem qualificação — inclusive por nós, numa versão anterior deste documento (erro E19, Seção 9.4). A distinção importa por dois motivos. **Primeiro**, valores de cauda são tipicamente 2 a 5 vezes maiores que a mediana; comparar um P99,99 de rede com uma latência típica de dispositivo mistura grandezas e infla artificialmente o custo do *fabric*. **Segundo** — e esta é a razão pela qual mantivemos os números mesmo assim — **para um SBD a cauda é o que importa**: é o P99,9 que quebra um SLA, não o P50. Ou seja, o número está certo e é o mais relevante; o que faltava era dizer que número ele é.

O iSCSI permanece consolidado em bases instaladas e ambientes menores; o NVMe/TCP é uma alternativa mais nova e, no ensaio citado, apresentou menor latência sobre a mesma mídia.

4.3.7 SAS — imortal, mas fora da corrida do SSD

O SAS resolveu tudo o que o SCSI paralelo não conseguia: 10 m de cabo (dez vezes o SATA), *fabric* com *expanders* para até **65.535 dispositivos**, endereço WWN de 64 bits, *dual-port* nativo e *hot-plug* pleno. Mas perdeu a corrida do SSD por duas razões admitidas pela própria STA (SCSI Trade Association): o NVMe foi projetado do zero para *flash*, enquanto o SAS foi otimizado para HDD numa era sem SSD; e o NVMe usa **4 lanes PCIe** contra 1–2 *lanes* do SAS.

Status do SAS-5: o projeto existe formalmente no T10 como **BSR INCITS 561, revisão 04 de 11 de maio de 2026**, em fase de *INCITS Approval / Public Review*, com o primeiro período de revisão pública encerrando em **29 de setembro de 2026**. O documento de projeto **não publica taxa de enlace**: os 45 Gb/s que circulam em fóruns e roteiros de marketing não têm respaldo normativo, e este trabalho não os adota. O que de fato avança em produto é o 24G+ (SAS-4.1), que — nas palavras do presidente da STA — “terá a mesma velocidade física de interface do 24G”, ou seja, **não há aumento de velocidade previsto**. O SAS permanece relevante em **HDDs** corporativos e *backplanes* tri-modo; sem uma série de mercado datada, não se afirma participação majoritária.

Registre-se também uma imprecisão de marca: **“24G SAS” opera a 22,5 Gb/s**, não a 24; o número 24 é arredondamento comercial.

4.3.8 FireWire — e por que perdeu para o USB

O IEEE 1394 era tecnicamente superior ao USB da sua época: DMA *peer-to-peer* sem intervenção da CPU do hospedeiro, 8–45 W de alimentação a 24–30 V (contra 2,5 W do USB 2.0), e 100 m sobre fibra no 1394b. Perdeu por três motivos: custo de licenciamento e de silício, a reserva de **80% da banda para tráfego isócrono** (foi projetado para vídeo DV, não para acesso aleatório a blocos), e a própria vantagem do DMA direto, que se revelou uma **vulnerabilidade de segurança** (ataques de DMA sobre a porta FireWire).

Está morto: a Apple descontinuou entre 2011 e 2012, removeu o suporte do macOS em 2025; o Windows não inclui drivers desde o Windows 10.

4.3.9 HBA — esclarecimento de categoria

HBA não é uma interface nem um protocolo

O enunciado lista “HBA” junto com USB, SATA e SAS, mas HBA (*Host Bus Adapter*) é uma **categoria de hardware**, não um padrão de conexão. É a placa (ou o chip integrado à placa-mãe) que liga o barramento do hospedeiro — quase sempre PCIe — a um barramento ou *fabric* de armazenamento (SAS, SATA, Fibre Channel, Ethernet/iSCSI, InfiniBand). Ela contém o controlador, os PHYs, memória e o *firmware* que implementa o protocolo de transporte.

Três distinções importam para um SBD:

- **HBA puro (modo IT, *Initiator Target*) × controladora RAID.** O HBA puro expõe os discos individualmente ao sistema operacional, sem *cache* de escrita nem metadados de RAID — é o que ZFS, Ceph, Storage Spaces e SGBDs com replicação por software exigem. A controladora RAID faz RAID em hardware com *cache* protegido por bateria ou *flash*.
- **HBA × NIC.** Uma placa de rede comum com iniciador iSCSI em software é diferente de um *HBA* iSCSI, que faz *offload* completo em hardware e permite *boot-from-SAN*.

- **CNA** (*Converged Network Adapter*) combina NIC e HBA FCoE/iSCSI em uma única porta Ethernet.

Exemplos correntes: Broadcom eHBA 9600-24i (tri-modo SAS/SATA/NVMe, PCIe 4.0, 24G SAS); Broadcom/Emulex LPe38102 e Marvell/QLogic 2870 (Fibre Channel 64GFC, PCIe 4.0, com FC-NVMe e FCP concorrentes na mesma porta); NVIDIA ConnectX-7/8 e BlueField-3 (InfiniBand e Ethernet com *offload* de NVMe-oF).

4.3.10 Fibre Channel, FCIP e FCoE

O Fibre Channel domina SANs corporativas de missão crítica por uma propriedade que nenhuma rede IP oferece nativamente: é **L2 dedicado com controle de fluxo por *buffer credits*** — crédito por *buffer*, não por janela — ou seja, **sem perdas por construção**. Não há retransmissão, não há colapso por congestionamento, não há TCP. Um *switch* Brocade G720 (Gen 7) entrega **460 ns de latência porta a porta**, sob duas condições que o *product brief* da Broadcom declara e que devem ser citadas junto: **portas comutadas localmente** (*locally switched*) e **já incluindo o FEC**.

Armadilha de leitura das especificações da FCIA

A coluna “throughput” do *speedmap* oficial da FCIA é **full-duplex**, isto é, a soma das duas direções. Um HBA “64GFC” entrega **6.400 MB/s por direção**, e não 12.800 MB/s em uma direção. Adotamos, na Tabela 2, a taxa **por direção**, que é a comparável com as demais interfaces.

FCIP (RFC 3821) tuneliza FC sobre TCP/IP para estender SANs entre *datacenters* — é a forma padrão de fazer replicação de *storage* entre sítios, e continua viva.

FCoE ocupa um nicho legado nas novas implantações. A promessa era convergência (um cabo só), mas exigia DCB fim a fim (PFC, ETS, DCBX), configuração frágil e cara, e não era roteável em L3. Ficou espremido: quem precisava de determinismo continuou no FC nativo; quem queria simplicidade foi para iSCSI e depois NVMe/TCP. Diagnósticos de obituário circulam desde 2015. **Atenção à distinção**: a adoção nova de FCoE é limitada; **Fibre Channel nativo permanece ativo** — a especificação FC-PI-8 (128GFC) foi concluída em 2023 e publicada como INCITS 560-2023, e o **256GFC está em desenvolvimento no T11** (FC-PI-9) — em desenvolvimento, note-se, não publicado.

4.3.11 InfiniBand — o *fabric* da era da IA

O InfiniBand não é uma interface de disco: é o *fabric* que transporta NVMe-oF/RDMA, SRP, iSER e, sobretudo, tráfego MPI/NCCL entre GPUs. Sua latência fim a fim é de **0,5 a 1,5 µs** — uma a duas ordens de grandeza abaixo do TCP/Ethernet convencional. A razão é arquitetural: RDMA nativo com **kernel bypass** e **zero-copy** (a placa lê e escreve diretamente na memória da aplicação, sem chamada de sistema, sem cópia e sem interrupção por pacote), controle de fluxo crédito-a-crédito sem perdas, e roteamento por um *Subnet Manager* centralizado.

A geração corrente é XDR (800 Gb/s em 4×, outubro de 2023), com *switches* NVIDIA Quantum-X800 que executam redução coletiva dentro da rede (SHARP).

Relevância para SBD: o **GPUDirect Storage** estabelece um caminho de DMA direto do SSD NVMe (ou da placa de rede, via NVMe-oF) **para a memória da GPU**, eliminando o *bounce buffer* na memória do hospedeiro. A NVIDIA reporta até **8×** de ganho de banda, **3×** de redução de latência e **3×** de melhora no uso de CPU. É a fundação técnica dos bancos acelerados por GPU (RAPIDS/cuDF, HeavyDB) e dos pipelines de treinamento que leem Parquet direto do armazenamento.

A disputa em aberto: o *Ultra Ethernet Consortium* publicou a Especificação 1.0 em junho de 2025, definindo uma pilha Ethernet para IA/HPC que ataca as duas fraquezas do RoCE clássico — a exigência de *lossless* rígido e a falta de escala em *incast*. Em 2026 a disputa segue indefinida: o InfiniBand domina os maiores clusters NVIDIA; a Ethernet/UEC ganha terreno entre hiperescaladores que priorizam multifornecedor.

4.4 Orçamento de latência ponta a ponta

A tabela abaixo decompõe uma leitura aleatória de 4 KB. É, no entendimento do grupo, a tabela mais útil de todo este trabalho para quem projeta um SBD.

Etapa	NVMe local	NVMe/RoCE	NVMe/TCP	iSCSI 10 GbE	HDD SAS
Chamada de sistema + camada de bloco	2–5 μ s	2–5 μ s	5–10 μ s	10–20 μ s	5 μ s
<i>Driver</i> + submissão na fila	1–2 μ s	2 μ s	5 μ s	20–50 μ s	10 μ s
Travessia do barramento/<i>fabric</i>	<1 μ s	5–15 μ s	50–120 μ s	200–400 μ s	5 μ s
Latência da mídia	20–70 μs	20–70 μ s	20–70 μ s	20–70 μ s	$\approx$ 4 ms
Controladora do alvo / RAID	—	10–30 μ s	10–30 μ s	30–80 μ s	50 μ s
TOTAL	20–70 μs^a	41–163 μs^b	122–177 μs^b	500–800 μs^a	5–10 ms^a

^a latência típica. ^b percentil 99,99 medido pela Western Digital (4 KB, QD=1); a mediana correspondente é menor. As duas colunas de *fabric* são, portanto, **conservadoras** em relação às demais — o que reforça, e não enfraquece, a conclusão (2) abaixo.

Três conclusões

- (1) Em NVMe local, cerca de 90% da latência é mídia, não protocolo.** O barramento PCIe custa menos de 1 μ s dentro de um orçamento de 20–70 μ s. Segue-se que **migrar de PCIe 5.0 para 6.0 não reduz a latência de leitura aleatória** — aumenta banda sequencial e IOPS agregados. Quem quiser cortar latência precisa trocar a *mídia*, não o barramento. E a mídia que faria isso (SCM/Optane) saiu do mercado.
- (2) Em *storage* de rede, o protocolo passa a dominar.** O NVMe/TCP acrescenta 100–150 μ s à *mesma* mídia; o iSCSI acrescenta 400–700 μ s. Aqui, trocar de protocolo tem efeito de primeira ordem.
- (3) A cauda importa mais que a média.** *Garbage collection* do SSD, replicação e reconstrução criam picos que a média esconde. Um SLA de banco de dados quebra no P99,9, não no P50. É nesse ponto que *fabrics* sem perdas (FC, InfiniBand, RoCE bem configurado) vencem o TCP: variância muito menor.




Figura 3: Evolução da taxa útil máxima das principais famílias de interface, em escala logarítmica. A linha horizontal do SATA a partir de 2009 é a estagnação discutida na Seção 4.3.3; o PCIe é a única família cuja inclinação se manteve constante por duas décadas — o que explica por que todas as demais interfaces de armazenamento acabaram construídas sobre ele. **Atenção ao eixo:** aqui o ano é o de publicação da especificação; na Tabela 2 o ano da família *Fibre Channel* é o de disponibilidade de mercado. As duas bases diferem em até três anos e não devem ser lidas uma contra a outra.

5 Implicações para o Gerente de Armazenamento do SBD

5.1 O que é o gerente de armazenamento

Na arquitetura de um SGBD, o *gerente de armazenamento* (*storage manager*) é o módulo que media entre as estruturas lógicas — relações, tuplas, índices — e o meio físico. Suas responsabilidades incluem a alocação de espaço em arquivos e *extents*, o mapeamento de páginas lógicas para blocos físicos, a gerência do *buffer pool*, a emissão e o escalonamento de operações de I/O, e a garantia das propriedades de durabilidade exigidas pelo gerente de transações.

Toda decisão desse módulo é parametrizada por características do dispositivo. Esta seção converte os números das Seções 3 e 4 em parâmetros acionáveis.

5.2 Tamanho de bloco e de *extent*

Silberschatz reporta blocos de 4 a 16 KB; a página NAND é tipicamente 4 KB e o bloco de apagamento, 256 KB a 1 MB. Isso produz recomendações distintas por meio:

Meio	Bloco recomendado	Justificativa
HDD	8–64 KB	O custo é dominado pela busca ($\approx 12,7$ ms); uma vez paga, ler mais é quase de graça (285 MB/s $\Rightarrow$ 64 KB custa 0,22 ms). Blocos maiores amortizam a busca.
SSD NVMe	4–16 KB	Alinhar à página NAND de 4 KB evita leitura-modificação-escrita. Blocos maiores desperdiçam banda em acesso aleatório, já que não há busca a amortizar.
Fita / arquivamento	≥ 1 MB	Meio sequencial; o custo é de posicionamento (25–121 s). Só faz sentido operar em unidades muito grandes.

O conceito de *extent* — conjunto de blocos consecutivos alocados de uma vez — continua útil em SSD, mas por outra razão: não mais para evitar buscas, e sim para reduzir metadados, melhorar a localidade da FTL e permitir que o *garbage collection* libere blocos de apagamento inteiros.

5.3 Buffer pool: profundidade de fila é tão importante quanto tamanho

O gerente de *buffer* foi projetado em uma era em que o dispositivo atendia **uma** requisição por vez. Um SSD moderno atende **32 ou mais** em paralelo, e a diferença é dramática: um SSD SATA entrega ≈ 13 mil IOPS a QD=1 e ≈ 98 mil a QD=32; um SSD NVMe passa de 350 mil leituras aleatórias de 4 KB por segundo.

Consequência de projeto

Um gerente de *buffer* que emite uma falta de página por vez e bloqueia esperando usa, na melhor das hipóteses, **3% da capacidade** de um SSD NVMe. Extrair o desempenho do dispositivo exige **I/O assíncrono com múltiplas requisições em voo** — *prefetch* agressivo em varreduras, leitura antecipada de nós de índice, I/O paralelo por *worker*. É exatamente por isso que SGBDs modernos adotaram `io_uring` no Linux e que o PostgreSQL introduziu *I/O assíncrono* em suas versões recentes. O parâmetro `effective_io_concurrency` do PostgreSQL existe literalmente para informar ao planejador quantas requisições paralelas o dispositivo suporta.

5.4 Latência de *commit*: o parâmetro mais importante de todos

Um COMMIT exige um `fsync` do registro de *log*. Trata-se de um I/O **síncrono e pequeno (8–16 KB)**. Isolando apenas uma escrita e sem *group commit*, *cache* protegido, paralelismo, FUA ou tempo de CPU, obtém-se o limite ilustrativo 1/latência do `fsync`; ele **não** é o throughput previsto do banco.

Meio do <i>log</i>	Latência de escrita síncrona	Teto teórico de <i>commits/s</i> por <i>thread</i>
HDD 7.200 rpm (sem NVRAM)	≈ 8 ms	≈ 125
SSD SATA	≈ 150 μ s	≈ 6.700
SSD NVMe local	≈ 30 μ s	≈ 33.000
NVMe/TCP (remoto)	≈ 122 μ s	≈ 8.200
iSCSI 10 GbE	≈ 600 μ s	≈ 1.700
SCM / Optane (hipotético)	≈ 10 μ s	≈ 100.000

Duas leituras deste quadro. Primeira: **nenhum aumento de largura de banda do SATA resolveria isso** — o problema é latência, não vazão, e foi exatamente o que o NVMe atacou e o AHCI não podia atacar. Segunda: a linha do SCM mostra o que *teria sido possível* e que a

descontinuação do Optane retirou da mesa; é a razão pela qual o desaparecimento dessa categoria (Seção 2.5) é o achado mais consequente deste trabalho para bancos de dados transacionais.

A mitigação clássica — *group commit*, que agrupa vários `COMMITs` em um único `fsync` — continua sendo o mecanismo que separa um SGBD que usa o dispositivo de um que o desperdiça.

5.5 O modelo de custo do otimizador envelheceu

O modelo de custo clássico conta **blocos lidos**. Garcia-Molina, Ullman & Widom formalizam essa prática no Capítulo 13 sob o nome de *I/O model of computation*, cuja premissa é enunciada de forma explícita: *o tempo de uma operação sobre disco é dominado pelo número de acessos a bloco, e o custo de CPU pode ser desprezado*. Toda a análise de algoritmos de junção, ordenação externa e varredura da disciplina repousa sobre essa premissa.

O ponto que este trabalho quer levantar é que **a premissa tinha uma justificativa quantitativa, e essa justificativa mudou**. Ela valia porque um acesso a bloco em disco magnético custava ≈ 10 ms enquanto uma instrução de CPU custava ≈ 1 ns — sete ordens de grandeza. Com um SSD NVMe a ≈ 50 μ s e CPUs de vários gigahertz, a distância caiu para cerca de **quatro ordens de grandeza**, e em cargas com muitas requisições em paralelo o custo de CPU do próprio caminho de I/O (chamada de sistema, cópia de *buffer*, tratamento de interrupção — as duas primeiras linhas da tabela de orçamento da Seção 4.4) deixou de ser desprezível: em NVMe local ele responde por 5 a 10 μ s dos 20–70 μ s totais. O modelo de I/O não se tornou falso; tornou-se **menos dominante**, e o erro que ele induz deixou de ser irrelevante.

O modelo clássico também distingue acesso sequencial de aleatório com uma razão da ordem de **1:100** em HDD — o que justifica a regra prática de que uma varredura completa (*full table scan*) vence o uso de índice quando a seletividade é pior que ≈ 5 –10%.

Em SSD NVMe, essa razão cai para algo entre **1:1** e **1:3**. A consequência direta é que o **ponto de equilíbrio entre varredura e índice se desloca substancialmente**: o índice passa a valer a pena para seletividades muito piores do que a regra clássica sugere.

Onde isso aparece na prática

O PostgreSQL expõe esse modelo em dois parâmetros: `seq_page_cost` (padrão 1,0) e `random_page_cost` (padrão 4,0). O valor 4,0 codifica a premissa de disco magnético. A recomendação corrente para armazenamento SSD é reduzir `random_page_cost` para **1,1–1,5**. Não fazê-lo faz o planejador preferir varreduras sequenciais que o hardware não mais favorece — um caso didático de modelo de custo desatualizado gerando plano subótimo. É o exemplo mais concreto que o grupo encontrou de como os números das Seções 3 e 4 se traduzem em uma linha de arquivo de configuração.

5.6 Tiering automatizado de armazenamento

Elmasri & Navathe (§16.11.4) descrevem o *automated storage tiering* (AST): mover dados automaticamente entre tipos de armazenamento conforme a frequência de acesso. Com os números de 2026, a tabela de *tiers* recomendada para um SBD fica assim:

<i>Tier</i>	Meio	Interface	Conteúdo típico
0 — memória	DRAM + CXL	DDR5 / CXL 2.0	<i>Buffer pool</i> , tabelas de <i>hash</i> , catálogos
1 — quente	SSD NVMe TLC (E3.S)	PCIe 5.0 ×4	Redo log, <i>tempdb</i> , índices, tabelas OLTP
2 — morno	SSD NVMe QLC alta capac.	PCIe 4.0 ×4	Partições históricas, tabelas de leitura intensiva
3 — frio	HDD <i>nearline</i> 30 TB	SATA 6 Gb/s ou NL-SAS 12G	<i>Data lake</i> , partições antigas, imagens de <i>backup</i>
4 — arquivo	Fita LTO-10	SAS 12G / FC 32G	Retenção legal, <i>air gap</i> contra <i>ransomware</i>

A razão de preço por byte entre o *tier* 1 e o *tier* 4 é da ordem de **20 a 40 vezes**, e entre o *tier* 0 e o *tier* 4, de mais de **3.000 vezes**. É essa razão — e não a diferença de desempenho — que sustenta economicamente a existência do *tiering*.

5.7 Evidência empírica: local × rede

Duas medições públicas ilustram o efeito prático das escolhas acima em PostgreSQL:

- **Azure AKS com NVMe local:** uma instância de 8 vCPU com NVMe local entrega ≈400.000 IOPS; obter os mesmos IOPS com disco de rede (*Ultra Disk*) exigiria uma VM de **112 vCPU** — 14× mais vCPUs para o mesmo IOPS.
- **TPC-C comparando NVMe local, Amazon Aurora e RDS sobre EBS gp3:** 873, 636 e 188 transações por segundo, com latências de 314 ms, 601 ms e 2.406 ms respectivamente. O armazenamento local entrega **4,6×** mais consultas por segundo que o RDS e latência **7,7×** melhor.

A diferença não vem principalmente de banda: vem de **latência multiplicada por concorrência**. Um SGBD faz muitos I/Os pequenos e sincronizados; nesse regime é o produto latência × paralelismo que determina o *throughput*, não os MB/s.

5.8 Direções emergentes

- **ZNS (Zoned Namespaces, NVMe 2.0):** expõe as zonas do *flash* ao *software*, que passa a escrever sequencialmente dentro de cada zona. Elimina o *garbage collection* do dispositivo e a amplificação de escrita — casa naturalmente com LSM-trees.
- **KV-SSD (Key-Value, NVMe 2.0):** o dispositivo expõe uma interface chave-valor em vez de blocos, eliminando uma camada de tradução.
- **Computational storage:** empurra predicados de filtragem para dentro do dispositivo, reduzindo o volume transferido — o velho princípio de “levar a computação até os dados” aplicado ao SSD.
- **CXL como tier de buffer pool:** *buffer pools* de vários terabytes sem os limites de *slots* DIMM, com promoção e rebaixamento de páginas guiados pela *Hot-Page Monitoring Unit* do CXL 3.2.
- **GPUDirect Storage:** caminho direto SSD → GPU para bancos e *pipelines* analíticos acelerados.
- **NVMe 2.4** (julho de 2026): criptografia pós-quântica e migração nativa de SSD local (*PCIe-exported NVM Subsystem*), que traz virtualização ao armazenamento diretamente conectado.

6 Conclusão

O estudo confirma a estrutura geral descrita pelos livros-texto — a hierarquia de armazenamento continua existindo, e continua governada pelo mesmo princípio econômico — mas mostra que **os valores dos parâmetros mudaram o suficiente para invalidar várias conclusões práticas** derivadas deles.

Primeiro, a memória persistente byte-endereçável, apresentada como tendência em ambos os livros, **deixou de existir comercialmente**. O Optane foi descontinuado entre 2022 e 2025 e nada o substituiu integralmente. O vazio de três ordens de grandeza entre DRAM e SSD é hoje preenchido, apenas parcialmente e apenas do lado da memória, pelo CXL — que, medido, fica em 214–271 ns e cobre menos desse vão do que o material promocional sugere. Para bancos de dados transacionais, isso significa que o teto de *commits* por segundo por *thread* de *log* continua sendo determinado pela latência do NVMe.

Segundo, SSD e HDD **divergiram em custo por terabyte** em vez de convergir: a razão saiu de $7\times$ no 3º trimestre de 2025 para $23\times$ no 1º de 2026; a observação em 05/09/2026 era **$18,6\times$** , ainda sem representar o fechamento do 3º trimestre. A premissa de que o SSD tornaria o *tiering* desnecessário não se realizou; ao contrário, o *tiering* ficou mais importante.

Terceiro, e mais relevante para a disciplina, **latência, vazão e profundidade de fila precisam ser analisadas em conjunto**. O orçamento de latência da Seção 4.4 mostra que, em NVMe local, cerca de 90% do tempo de uma leitura aleatória é mídia e apenas menos de 1 μ s é barramento. Isso explica de uma só vez três fatos aparentemente independentes: por que o SATA parou em 6 Gb/s sem consequências, por que o NVMe venceu apesar de não ser mais rápido *por lane* que o SAS, e por que migrar de PCIe 5.0 para 6.0 não melhora a latência de um SGBD transacional. O que governa o desempenho de um SBD é **latência multiplicada por profundidade de fila**.

Quarto, a fita magnética — tratada nos livros como tecnologia residual — mostrou-se a categoria com **maior vitalidade de roadmap** de toda a hierarquia, com o LTO-10 a 40 TB nativos e *roadmap* publicado até **365 TB nativos** no LTO-14, a US\$ 5–10 por terabyte de mídia. Para retenção legal e defesa contra *ransomware*, não há substituto. Vale a ressalva, porém, que o próprio *roadmap* foi revisado para baixo em novembro de 2025 — vitalidade não é o mesmo que previsibilidade.

Finalmente, o exercício de atualizar a Tabela 16.1 revelou um problema metodológico que merece registro: **fabricantes publicam cada vez menos parâmetros de latência**. A Seagate removeu o tempo de busca do manual do Exos M; nenhum fabricante de SSD de consumo publica latência; a Samsung não publica IOPS do PM1743. Um trabalho equivalente feito em 2014 teria mais dados disponíveis do que um feito em 2026 — o que é, em si, um achado.

7 Dúvidas, considerações e pontos para o debate

O grupo registra abaixo as questões que considera em aberto e que gostaria de levar ao debate em sala.

- Q1.** O modelo de custo do otimizador deveria ser calibrado automaticamente? Se o `random_page_cost` precisa mudar de 4,0 para 1,1 conforme o meio, por que o SGBD não mede a razão empiricamente na inicialização, em vez de depender de um administrador que talvez nem saiba que o parâmetro existe?
- Q2.** Faz sentido continuar ensinando o modelo de I/O baseado em contagem de blocos, ou o modelo correto para o hardware de 2026 seria baseado em latência $\times$ paralelismo, contabilizando a profundidade de fila explicitamente?
- Q3.** A descontinuação do Optane foi uma falha de mercado ou de tecnologia? O 3D XPo-

int funcionava e ocupava um degrau real da hierarquia, de modo que, se a razão foi custo de fabricação, fica a pergunta sobre o que impede que a mesma lacuna se abra indefinidamente.

- Q4. O CXL substituirá o *buffer pool* ou o *tier* de SSD? Se a memória barata escalar via CXL, bancos “in-memory” de dezenas de terabytes ficam viáveis, e cabe perguntar o que mudaria no projeto de um SGBD que hoje assume que os dados não cabem na memória.
- Q5. Em que ponto a latência de cauda deveria entrar no modelo formal? Toda a literatura de otimização usa custo esperado, isto é, média, enquanto os SLAs reais são escritos em P99 e P99,9. Existe formalismo de otimização de consultas que otimize percentil em vez de média?
- Q6. Armazenamento em nuvem é aceitável para o *tier* 1? Silberschatz observa que a nuvem tem latência de dezenas a centenas de milissegundos quando os dados não são colocados, e os dados de TPC-C que reunimos confirmam degradação de $4,6\times$, o que deixa em aberto se o limite é físico ou de arquitetura.
- Q7. O enunciado da tarefa continha um erro factual, ao afirmar que “SATA também é conhecida como NL-SAS”, afirmação que vem do próprio Elmasri & Navathe (§16.2.1). O grupo optou por documentar a correção em vez de reproduzi-la, e fica a pergunta sobre se essa foi a conduta correta em um trabalho avaliativo.

8 Referências

Livros-texto

- [1] ELMASRI, R.; NAVATHE, S. B. *Sistemas de Banco de Dados*. 7. ed. São Paulo: Pearson, 2018. Capítulo 16 — *Disk Storage, Basic File Structures, Hashing, and Modern Storage Architectures*. (Seções 16.1, 16.2, 16.3, 16.10 e 16.11; Tabela 16.1.)
- [2] SILBERSCHATZ, A.; KORTH, H. F.; SUDARSHAN, S. *Sistemas de Banco de Dados*. 7. ed. Rio de Janeiro: Gen/LTC, 2020. Capítulo 12 — *Physical Storage Systems*. (Seções 12.1 a 12.7; Figura 12.1; Nota 12.1.)
- [3] GARCIA-MOLINA, H.; ULLMAN, J. D.; WIDOM, J. *Database Systems: The Complete Book*. 2. ed. Pearson, 2008. Capítulo 13 — *Secondary Storage Management*.

Especificações e organismos normatizadores

- [4] PCI-SIG. *PCI Express Base Specification 7.0* (128,0 GT/s), publicada em 11/jun./2025. <https://pcisig.com>
- [5] NVM EXPRESS INC. *NVM Express Base Specification*, revisões 1.0 (2011) a 2.4 (2026). <https://nvmexpress.org/specification/nvm-express-base-specification/>
- [6] NVM EXPRESS INC. *NVMe over Fabrics 1.0* (2016) e *1.1* (2019).
- [7] SATA-IO. *Serial ATA Specification Revision 3.5* (2020). <https://sata-io.org>
- [8] INCITS/T10. *Serial Attached SCSI-4 (SAS-4)* e item de trabalho SAS-5. <https://www.t10.org>
- [9] INCITS/T11 e FCIA. *Fibre Channel Roadmap; FC-P1-8 (128GFC)*, 2023. <https://fibrechannel.org>
- [10] IBTA. *InfiniBand Architecture Specification*; anúncio XDR, out./2023. <https://infinibandta.org>
- [11] IETF. *RFC 7143 — Internet Small Computer System Interface (iSCSI) Protocol (Consolidated)*, abr./2014. <https://www.rfc-editor.org/rfc/rfc7143.html>
- [12] USB-IF. *USB4 Version 2.0 Specification* (80 Gb/s; modo assimétrico opcional). <https://www.usb.org/usb4>. Consulta: 05/09/2026.
- [13] CXL CONSORTIUM. *Compute Express Link 3.1* (nov./2023) e *3.2* (dez./2024).
- [14] SNIA. *EDSFF Form Factors (SFF-TA-1006/1007/1008)*; *What is NVMe-oF*. <https://www.snia.org>
- [15] ULTRA ETHERNET CONSORTIUM. *UEC Specification 1.0*, jun./2025.

- [16] LTO PROGRAM. *LTO-9 Technical Brief; LTO Program Announces New 40 TB LTO-10 Cartridge Specifications and Refreshes its Roadmap*, 12/nov./2025 (40 TB nativos, até 100 TB a 2,5:1; embarques no 1º trimestre de 2026; *roadmap* revisado com pico de 913 TB comprimidos na Geração 14 — os 365 TB nativos citados na Seção 3.4 são a derivação $913 \div 2,5$). <https://www.lto.org/2025/11/lto-program-announces-new-40-tb-lto-10-cartridge-specifications-and-refreshes-its-roadmap-for-ultra-high-density-ai-ready-archival-storage/>

Documentação de fabricante

- [17] AMD. *Ryzen 9 9950X3D2 Dual Edition — Specifications*. <https://www.amd.com/en/products/processors/desktops/ryzen/9000-series/amd-ryzen-9-9950x3d2-dual-edition.html>. Consulta: 05/09/2026.
- [18] SEAGATE. *Exos M SATA Product Manual, 32/30/28/24 TB*, Rev. D, ago./2025, que sustenta os pontos de 24 a 32 TB. O ponto de 36 TB não consta desse manual e vem de fonte separada: SEAGATE. *Seagate Introduces Hard Drive Capacities of Up to 36TB, Extending Its HAMR-Based Mozaic 3+ Technology Platform*, 20/jan./2025. <https://investors.seagate.com/news/news-details/2025/Seagate-Introduces-Hard-Drive-Capacities-of-Up-to-36TB-Extending-Its-HAMR-Based-Mozaic-3-Technology-Platform/default.aspx>
- [19] SOLIDIGM. *D5-P5336 Product Specification* (até 122,88 TB).
- [20] MICRON. *9550 PRO NVMe SSD; 9650 Series* (primeiro SSD PCIe 6.0 em produção, fev./2026).
- [21] SAMSUNG. *SSD 870 EVO Data Sheet*, Rev. 1.1 (https://download.semiconductor.samsung.com/resources/data-sheet/Samsung_SSD_870_EVO_Data_Sheet_Rev1.1_230509_10129500053000.pdf); *9100 PRO*, ficha Rev. 1.0 (https://download.semiconductor.samsung.com/resources/data-sheet/Samsung_NVMe_SSD_9100_PRO_Datasheet_Rev.1.0_10149294091048.pdf) e anúncio de MSRP (<https://news.samsung.com/us/samsung-announces-9100-pro-series-ssds-with-breakthrough-pcie-5-0-performance/>); *CMM-D MD220*. Consulta: 05/09/2026.
- [22] KIOXIA. *CM9-R Product Brief* (PCIe 5.0, NVMe 2.0).
- [23] WESTERN DIGITAL. *NVMe-oF Network Storage Protocol: NVMe/TCP vs. RDMA with RoCEv2* (OpenFlex Data24). Condições declaradas no documento: aleatório, bloco de 4 K, 1 job, QD1, 20 min, “measured at the 4 nines (0.9999)”. Valores: RoCE escrita 41,22 µs, RoCE leitura 162,82 µs, TCP escrita 122,37 µs, TCP leitura 177,15 µs. https://documents.westerndigital.com/content/dam/doc-library/en_us/assets/public/western-digital/collateral/white-paper/white-paper-open-flex-data24-roce-vs-tcp.pdf
- [24] BROADCOM. *Brocade G720 Switch Product Brief*, que registra literalmente “*Latency for locally switched ports is 460 ns (including FEC)*”. O valor vale para portas comutadas localmente, e não para um caminho porta a porta arbitrário, que ainda soma a travessia de ISL. [https://docs.broadcom.com/doc/G720-Switch-PB_eHBA_9600-24i; Emulex LPe38102](https://docs.broadcom.com/doc/G720-Switch-PB_eHBA_9600-24i_Emulex_LPe38102_64GFC) (64GFC).
- [25] MARVELL. *QLogic 2870 Series 64GFC Fibre Channel HBA*.
- [26] NVIDIA. *Magnum IO GPUDirect Storage; Quantum InfiniBand Switches; DGX SuperPOD InfiniBand Overview*.
- [27] IBM. *TS4500 Tape Library*. <https://www.ibm.com/docs/en/ts4500-tape-library/1.12.2?topic=overview-introduction-ts4500-tape-library>. QUANTUM. *Scalar i6000*. SPECTRA LOGIC. *TFinity ExaScale*.
- [28] VERBATIM. *M-DISC BDXL 100 GB*. PIONEER. *BDR-X13U-S*.

Mercado e medições de terceiros

- [28] TRENDFORCE. Relatórios de preço de contrato de DRAM e NAND, 1T26 a 3T26. <https://www.trendforce.com/price>. Consultados como série de mercado; não reproduzimos valores pontuais deste provedor no corpo do texto.
- [29] VDURA. *Flash Volatility Index* — “SSD Prices Settle Into a Costly New Normal at ~6.5x Year-Ago Levels”, 11/ago./2026. Fonte primária dos valores de 18,6×, 23,2× (pico do 1T26), 7,0× (3T25) e dos preços de US\$ 22.600 (SSD TLC 30 TB) e US\$ 1.216 (HDD 30 TB) usados na Seção 3.5(c). <https://www.vdura.com/2026/08/11/ssd-prices-settle-into-a-costly-new-normal-at-6-5-x-year-ago-levels-reshaping-the-economics-of-ai-factories-vdura-flash-volatility-i>

- [ndex-shows/](#). Consulta: 05/09/2026.
- [30] MICROSOFT AZURE. *PostgreSQL on AKS with local NVMe*, blog de engenharia, jul./2025. <https://techcommunity.microsoft.com/category/azure/blog/adforpostgresql>
 - [31] UBICLOUD. *PostgreSQL performance: local vs. network-attached storage* (TPC-C e TPC-H comparando NVMe local, Amazon Aurora e RDS). <https://www.ubicloud.com/blog>. É medição de fornecedor sobre a própria plataforma, e a degradação de $4,6\times$ citada na Seção 7 deve ser lida com essa origem em vista.
 - [32] SCSI TRADE ASSOCIATION (STA) / SNIA. *SAS Technology Roadmap* e declarações sobre 24G+ e SAS-5. <https://www.snia.org/forums/sfa>
 - [33] Medição de latência de expansores CXL 2.0 (214–271 ns contra 111–117 ns de DDR5 local, nota † da Tabela 1). Os valores vêm de medição independente revisada por pares, mas este trabalho não fixou a referência exata, e por isso os 214–271 ns devem ser lidos como ordem de grandeza, e não como dado com proveniência fechada.

9 Post-Mortem — Uso de Assistentes de IA Generativa

Esta seção atende ao item do enunciado que exige (i) o log dos *prompts*-chave, (ii) a demonstração de autoria dos participantes e (iii) o registro dos erros gerados pela IA e das correções aplicadas. O grupo entende o Post-Mortem não como formalidade burocrática, mas como a parte do trabalho que documenta **o que foi verificado e como** — distinguindo dados de fonte, estimativas e lacunas. Na revisão editorial solicitada por Raphael em 08/09/2026, a IA padronizou KB, corrigiu o MSRP, retirou latências não confirmadas e enxugou slides. Esse registro não representa nova confirmação humana das fontes comerciais.

9.1 Ferramentas utilizadas

Ferramenta	Uso	Limitação observada
Assistente de IA generativa com busca web	Levantamento de <i>datasheets</i> , especificações normativas e preços; primeira redação de seções expositivas	Divergência entre fontes de preço; tendência a apresentar estimativas com a mesma confiança que dados de <i>datasheet</i>
Extração de texto de PDF (<i>pdftotext</i>)	Leitura integral do Cap. 16 (Elmasri) e do Cap. 12 (Silberschatz)	Nenhuma relevante
Python / Matplotlib	Cálculo do preço por KB e geração das Figuras 1–3	Nenhuma; cálculos verificados manualmente por amostragem
L ^A T _E X	Diagramação do documento	Nenhuma
Segunda instância de IA, em modo adversarial	Verificação das 29 afirmações verificáveis do documento contra fonte primária (Seção 9.5)	Exige instrução explícita de não confirmar por plausibilidade; sem isso, tende a validar o que soa razoável

9.2 Log dos *prompts*-chave

Reproduzimos abaixo os *prompts* que efetivamente determinaram o conteúdo do trabalho, na ordem em que foram usados. *Prompts* de refinamento estilístico foram omitidos por não afetarem o conteúdo técnico.

P1. Extração da base textual. “*Leia os capítulos anexos (Elmasri cap. 16 e Silberschatz cap. 12). Extraia a Tabela 16.1 original na íntegra, com todas as colunas e valores, e os parâmetros de desempenho de disco e de flash discutidos no texto.*”

Papel: garantir que a atualização partisse do original exato, e não de uma reconstrução de memória do modelo.

P2. Levantamento de dispositivos. “*Para cada categoria da Tabela 16.1 (cache, DRAM, SCM, SSD NVMe consumidor e datacenter, SSD SATA, pen drive, HDD, óptico, fita, tape library), encontre 1–2 produtos comerciais específicos com marca e modelo e reporte capacidade, tempo de acesso, largura de banda de leitura e de escrita separadas, e preço atual, com URL da fonte. Marque claramente o que vem de *datasheet* oficial, o que é medição de terceiro e o que é estimativa. Não invente; se não encontrar, diga que não encontrou.*”

Papel: o comando explícito de marcar a origem de cada número e de declarar lacunas foi a decisão metodológica mais importante do trabalho. Sem ele, estimativas e *datasheets* viriam misturados e indistinguíveis.

P3. Levantamento de interfaces. “*Para USB (1 a 4), SCSI, SATA (1–3), eSATA, SATA Express, NVMe/PCIe, M.2, U.2, SAS (1–4), iSCSI, FireWire, HBA, FC (incluindo FCIP e FCoE) e InfiniBand, reporte ano da especificação, serial ou paralela, taxa bruta e taxa útil, latência típica, distância máxima, portabilidade, topologia e número máximo de dispositivos,*

com fontes normativas. Distinga rigorosamente Gb/s de GB/s e cite a codificação de linha que explica a diferença.”

Papel: exigir a *codificação de linha* forçou a distinção entre taxa bruta e útil em toda a tabela, que é onde a maioria dos comparativos publicados na web erra.

- P4. Verificação dirigida de uma afirmação do enunciado.** *“O enunciado afirma que ‘SATA também é conhecida como NL-SAS’. Verifique se isso é correto e reporte a correção com fontes.”*

Papel: o grupo suspeitou da afirmação ao estudar a Seção 16.11 de Elmasri e decidiu testá-la explicitamente. Resultado na Seção 4.3.3 deste documento.

- P5. Verificação da anomalia de preços.** *“Há relatos de alta de preço de memória em 2025–2026 por demanda de IA. Verifique se procede e quantifique com fontes de mercado.”*

Papel: evitou que o grupo apresentasse preços de um pico anômalo como se fossem tendência estrutural.

- P6. Solicitação de lacunas.** *“Liste explicitamente o que você NÃO conseguiu encontrar em fonte pública.”*

Papel: produziu a Nota N10 da Tabela 1. Considerar as lacunas como resultado, e não como falha, foi decisão do grupo.

- P7. Verificação adversarial da versão final.** *“Você é um verificador de fatos adversarial. Verifique cada afirmação abaixo com busca web e classifique como CONFIRMADO (com fonte), IMPRECISO (explique o que está errado e qual o valor correto), NÃO VERIFICÁVEL ou FALSO. Seja implacável: o objetivo é encontrar erros ANTES que um professor os encontre. Não confirme nada por plausibilidade — só com fonte. Se não achar fonte, diga NÃO VERIFICÁVEL, o que já é um achado. Ao final, ordene por gravidade o que um professor rigoroso poderia usar para derrubar o trabalho.”*

Papel: este foi o *prompt* mais produtivo de todo o trabalho em razão erros-encontrados por esforço. Produziu os achados E13 a E17 e a Seção 9.5. As duas cláusulas que o fazem funcionar são “não confirme por plausibilidade” e “ordene por gravidade”: a primeira impede a validação complacente, a segunda obriga o verificador a assumir a perspectiva do avaliador.

9.3 Demonstração de autoria — quem fez o quê e por quê

Integrante		Responsabilidade	Decisões tomadas e justificativa
Bernardo Pozzato Costa	Brandão Carvalho	Coordenação; Seções 1 e 6; revisão final	Decidiu adotar faixas de preço em vez de valores pontuais, por causa da divergência entre rastreadores; decidiu incluir o aviso metodológico sobre a crise de preços de 2026.
Enzo de Sampaio	Carvalho	Seção 2 (fundamentos); leitura dos capítulos-base	Decidiu articular os dois livros-texto em vez de seguir um só, por Elmasri detalhar as arquiteturas modernas (SAN/NAS/iSCSI) e Silberschatz detalhar a física do <i>flash</i> e a FTL.
Gabriel Schmitz Corrêa Rizawinsk		Seção 3 (Tabela 16.1 atualizada); cálculo de preço por KB	Decidiu usar convenção binária para memórias e decimal para armazenamento, seguindo a prática de cada indústria, e documentar a escolha; decidiu acrescentar as três linhas novas (CXL, SSD de datacenter, LTO-10) e justificá-las.
Vivian Silva	Maria da Souza	Seção 4 (interfaces); verificação normativa	Decidiu adotar taxa por direção para Fibre Channel, contra a convenção <i>full-duplex</i> da FCIA, para manter comparabilidade com as demais interfaces; detectou e documentou a correção sobre NL-SAS.
Raphael Henrique da Silva Pereira		Seção 5 (gerente de armazenamento); coordenação da consolidação do Post-Mortem em 06/09/2026, com conferência executada pelo Codex	Decidiu ancorar a discussão em parâmetros verificáveis de SGBD real (<code>random_page_cost</code> , <code>effective_io_concurrency</code>) e separar os problemas da versão auditada das pendências que ainda existem nos artefatos atuais.
Guilherme Hu	En Shih	Rodada de verificação adversarial; execução do verificador e revisão final dos artefatos	Decidiu manter uma segunda rodada independente para encontrar contradições internas e só fechar a entrega depois que as contas e os termos-chave coincidissem entre relatório e slides.

Nota de honestidade acadêmica: a redação inicial de várias seções expositivas foi produzida pelo assistente de IA a partir dos *prompts* listados em 9.2. O trabalho dos integrantes consistiu em definir o escopo, decidir a estrutura, verificar cada número contra a fonte primária, corrigir os erros documentados em 9.4 e escrever as análises interpretativas — que são as partes onde este documento diverge do que a IA produziu espontaneamente.

Consolidação do Post-Mortem coordenada por Raphael — 06/09/2026

A pedido de Raphael Henrique da Silva Pereira, o Codex confrontou o plano de correções da versão anterior com `dados.py`, `relatorio.tex`, os artefatos atuais e o verificador. Os ajustes quantitativos já incorporados foram mantidos como histórico de revisão; a identificação e a confirmação dos demais integrantes continuam pendentes e não foram inferidas.

9.4 Erros gerados pela IA e correções aplicadas

Tabela 3: Registro de erros e correções.

#	Erro gerado	Correção aplicada	Deteção
E1	Apresentou o preço da SRAM derivado do <i>delta</i> de V-Cache como se fosse preço de mercado da tecnologia.	Reclassificado como <i>proxy</i> com margem embutida; acrescentada a Nota N2 explicando o método e sua limitação.	Gabriel Schmitz, ao tentar reproduzir a conta.

#	Erro gerado	Correção aplicada	Deteção
E2	Misturou convenção binária e decimal ao converter US\$/MB em US\$/GB para a SRAM, gerando divergência de $\approx 5\%$ entre valores reportados.	Fixada a convenção por categoria (binária para memórias, decimal para armazenamento) e documentada no texto; todos os valores recalculados em <i>script</i> único.	Gabriel Schmitz, ao verificar 199/64 MiB.
E3	Sugeriu manter o Intel Optane como linha da tabela, por ser a tecnologia citada no livro-texto.	Linha removida: o critério C2 exige disponibilidade comercial, e o Optane foi descontinuado. A ausência foi transformada em achado (Seção 2.5) em vez de omissão.	Bernardo Brandão.
E4	Reportou capacidade do LTO-10 de forma inconsistente entre trechos: 36 TB (<i>roadmap</i> antigo), 30 TB (lançamento) e 40 TB (cartucho de 2026).	Reconstruída a cronologia completa: 36 TB era meta de <i>roadmap</i> nunca cumprida; 30 TB foi o lançamento de 2025; 40 TB é a especificação de nov./2025, embarcada em jan./2026 e compatível com os <i>drives</i> existentes. Adotados 30 e 40 TB, com a transição explicada.	Gabriel Schmitz.
E5	Reportou 64GFC como “12.800 MB/s” sem qualificar.	Identificado que a FCIA publica <i>throughput full-duplex</i> . Adotada a taxa por direção (6.400 MB/s) em toda a Tabela 2, para manter comparabilidade, com nota explicativa.	Vivian Maria.
E6	Referiu-se a SAS-4 como “24 Gb/s”.	Corrigido para 22,5 Gb/s ; “24G” é marca comercial, não taxa. Taxa útil recalculada com 128b/150b: 2.400 MB/s.	Vivian Maria.
E7	Ecoou a afirmação do enunciado de que “SATA também é conhecida como NL-SAS”.	Verificação dirigida (<i>prompt</i> P4) mostrou que NL-SAS é mecânica SATA <i>nearline</i> com interface e protocolo SAS. Erro documentado em destaque na Seção 4.3.3, com tabela comparativa e consequência prática (<i>dual-port</i> , STP, <i>interposer</i>).	Vivian Maria, por suspeita levantada na leitura de Elmasri §16.11.
E8	Apresentou tempo de busca do Seagate Exos M como se fosse dado de <i>datasheet</i> .	Verificação no manual oficial mostrou que a Seagate removeu o <i>seek time</i> da documentação. O valor foi remarcado como estimativa da classe e somado à latência rotacional publicada (4,16 ms), com a Nota N6 registrando o procedimento.	Gabriel Schmitz.
E9	Reportou mediana de preço de DRAM de servidor de US\$ 37,31/GB e, em outro trecho, US\$ 4,47/GB, sem sinalizar a contradição.	Identificado que os dois valores vêm de rastreadores com metodologias distintas. Adotada faixa , com registro explícito da divergência na Nota N9.	Bernardo Brandão.
E10	Apresentou <i>throughput</i> agregado de biblioteca de fita como especificação de fabricante.	Verificação mostrou que nem IBM nem Quantum publicam esse número. Reclassificado como derivação nossa (128 <i>drives</i> $\times$ 400 MB/s) e marcado como teto teórico (Nota N8).	Guilherme En Shih.

#	Erro gerado	Correção aplicada	Deteção
E11	Na primeira versão da tabela de dispositivos, repetiu o mesmo valor nas colunas de leitura e escrita para todos os meios, sem verificar se a assimetria era conhecida.	Segregação efetiva onde a informação existe (SSD: 14,7 contra 13,3 GB/s; SSD SATA: 560 contra 530 MB/s; Solidigm: 7,0 contra 3,0 GB/s — assimetria de 2,3× típica de QLC). Para meios genuinamente simétricos (DRAM, fita, HDD), mantido o mesmo valor com nota.	Gabriel Schmitz.
E12	Tendeu a apresentar estimativas de latência de SSD de consumo com a mesma confiança de dados publicados.	Introduzido o sistema de marcação de origem em toda a tabela e a Nota N4, que recomenda explicitamente usar os valores <i>enterprise</i> (publicados) em vez dos de consumo (estimados) para citação acadêmica.	Enzo de Carvalho.
<i>Erros abaixo detectados na rodada de verificação adversarial descrita na Seção 9.5.</i>			
E13	Afirmou que o <i>roadmap</i> do LTO Program vai até 913 TB nativos no LTO-14.	Duplamente errado. Os 913 TB são capacidade comprimada ($365 \times 2,5$); a nativa é 365 TB . E o número vinha do <i>roadmap</i> antigo, revisado para baixo em novembro de 2025 (LTO-11 de 72 para 70 TB, LTO-12 de 144 para 120, LTO-13 de 288 para 210, LTO-14 de 576 para 365). Corrigido em três pontos do documento e em três slides.	Verificação adversarial (Seção 9.5); confirmado por Gabriel Schmitz contra o <i>roadmap</i> oficial.
E14	Atribuiu ao módulo Samsung CMM-D uma latência de ≈ 140 ns.	Sem fonte, e implausível. A Samsung não publica latência do CMM-D; o único valor que divulga é 596 ns, e é do CMM-B. Medições revisadas por pares em expansores CXL 2.0 dão 214–271 ns , contra 111–117 ns de DDR5 local. Adotada a faixa medida e criada a Nota N11.	Verificação adversarial (Seção 9.5).
E15	Apresentou a razão de preço SSD/HDD como “ $\approx 16\times$ em 2026”, sem trimestre.	A razão é volátil: $7,0\times$ no 3T25, $23,2\times$ no 1T26, $16,3\times$ no 2T26 e $18,6\times$ na consulta de 05/09/2026 — dentro do trimestre ainda corrente. Acrescentada a tabela por período e o carimbo de data em todas as ocorrências.	Verificação adversarial (Seção 9.5).
E16	Datou a alta do HDD como “46–50% em seis meses” e a do NAND como “ $5\times$ entre agosto de 2025 e janeiro de 2026”.	As janelas estavam erradas e enfraqueciam dados que são mais fortes do que o relatório: o HDD subiu 46% em quatro meses (15/09/2025 a 14/01/2026, doze modelos) e o NAND <i>spot</i> multiplicou-se por 5 a partir de outubro de 2025 , chegando a $8,5\times$ em março de 2026.	Verificação adversarial (Seção 9.5).
E17	O resumo afirmava “trinta e nove variantes” de interface.	A Tabela 2 tinha 49 linhas — e passou a 56 com a inclusão dos fatores de forma e dos HBA (Seção 9.6). Contagem corrigida: um corretor que confira o número contra a tabela encontra a inconsistência em segundos.	Verificação adversarial (Seção 9.5).

#	Erro gerado	Correção aplicada	Deteção
E18	Confundiu latência típica e QoS do D5-P5336.	A revisão editorial retirou os valores não confirmados. Adotados 50 μ s da Tabela 16.1 original, explicitamente como referência do livro, não dado do produto.	Revisão assistida por IA; sem nova atribuição de confirmação humana.
E19	Rotulou como “medido” e como “TOTAL observado” os números de latência da Western Digital.	São de percentil 99,99 , não médias. Rótulo corrigido na Tabela 2, na Seção 4.3.6 e na tabela de orçamento de latência, com nota explicando que isso torna as colunas de <i>fabric</i> conservadoras — o que reforça a conclusão que delas se extrai.	Verificação adversarial (Seção 9.5).
E20	Misturou números de capacidades diferentes do Samsung 9100 PRO numa mesma linha (preço do 1 TB, desempenho tratado como sendo da família).	Fixado o modelo de 1 TB em toda a linha, com nota registrando que o 4 TB atinge 14.800 MB/s e 2.200 KIOPS. Também corrigidas as taxas do M-DISC ($4\times \approx 18$ MB/s de gravação; leitura não publicada pelo fabricante).	Verificação adversarial (Seção 9.5).
E21	Tratou “46,5 ciclos” de L3 do Zen 5 e “14 ciclos” de L2 como dados publicados, e converteu para nanossegundos sem declarar o <i>clock</i> .	A AMD publica apenas L1D = 4 ciclos e um <i>delta</i> de $-3,5$ ciclos no L3 sobre o Zen 4; os 46,5 são derivação , e os 14 ciclos de L2 são do Zen 4 . Nota N3 reescrita com a derivação completa e o <i>clock</i> de 5,7 GHz explicitado.	Verificação adversarial (Seção 9.5).

9.5 A rodada de verificação adversarial

Concluída a primeira versão completa do documento, o grupo decidiu submetê-la a uma **segunda passagem de IA operando em modo adversarial** — isto é, com a instrução explícita de *tentar derrubar* o trabalho em vez de melhorá-lo. A motivação foi metodológica: a primeira IA foi a autora do texto e, portanto, a menos indicada para auditá-lo; e sabe-se que a correção deste trabalho contará com apoio de IA, de modo que antecipar essa leitura é parte razoável do preparo.

Protocolo adotado

Extraímos do documento uma lista de **29 afirmações verificáveis** — existência e especificações de produto, datas de cronologia, números de mercado e taxas de interface — e submetemos cada uma a um verificador com acesso a busca web, sob quatro instruções:

- V1.** Classificar cada afirmação como **CONFIRMADA** (com URL), **IMPRECISA** (com o valor correto), **NÃO VERIFICÁVEL** (nenhuma fonte pública encontrada) ou **FALSA**.
- V2.** Não confirmar nada por plausibilidade — apenas com fonte primária.
- V3.** Tratar “não encontrei fonte” como **achado**, não como falha.
- V4.** Ordenar os achados por **gravidade**, na perspectiva de um avaliador rigoroso.

A instrução V2 é a que faz o protocolo funcionar. Sem ela, um verificador tende a “confirmar” o que soa razoável — que é exatamente o mecanismo que produziu os erros da primeira rodada.

Resultado

Veredito	Qtd.	Exemplos
Confirmada com fonte	15	Existência do Ryzen 9 9950X3D2 (192 MB de L3); remoção do <i>seek time</i> do manual do Exos M; datas do Optane; PCIe 7.0 em 11/jun./2025; 460 ns do Brocade G720; PAM3 a 25,6 GBd do USB4 v2.0
Imprecisa	9	Roadmap do LTO; janelas de preço; razão SSD/HDD sem data; latência do Solidigm como QoS; ciclos de <i>cache</i> do Zen 5
Não verificável	4	Latência do CMM-D; taxa do SAS-5; velocidade de leitura do M-DISC; banda agregada do MD220
Falsa	1	“913 TB nativos no LTO-14”

Nove achados geraram correção e estão registrados como **E13 a E21** na tabela da Seção 9.4: cinco de conteúdo (E13–E17) e quatro de **rótulo** (E18–E21) — casos em que o número estava certo mas descrevia outra coisa (QoS confundido com latência típica, percentil confundido com média, capacidades misturadas, derivação apresentada como especificação). Esta segunda categoria é a mais insidiosa: nenhum desses valores falharia uma busca simples, porque todos existem — apenas não significam o que o texto dizia.

O que a rodada adversarial ensinou

- A1. A IA autora não audita a si mesma.** Todos os cinco erros graves sobreviveram à revisão da própria IA que escreveu o texto, e caíram na primeira passagem de um verificador instruído a atacá-lo. Autoria e auditoria precisam ser papéis separados — o que vale para IA tanto quanto para pessoas.
- A2. O erro mais grave foi de autoinconsistência, não de pesquisa.** O trabalho usa a distinção entre capacidade nativa e comprimida como *argumento metodológico* (Nota N7 critica a convenção 2,5:1 do LTO Program) e, três seções adiante, cai exatamente nela (E13). Erros assim são invisíveis para quem lê linearmente e óbvios para quem cruza seções — que é o que um corretor por IA faz.
- A3. “Não verificável” é informação valiosa.** Quatro afirmações não têm fonte pública. Descobrir isso mudou a redação de três delas: passaram de afirmação a estimativa declarada. O caso do CMM-D (E14) é o mais instrutivo, porque o número sem fonte era o que sustentava a tese central do trabalho.
- A4. Corrigir um erro pode fortalecer o argumento.** Com a latência correta do CXL (214–271 ns em vez de 140 ns), o vão deixado pelo Optane fica *maior*, não menor — e a tese da Seção 2.5 sai reforçada. Verificar não é só defensivo.
- A5. Número sem data não é dado.** A razão SSD/HDD variou de 7× a 23× em quatro trimestres (E15). Em mercados voláteis, a data faz parte do valor.

9.6 Um erro que não foi da IA: o livro-texto também erra

Durante a verificação, o grupo encontrou uma imprecisão no próprio Silberschatz (§12.2), que afirma: “*The SATA-3 version of SATA nominally supports 6 gigabytes per second*”. São 6 **gigabits** por segundo. O próprio texto se corrige implicitamente na frase seguinte, ao citar 600 MB/s. Registramos o achado não para diminuir a obra, mas porque ilustra o ponto metodológico central deste Post-Mortem: **a verificação contra fonte primária é necessária independentemente de quem produziu o texto** — IA, livro-texto ou o próprio grupo.

9.7 Lições aprendidas sobre o uso de IA neste tipo de trabalho

- L1. Exigir a origem de cada número muda a qualidade do resultado.** O *prompt* que pedia marcação explícita entre *datasheet*, medição e estimativa (P2) foi o que tornou o trabalho auditável. Sem ele, os quatro tipos de dado chegariam indistinguíveis.
- L2. Pedir explicitamente as lacunas é tão importante quanto pedir os dados.** Um assistente tende a preencher; instruí-lo a declarar o que *não* encontrou (P6) produziu a lista de dez informações indisponíveis da Nota N10, que é informação genuína sobre o estado do mercado.
- L3. A IA reproduz premissas erradas contidas no próprio pedido.** O erro E7 só apareceu porque o grupo desconfiou do enunciado e formulou uma pergunta de verificação. A IA não questionou espontaneamente a premissa dada.
- L4. Contradições internas são frequentes em respostas longas.** Os erros E4 e E9 são casos em que o mesmo relatório trazia dois valores incompatíveis em trechos diferentes. A leitura integral e cruzada foi o que os revelou.
- L5. O trabalho interpretativo permaneceu humano.** Nenhuma das conclusões estruturais da Seção 6 — a divergência SSD/HDD, o vazio deixado pelo Optane, a primazia da latência sobre a banda — veio pronta do assistente. Todas resultaram de comparar tabelas produzidas separadamente e perceber o padrão.
- L6. Uma segunda IA, instruída a atacar, encontra o que a primeira não vê.** Os cinco erros mais graves do trabalho (E13–E17) sobreviveram à revisão da IA que escreveu o texto e caíram na primeira passagem do verificador adversarial. O custo foi de um *prompt*; o benefício, um erro factual demonstrável a menos em cada uma das três afirmações mais visíveis do documento. **Se houver uma única prática a levar deste trabalho para o uso profissional de IA, é esta.**

Anexo A — Glossário de siglas

Sigla	Significado
AHCI	<i>Advanced Host Controller Interface</i> — interface de controlador para SATA
CXL	<i>Compute Express Link</i> — protocolo coerente de memória sobre PCIe
DWPD	<i>Drive Writes Per Day</i> — medida de resistência de SSD
EDSFF	<i>Enterprise and Data Center Standard Form Factor</i> (E1.S, E1.L, E3.S)
FC	<i>Fibre Channel</i> ; FCIP = FC sobre IP; FCoE = FC sobre Ethernet
FTL	<i>Flash Translation Layer</i> — camada de tradução lógico-física do SSD
HAMR	<i>Heat-Assisted Magnetic Recording</i> — gravação magnética assistida por calor
HBA	<i>Host Bus Adapter</i> — adaptador de barramento do hospedeiro
IOPS	<i>Input/Output Operations Per Second</i>
LTO	<i>Linear Tape-Open</i> — padrão aberto de fita magnética
MTTF	<i>Mean Time To Failure</i>
NCQ / TCQ	<i>Native / Tagged Command Queuing</i>
NL-SAS	<i>Nearline SAS</i> — mídia SATA <i>nearline</i> com interface e protocolo SAS
NVMe	<i>Non-Volatile Memory Express</i> ; NVMe-oF = NVMe <i>over Fabrics</i>
PAM3/PAM4	<i>Pulse Amplitude Modulation</i> de 3 e 4 níveis
QD	<i>Queue Depth</i> — profundidade de fila
RDMA	<i>Remote Direct Memory Access</i> ; RoCE = RDMA sobre Ethernet convergente
SAN / NAS	<i>Storage Area Network / Network-Attached Storage</i>
SAS	<i>Serial Attached SCSI</i>
SCM	<i>Storage Class Memory</i> — memória de classe de armazenamento
SMR / CMR	<i>Shingled / Conventional Magnetic Recording</i>
STP	<i>Serial ATA Tunneling Protocol</i>
TBW	<i>Terabytes Written</i>
UEC	<i>Ultra Ethernet Consortium</i>
WORM	<i>Write Once, Read Many</i>
ZNS	<i>Zoned Namespaces</i>