

Dispositivos de Armazenamento Físico para SBD

Interfaces de conexão e parâmetros para o Gerente de Armazenamento.

Atualização da Tabela 16.1 de Elmasri & Navathe para o mercado de setembro de 2026.

INTEGRANTES DO GRUPO

[NOME COMPLETO DO INTEGRANTE 1] — DRE [00000000]

[NOME COMPLETO DO INTEGRANTE 2] — DRE [00000000]

[NOME COMPLETO DO INTEGRANTE 3] — DRE [00000000]

[NOME COMPLETO DO INTEGRANTE 4] — DRE [00000000]

[NOME COMPLETO DO INTEGRANTE 5] — DRE [00000000]

18,6×

é o quanto o SSD corporativo custa a mais por TB que o HDD nearline no 3T26 — divergiram, não convergiram

0

memórias persistentes byte-endereçáveis em produção: o Optane morreu

<1 μ s

é o custo do barramento PCIe num I/O de 20–70 μ s — latência é média

Roteiro da apresentação

1

Fundamentos

Hierarquia de memória, mecânica do HDD, física do flash, o fim da SCM

2

Tabela 16.1 atualizada

13 dispositivos comerciais de 2026, com preço por KB

3

Interfaces de conexão

56 variantes: USB, SATA, SAS, NVMe, M.2/U.2/EDSFF, HBA, FC, iSCSI, InfiniBand

4

Gerente de Armazenamento

Bloco, buffer, latência de commit, modelo de custo, tiering

5

Post-Mortem

Prompts, autoria, erros da IA e correções aplicadas

Todo SGBD é uma máquina de transformar I/O em respostas

Índices, buffer pool, WAL, otimizador de consultas — tudo existe porque o meio persistente é ordens de grandeza mais lento que a memória. Essa razão é o parâmetro que justifica a arquitetura inteira. E ela mudou.

2014

ano dos preços da Tabela 16.1 do Elmasri & Navathe

2018

ano dos números do Capítulo 12 do Silberschatz

12 anos


de defasagem que este trabalho mede e corrige

A pergunta do trabalho

Se os parâmetros físicos mudaram por várias ordens de grandeza, quais conclusões práticas dos livros-texto ainda valem — e quais deixaram de valer?

1. FUNDAMENTOS

A hierarquia continua existindo — com um buraco novo



Como ler

- Cada tecnologia da Tabela 16.1 atualizada, posicionada por tempo de acesso e preço por KB. Ambos os eixos são logarítmicos.
- A fronteira desce da esquerda superior para a direita inferior: pagar mais compra latência menor.
- O vazio no eixo horizontal entre DRAM (10^{-7} s) e SSD NVMe (5×10^{-5} s) é onde ficava o Intel Optane.

1. FUNDAMENTOS

Disco magnético: a mecânica que define o modelo de custo

Busca

4–10 ms *

Deslocamento do braço até a trilha. * A Seagate REMOVEU o seek time do manual do Exos M — os $\approx 8,5$ ms que somamos são estimativa nossa da classe.

Latência rotacional

4,16 ms

Meia rotação a 7.200 rpm: $60 \div 7.200 \div 2 = 4,17$ ms; a Seagate publica 4,16. É o único parâmetro de tempo que ela ainda publica.

Transferência

275–285 MB/s

Trilhas externas. Bem menos nas internas, que têm menos setores.

IOPS (4 KB)

50–200

Governado pela mecânica. Praticamente inalterado em duas décadas.

O que os livros não enfatizam o bastante

Capacidade cresceu 4×; taxa sequencial, 1,4×; IOPS aleatório, nada. Varrer 8 TB a 200 MB/s levava 11 h; varrer 32 TB a 285 MB/s leva 31 h. Backup, reconstrução de RAID e full table scan pioraram — e é por isso que RAID 5 saiu de cena em discos grandes.

1. FUNDAMENTOS

Flash: escrever é diferente de ler, e isso muda o projeto

Ler página

dezenas de μ s

Escrever página apagada

$\approx 100 \mu$ s

Apagar bloco (256 KB–1 MB)

2–5 ms

Sobrescrever uma página é impossível: é preciso apagar o bloco inteiro, e cada bloco suporta 10^5 – 10^6 apagamentos. Toda a arquitetura do SSD — FTL, garbage collection, wear leveling — existe por causa dessa única restrição.

1

Amplificação de escrita

O GC move dados: 4 KB lógicos custam mais que 4 KB físicos. É por isso que SGBDs da era do SSD (RocksDB, Cassandra) usam LSM-tree em vez de B⁺-tree in-place.

2

Latência de cauda

O GC é assíncrono e imprevisível. A mediana é ótima; o P99,9 pode ser 10× pior. SLA de banco quebra na cauda, não na média.

3

Paralelismo interno

O SSD atende 32+ requisições simultâneas. SATA: 13 mil IOPS a QD1, 98 mil a QD32. Emitir uma por vez desperdiça o dispositivo.

A memória persistente que os livros anunciam não existe mais

A Nota 12.1 do Silberschatz apresenta a storage class memory — 3D XPoint / Intel Optane — como o degrau que preencheria o vão entre DRAM e flash.

2017

Optane SSD começa a ser vendido

2018

Optane PMem em soquete DIMM

jul/2022

Intel anuncia a saída do negócio

—

Geração 300 (Crow Pass) cancelada

fim/2025

Últimos embarques da série 200

Consequência para bancos de dados transacionais

O vão de três ordens de grandeza entre DRAM (≈ 70 ns) e SSD NVMe (20–70 μ s) foi reaberto. Um log em SCM permitiria ≈ 100.000 commits/s por thread; com NVMe o teto é ≈ 33.000 . O CXL cobre parte do vão — mas do lado da memória, a 214–271 ns medidos (2–2,5 $\times$ a DRAM local), e não como meio persistente de log.

O ponto de partida: a Tabela 16.1 original (2014)

Type	Capacity	Access Time	Max Bandwidth	Commodity Prices (2014)
Main Memory — RAM	4 GB – 1 TB	30 ns	35 GB/s	US\$ 100 – 20 K
Flash Memory — SSD	64 GB – 1 TB	50 µs	750 MB/s	US\$ 50 – 600
Flash Memory — USB stick	4 GB – 512 GB	100 µs	50 MB/s	US\$ 2 – 200
Magnetic Disk	400 GB – 8 TB	10 ms	200 MB/s	US\$ 70 – 500
Optical Storage	50 GB – 100 GB	180 ms	72 MB/s	US\$ 100
Magnetic Tape	2,5 TB – 8,5 TB	10 – 80 s	40 – 250 MB/s	US\$ 2,5 K – 30 K
Tape jukebox	25 TB – 2,1 EB	10 – 80 s	250 MB/s – 1,2 PB/s	US\$ 3 K – 1 M+

O que o enunciado pede: substituir cada tipo por produtos comerciais de 2026, atualizar capacidade e preço, separar a banda em leitura e escrita, e acrescentar a coluna de preço por kilobyte.

Tabela 16.1 atualizada — primário e secundário

Tipo	Exemplo comercial	Capacidade	Acesso	Leitura	Escrita	Preço US\$	US\$/KB
Cache SRAM L3	Ryzen 9 9950X3D2 / EPYC 9755	96–512 MB	≈8,9 ns ‡	≈1,4 TB/s	≈1,4 TB/s	700–14.800	3,0×10 ⁻³
DRAM desktop	Corsair DDR5-6000 CL30	16–96 GB	70 ns	96 GB/s	96 GB/s	270–1.100	1,6×10 ⁻⁵
DRAM servidor	RDIMM DDR5-6400 64 GB	32–256 GB	≈75 ns	51,2 GB/s	51,2 GB/s	1.000–4.000	4,2×10 ⁻⁵
Memória CXL 2.0	Samsung CMM-D MD220 (E3.S)	128–256 GB	214–271 ns †	≈36 GB/s †	≈36 GB/s †	não público	n/d
SSD NVMe PCIe 5.0	Samsung 9100 PRO (1 TB)	1–8 TB	≈50 μs *	14,7 GB/s	13,3 GB/s	249–1.099	2,0×10 ⁻⁷
SSD NVMe QLC (DC)	Solidigm D5-P5336	7,68–122,88 TB	8–10 μs †	7,0 GB/s	3,0 GB/s	16.246–33.249	2,6×10 ⁻⁷
SSD NVMe TLC (DC)	Micron 9550 PRO	7,68–30,72 TB	≈80 μs *	14,0 GB/s	10,0 GB/s	33.217	1,1×10 ⁻⁶
SSD SATA	Samsung 870 EVO	250 GB–8 TB	77 μs	560 MB/s	530 MB/s	345 (1 TB)	3,4×10 ⁻⁷
Pen drive USB	Kingston DataTraveler Max	256 GB–1 TB	≈0,1–0,5 ms	1.000 MB/s	900 MB/s	130 (1 TB)	1,3×10 ⁻⁷
Disco HAMR	Seagate Exos M 30 TB	24–36 TB	≈12,7 ms *	275 MB/s	275 MB/s	800–1.280	2,7×10 ⁻⁸

PROVENIÊNCIA — sem marca: datasheet do fabricante. * estimativa nossa de ordem de grandeza (nenhum fabricante de SSD de consumo publica latência; a Seagate removeu o seek time do manual do Exos M). † latência típica de datasheet — o QoS de percentil do mesmo produto é 110 μs (leitura) e 40 μs (escrita); a Samsung não publica nada do CMM-D, cuja faixa vem de medições revisadas por pares. ‡ derivado de 46,5 ciclos a 5,7 GHz — a AMD publica só o delta sobre o Zen 4. Em azul: as três linhas novas do grupo.

Tabela 16.1 atualizada — terciário, e a coluna de preço por KB

Tipo	Exemplo comercial	Capacidade	Acesso	Leitura	Escrita	Preço US\$	US\$/KB
Óptico WORM	Verbatim M-DISC BD-XL 100 GB	100 GB/disco	≈150–250 ms *	não publicada	≈18 MB/s (4×)	12,70 + 230	$1,3\times10^{-7}$
Fita LTO-9	Cartucho Ultrium LTO-9	18 TB nativo	25–121 s	400 MB/s	400 MB/s	88 + drive	$4,9\times10^{-9}$
Fita LTO-10	Cartucho Ultrium LTO-10 (2026)	30 → 40 TB	25–121 s	400 MB/s	400 MB/s	260–300 + drive	$9,3\times10^{-9}$
Tape library	IBM TS4500 / Quantum i6000	até 927 PB	25–121 s	≈51,2 GB/s	≈51,2 GB/s	sob cotação	n/d

A razão que sustenta a hierarquia


621.000×

separam o preço por KB da SRAM do da fita LTO-9: $(\text{US\$ } 199 \div 65.536 \text{ KiB}) \div (\text{US\$ } 87,99 \div 1,8\times10^{10} \text{ KB}) = 3,04\times10^{-3} \div 4,89\times10^{-9}$. Não é o desempenho que sustenta o tiering: é essa razão de custo.

Por que a fita não morreu

- Único meio em que drive e mídia são precificados à parte: cada TB adicional custa US\$ 5–10.
- Roadmap (revisado em nov/2025) até 365 TB nativos no LTO-14 — a maior vitalidade da hierarquia.
- Consumo zero na estante, air gap físico contra ransomware, retenção declarada de 30 anos.

A largura de banda foi o que realmente explodiu



O que o gráfico mostra

20×

de banda a mais no SSD, contra a Tabela 16.1 original: de 750 MB/s para 14,7 GB/s.

1,4×

foi o avanço do disco magnético no mesmo período: de 200 para 285 MB/s.

LTO > HDD

a fita supera o disco em taxa sequencial — não precisa posicionar braço entre blocos.

O que mudou entre 2014 e 2026

Mudança	Impacto no projeto de SBD
Optane / 3D XPoint descontinuado (2022–2025)	Removeu o degrau de memória persistente; reabriu o vão de 3 ordens de grandeza
CXL preenche o vão parcialmente	Novo nível de memória a 214–271 ns (2–2,5× a DRAM local); buffer pool cresce além dos slots DIMM
Sony ODA encerrado; Pioneer saiu dos leitores	Óptico virou nicho de arquivamento WORM de longuíssimo prazo
SSD SATA virou legado	Interface satura em 550 MB/s; mantido apenas por retrofit
PCIe 5.0 padrão; PCIe 6.0 no datacenter	14,9 GB/s no consumo; 28 GB/s no Micron 9650 (fev/2026)
HAMR entrou em produção	HDD saltou de 24 TB para 32–36 TB; 44 TB anunciado
LTO-10 lançado (30 → 40 TB nativos)	Arquivamento a US\$ 5–10/TB; roadmap revisado até 365 TB nativos
SSD e HDD divergiram em custo	18,6× por TB no 3T26 (era 7× no 3T25) — invalida a premissa de convergência

Aviso metodológico: os preços de 2026 são de um pico anômalo

A coleta ocorreu durante uma crise de oferta de memória e NAND causada pela realocação de capacidade fabril para HBM (aceleradores de IA) e por pedidos antecipados de hiperescaladores.

+575%

no mesmo kit DDR5-6000 de 32 GB, de meados de 2025 a set/2026

5×

no preço spot do NAND, de out/2025 a fev/2026 — e 8,5× até março

+46%

no preço do HDD em apenas quatro meses (15/set/2025 a 14/jan/2026, 12 modelos)

18,6×

é o prêmio do SSD corporativo sobre o HDD por TB no 3T26 — foi 7× no 3T25 e 23× no 1T26

Como o leitor deve usar a tabela

As razões entre tecnologias — quantas ordens de grandeza separam DRAM de fita — são estruturais e estáveis. Os valores absolutos, não. Registramos ainda uma inversão temporária: um pen drive de 1 TB (US\$ 130/TB) está mais barato por terabyte que um SSD SATA de 1 TB (US\$ 345/TB).

Antes de comparar interfaces: três reduções separam marketing de realidade

1

Unidade

1 GB/s = 8 Gb/s. Uma interface de 6 Gb/s nunca entrega 6 GB/s.

O próprio Silberschatz escorrega aqui (§12.2).

2

Codificação de linha

Bits de controle para balanceamento DC e recuperação de clock.

8b/10b custa 25%; 128b/130b custa 1,6%.

3

Modulação

NRZ = 1 bit/símbolo. PAM4 = 2 bits/símbolo, com FEC obrigatório.

PAM4 está em FC 64G, IB HDR+, PCIe 6.0.

SATA 3.0: $6,0 \text{ Gb/s bruto} \times 8/10 = 4,8 \text{ Gb/s úteis} \div 8 = 600 \text{ MB/s}$
 $\times 4 \text{ lanes} \times 128/130 \div 8 = 15,754 \text{ GB/s}$


PCIe 5.0 $\times 4$: 32 GT/s

Comparativo das interfaces — extrato de 56 variantes estudadas

Interface	Ano	Ser./Par.	Taxa útil	Latência	Distância	Topologia / nº disp.	Uso em SBD
USB 3.2 Gen 2×2	2017	Serial ×2	2.424 MB/s	≈100 μs	1 m	Estrela hierárq., 127	Backup externo
USB4 v2.0	2022	Serial PAM3	≈9,6 GB/s	≈50 μs	1 m ativo	Roteado (tunneling)	SSD externo NVMe
Ultra-320 SCSI	2002	Paralela	320 MB/s	ms	12 m LVD	Barramento, 16	Obsoleto
SATA 3.0	2009	Serial	600 MB/s	100–200 μs	1 m	Ponto-a-ponto	Capacidade, backup
SATA Express	2013	Serial (PCIe ×2)	1,97 GB/s	<1 μs	≈0,3 m	Ponto-a-ponto	Fracassou
SAS-4 (24G)	2019	Serial	2.400 MB/s	100–200 μs	10 m	Fabric, 65.535	HDD, backplane
PCIe 5.0 ×4 + NVMe	2019	Serial	15,75 GB/s	20–70 μs	≈0,25 m	65.535 filas	OLTP, redo log
Fibre Channel 64GFC	2020	Serial PAM4	6.400 MB/s	460 ns/switch	10 km SMF	Fabric, 2 ²⁴	SAN corporativa
NVMe/TCP	2018	Fabric IP	= Ethernet	122–177 μs	ilimitada	Rede IP roteável	Sucessor do iSCSI
iSCSI	2004	Protocolo IP	= Ethernet	500–800 μs	ilimitada	Rede IP	PME, virtualização
InfiniBand XDR 4×	2023	Serial PAM4	800 Gb/s	sub-μs	10 km	Fabric comutado	Clusters de IA/LLM
Em 20280, as 21 linhas de SFF são apodados — fator de 10 e adaptador NVMe em taxa própria, não em as lanes PCIe da linha correspondente. E não se trata porque constam da lista do enunciado. A tabela completa tem 56 linhas, com taxa bruta, hot-plug e alimentação pelo cabo.							
HBA (tri-modo, FC, CNA)	—	adaptador PCIe	= do meio	= do meio	host	Modo IT expõe discos crus ao SO	ZFS/Ceph, SAN

3. INTERFACES

Uma família manteve a inclinação — e por isso todas as outras se mudaram para ela



Por que o SATA parou

- Requalificar conector, cabo e PHY custaria caro sem retorno.
- O overhead de 25% do 8b/10b; trocá-lo quebraria compatibilidade.
- O gargalo real é o AHCI — 1 fila de 32 comandos — e não o fio.
- O PCIe já existia, já era mais rápido e mais barato por GB/s.

17 anos sem mudança de velocidade — e ninguém se importou.

Correção a uma afirmação do próprio enunciado

“SATA também é conhecida como NL-SAS.”
Factualmente incorreto.

NL-SAS = mecânica SATA nearline + protocolo SAS

	SATA (HDD)	NL-SAS	SAS corporativo
Interface / protocolo	SATA / ATA	SAS / SCSI	SAS / SCSI
Mídia e rotação	Nearline 7.200 rpm	Nearline 7.200 rpm (a mesma)	10 K / 15 K rpm
Portas	1 (single-port)	2 (dual-port)	2 (dual-port)
Multipath / alta disponib.	Não	Sim	Sim
Exige STP / interposer	Sim	Não	Não
Taxa de erro irre recuperável	10 ⁻¹⁴	10 ⁻¹⁵	10 ⁻¹⁶

Consequência prática: um array SAS com discos SATA precisa de STP ou de placas interposer e perde o caminho redundante. Com NL-SAS, não. Para um SGBD em cluster, é a diferença entre sobreviver ou não à falha de um controlador.

Por que o NVMe venceu — e não foi por largura de banda

	AHCI / SATA	NVMe
Filas de submissão	1	65.535
Comandos por fila	32	65.536
Registradores MMIO por comando	4 (não cacheáveis)	1
Afinidade de núcleo	Não	Uma fila por núcleo — sem contenção de lock
Conjunto de comandos	ATA (herdado do disco rotativo)	Enxuto, projetado para flash

O argumento em uma frase

Para um SGBD com alta concorrência, o gargalo do AHCI nunca foram os 600 MB/s: era o lock na fila única, disputado por todos os núcleos que querem emitir I/O. O NVMe elimina essa disputa por construção — dando a cada núcleo a sua própria fila.

Orçamento de latência de uma leitura aleatória de 4 KB

Etapa	NVMe local (a)	NVMe/RoCE (b)	NVMe/TCP (b)	iSCSI 10 GbE (a)	HDD SAS (a)
Chamada de sistema + camada de bloco	2–5 μ s	2–5 μ s	5–10 μ s	10–20 μ s	5 μ s
Driver + submissão na fila	1–2 μ s	2 μ s	5 μ s	20–50 μ s	10 μ s
Travessia do barramento / fabric	<1 μ s	5–15 μ s	50–120 μ s	200–400 μ s	5 μ s
Latência da mídia	20–70 μ s	20–70 μ s	20–70 μ s	20–70 μ s	≈4 ms
Controladora do alvo / RAID	—	10–30 μ s	10–30 μ s	30–80 μ s	50 μ s
TOTAL	20–70 μs	41–163 μs	122–177 μs	500–800 μs	5–10 ms

(a) latência típica. (b) percentil 99,99 medido pela Western Digital (4 KB, QD=1, mesma mídia) — a mediana é menor. As duas colunas de fabric são, portanto, conservadoras face às demais: isso reforça a conclusão (2), não a enfraquece.

Em NVMe local, ≈90% da latência é mídia

PCIe 5.0 → 6.0 não reduz latência de leitura aleatória. Só a mídia reduziria — e a mídia que faria isso saiu do mercado.

Em storage de rede, o protocolo domina

Trocar iSCSI por NVMe/TCP tem efeito de primeira ordem: 4× menos latência sobre a mesma mídia.

A cauda importa mais que a média

SLA de banco quebra no P99,9. Fabrics lossless (FC, IB) vencem o TCP pela variância, não pela média.

Traduzindo os números em decisões do Gerente de Armazenamento

1

Tamanho de bloco

HDD: 8–64 KB, para amortizar a busca de 12,7 ms. · SSD: 4–16 KB, alinhado à página NAND. · Fita: ≥1 MB.

2

Buffer pool

Emitir uma falta de página por vez usa ≈3% de um SSD NVMe. É preciso I/O assíncrono com muitas requisições em voo — daí `io_uring` e `effective_io_concurrency`.

3

Durabilidade

O commit custa $1/\text{latência_do_fsync}$. Group commit é o que separa usar o dispositivo de desperdiçá-lo.

4

Modelo de custo

`random_page_cost = 4,0` codifica a premissa de disco magnético. Em SSD deve cair para 1,1–1,5, ou o planejador prefere varreduras que o hardware não favorece.

Teto de commits por thread: HDD ≈125/s · SSD SATA ≈6.700/s · NVMe local ≈33.000/s · NVMe/TCP ≈8.200/s · iSCSI ≈1.700/s

Uma arquitetura de tiers para 2026

Tier	Meio	Interface	Conteúdo típico	US\$/KB
0 — memória	DRAM + CXL	DDR5 / CXL 2.0	Buffer pool, tabelas de hash, catálogos	10^{-5}
1 — quente	SSD NVMe TLC (E3.S)	PCIe 5.0 ×4	Redo log, tempdb, índices, tabelas OLTP	10^{-6}
2 — morno	SSD NVMe QLC alta capac.	PCIe 4.0 ×4	Partições históricas, leitura intensiva	10^{-7}
3 — frio	HDD nearline 30 TB	SATA 6 Gb/s ou NL-SAS 12G	Data lake, partições antigas, backup	10^{-8}
4 — arquivo	Fita LTO-10	SAS 12G / FC 32G	Retenção legal, air gap contra ransomware	10^{-9}

3.000×

é a razão de preço por byte entre o tier 0 e o tier 4. É ela — e não a diferença de desempenho — que sustenta economicamente o tiering.

Evidência empírica (PostgreSQL)

- NVMe local: 400 mil IOPS em 8 vCPU. Disco de rede precisaria de 112 vCPU — 14× mais.
- TPC-C: 873 tps (NVMe local) contra 636 (Aurora) e 188 (RDS/EBS gp3).

Quatro conclusões

1

A SCM saiu do mercado

O Optane foi descontinuado entre 2022 e 2025 e nada o substituiu. O teto de commits por thread continua ditado pela latência do NVMe.

2

SSD e HDD divergiram

18,6× em US\$/TB no 3T26, contra a expectativa de convergência. O tiering ficou mais necessário, não menos.

3

Banda deixou de ser o parâmetro

Em NVMe local, <1 µs de 20–70 µs é barramento. Explica o SATA parado, a vitória do NVMe e a irrelevância do PCIe 6.0 para OLTP.

4

A fita é a mais viva do baixo da pirâmide

LTO-10 a 40 TB nativos, roadmap até 365 TB, US\$ 5–10/TB. Para retenção legal e air gap, não há substituto.

Achado metodológico: fabricantes publicam cada vez menos parâmetros de latência. Um trabalho equivalente feito em 2014 teria mais dados disponíveis do que este, feito em 2026.

Post-Mortem — como usamos a IA e o que decidimos nós

Prompts que determinaram o conteúdo

- P2 — “marque o que é datasheet, o que é medição e o que é estimativa; se não encontrar, diga.”
- P3 — “distinga Gb/s de GB/s e cite a codificação de linha.”
- P4 — “verifique se ‘SATA = NL-SAS’ é correto.”
- P6 — “liste o que você NÃO conseguiu encontrar.”
- P7 — “verificador adversarial: não confirme nada por plausibilidade; ordene por gravidade o que derrubaria o trabalho.”

Autoria — quem decidiu o quê

- [INT. 1] — coordenação; decidiu adotar faixas em vez de valores pontuais.
- [INT. 2] — fundamentos; decidiu articular os dois livros-texto.
- [INT. 3] — Tabela 16.1; decidiu a convenção binária/decimal e as linhas novas.
- [INT. 4] — interfaces; decidiu usar taxa por direção no FC; detectou o erro do NL-SAS.
- [INT. 5] — gerente de armazenamento e Post-Mortem.

Cinco lições sobre o uso de IA neste tipo de trabalho

- Exigir a origem de cada número é o que torna o trabalho auditável.
- Pedir as lacunas explicitamente é tão importante quanto pedir os dados.
- A IA reproduz premissas erradas contidas no próprio pedido — o erro do NL-SAS só apareceu porque perguntamos.
- Respostas longas contêm contradições internas; só a leitura cruzada as revela.
- As conclusões estruturais não vieram prontas: resultaram de comparar tabelas produzidas separadamente.
- Uma segunda IA, instruída a ATACAR o texto, achou 5 erros graves que a IA autora não viu — a lição que levamos.

Post-Mortem — os 21 erros e as correções aplicadas

#	Erro gerado	Correção aplicada
E5	Reportou 64GFC como 12.800 MB/s sem qualificar	Identificada a convenção full-duplex da FCIA; adotada a taxa por direção (6.400 MB/s)
E7	Ecoou a afirmação do enunciado de que SATA = NL-SAS	Verificação dirigida; erro documentado com tabela comparativa e consequência prática
E8	Apresentou o seek time do Exos M como dado de datasheet	A Seagate removeu o dado; remarcado como estimativa somada à latência rotacional publicada
E10	Apresentou throughput de tape library como spec de fabricante	Nem IBM nem Quantum publicam; reclassificado como derivação nossa e teto teórico
E13	“Roadmap do LTO até 913 TB nativos no LTO-14”	FALSO em dobro: 913 TB é comprimido (365 × 2,5); o nativo é 365 TB, e o roadmap mudou em nov/2025
E14	Atribuiu ≈140 ns de latência ao módulo CXL Samsung	Sem fonte: a Samsung não publica. Medições revisadas por pares dão 214–271 ns — reforça nossa tese
E15	Razão SSD/HDD como “≈16× em 2026”, sem trimestre	Volátil: 7× no 3T25, 23× no 1T26, 16× no 2T26, 18,6× no 3T26. Razão sem data não é dado
E16	Janelas erradas na alta do HDD e do NAND	HDD: 46% em quatro meses (não seis). NAND: 5× a partir de out/2025 (não ago)
E17	O resumo dizia “39 variantes” de interface	A tabela tinha 49 linhas e passou a 56 com os fatores de forma e os HBA
E18–E21	Quatro erros de RÓTULO: o número certo descrevendo outra coisa	QoS do Solidigm como latência típica • P99,99 da WD como média • capacidades misturadas do 9100 PRO • ciclos do Zen 5 como dado, sendo derivação

Em laranja: os achados da rodada de verificação adversarial (Seção 9.5) — uma segunda IA instruída a derrubar o trabalho. Os 21 erros e quem detectou cada um estão na Seção 9.4, e o quadro completo no backup B4. Também documentamos uma imprecisão do próprio Silberschatz (§12.2: “6 gigabytes per second” para o SATA-3).

O que levamos ao debate

Q1

O modelo de custo do otimizador deveria ser calibrado automaticamente, em vez de depender de um administrador que talvez não saiba que `random_page_cost` existe?

Q2

Faz sentido continuar ensinando o modelo de I/O por contagem de blocos, ou o modelo de 2026 seria latência $\times$ profundidade de fila?

Q3

A morte do Optane foi falha de mercado ou de tecnologia — e o que impede que a lacuna seja reaberta indefinidamente?

Q4

Se o CXL viabilizar buffer pools de dezenas de terabytes, o que muda num SGBD que hoje assume que os dados não cabem na memória?

Q5

Existe formalismo de otimização de consultas que otimize percentil (P99) em vez de custo esperado?

Obrigado. · Documento completo, com as tabelas integrais e o Post-Mortem, entregue em PDF.

BACKUP

Proveniência dos dados · derivações aritméticas · fatores de forma e HBA · registro completo de erros

De onde vem cada número da Tabela 16.1

Categoria de origem	Como aparece na tabela	Exemplos
Datasheet do fabricante	Sem marcação	Capacidades e taxas do 9100 PRO, 870 EVO, D5-P5336, 9550 PRO, DT Max, Exos M; latência rotacional de 4,16 ms; taxas nativas do LTO-9 e LTO-10
Medição publicada por terceiro	Citada no texto	1,4 TB/s de L3 do Zen 5 (Chips and Cheese); 214–271 ns do CXL 2.0 (ASPLOS); 41–177 μs do NVMe-oF (Western Digital)
Derivação nossa	Conta explicitada na nota	Preço/KB (preço ÷ capacidade em KB); 51,2 GB/s por módulo DDR5-6400; 51,2 GB/s agregados da tape library (128 drives × 400 MB/s); 927 PB (23.170 × 40 TB); latência do cache em ns
Estimativa de ordem de grandeza	Marcada com *	≈50 μs do SSD de consumo; ≈8,5 ms de busca do HDD; ≈0,1–0,5 ms do pen drive; ≈150–250 ms do leitor óptico
Não encontrado	n/d	Preço de módulo CXL e de tape library (só sob cotação); banda agregada do MD220; velocidade de leitura do M-DISC

Regra que adotamos: nenhuma célula fica sem origem declarada, e “não encontramos” é resposta aceitável — preencher com estimativa não rastreável é o que este trabalho critica. As dez lacunas estão na Nota N10 do documento.

As contas, por extenso

Preço por KB (SRAM)

$$\text{US\$ } 199 \div 65.536 \text{ KiB} = 3,04 \times 10^{-3} \text{ /KB}$$

Delta entre 9950X3D2 (192 MB L3, US\$ 899) e 9950X3D (128 MB, US\$ 700)

Latência rotacional

$$60 \div 7.200 \div 2 = 4,16 \text{ ms}$$

Meia rotação a 7.200 rpm — publicado pela Seagate

SATA 3.0 útil

$$6,0 \text{ Gb/s} \times 8/10 \div 8 = 600 \text{ MB/s}$$

Codificação 8b/10b, 80% de eficiência

SAS-4 útil

$$22,5 \text{ Gb/s} \times 128/150 \div 8 = 2.400 \text{ MB/s}$$

“24G” é marca; a taxa é 22,5 Gb/s

Banda DDR5-6000

$$6.000 \text{ MT/s} \times 8 \text{ B} \times 2 \text{ canais} = 96 \text{ GB/s}$$

Dois canais no kit de desktop

Razão topo/base

$$3,04 \times 10^{-3} \div 4,89 \times 10^{-9} = 621.000 \times$$

SRAM contra cartucho LTO-9 (US\$ 87,99 ÷ 1,8×10¹⁰ KB)

Varredura de disco

$$32 \text{ TB} \div 285 \text{ MB/s} = 31,2 \text{ h}$$

Contra 8 TB ÷ 200 MB/s = 11,1 h em 2014

PCIe 5.0 ×4

$$32 \text{ GT/s} \times 4 \times 128/130 \div 8 = 15,754 \text{ GB/s}$$

Codificação 128b/130b, 98,46%

Teto de commits/s

$$1 \div \text{latência do fsync}$$

NVMe 30 μs → 33.333/s; SATA 150 μs → 6.667/s; HDD 8 ms → 125/s

Latência L3 do Zen 5

$$46,5 \text{ ciclos} \div 5,7 \text{ GHz} = 8,16 \text{ ns}$$

46,5 = 50 (Zen 4) – 3,5 (delta AMD); +4 ciclos do V-Cache

Fatores de forma e HBA — o que não é protocolo

Fator de forma	Lanes	Hot-swap	Tensão / potência	Uso
M.2 2280	×4 (M-key)	Não	3,3 V — 8 a 11 W	Boot, cliente, cache
U.2 (SFF-8639)	×4	Sim	12 V — 25 W	Servidor, gaveta frontal
U.3 (SFF-TA-1001)	×4	Sim	12 V — 25 W	Baia tri-modo: SAS, SATA ou NVMe
E1.S / E1.L (EDSFF)	×4	Sim	12 V — 16 a 40 W	1U; E1.L é a “régua” de capacidade
E3.S / E3.S 2T	×4 ou ×8	Sim	12 V — 25 a 70 W	Sucessor do U.2; o 2T aceita módulo CXL

Por que o EDSFF está substituindo o U.2: SSDs PCIe 5.0/6.0 passam de 25 W e a lata de 2,5 polegadas não dissipa. O M.2, além de não ter hot-swap, só tem 3,3 V.

HBA não é interface nem protocolo — é o adaptador

- HBA em modo IT expõe os discos crus ao SO, sem cache nem metadados de RAID — é o que ZFS, Ceph e réplica por software exigem. Em modo RAID, faz RAID em hardware com cache protegido.
- Armadilha de durabilidade: HBA RAID com cache NÃO protegido por bateria pode confirmar um fsync antes da persistência. O SGBD acredita ter cumprido a durabilidade; a queda de energia prova o contrário.

Post-Mortem — os 21 erros, em uma página

Revisão do grupo

E1 a E12

Detectados ao reproduzir contas, cruzar seções e conferir datasheets. Predominam erros de atribuição de origem.

E1 proxy de preço da SRAM • E2 convenção binária/decimal • E3 Optane mantido na tabela • E4 cronologia do LTO-10 • E5 64GFC em full-duplex • E6 SAS-4 como “24 Gb/s” • E7 SATA = NL-SAS • E8 seek time do Exos M • E9 preço de DRAM contraditório • E10 throughput de tape library • E11 leitura = escrita sem verificar • E12 estimativa com cara de dado

Verificação adversarial — conteúdo

E13 a E17

Sobreviveram à revisão da IA autora e caíram na 1ª passagem de um verificador instruído a atacar o texto.

E13 LTO-14 com 913 TB “nativos” (são 365; 913 é comprimido, e o roadmap mudou em nov/2025) • E14 latência de 140 ns do CXL sem fonte (medido: 214–271 ns) • E15 razão SSD/HDD sem trimestre • E16 janelas erradas de HDD e NAND • E17 contagem de interfaces

Verificação adversarial — rótulo

E18 a E21

Os mais insidiosos: o número existe e resiste a uma busca — apenas não significa o que o texto dizia.

E18 QoS de percentil do Solidigm citado como latência típica • E19 números da Western Digital como média, sendo P99,99 • E20 capacidades misturadas do Samsung 9100 PRO • E21 ciclos de cache do Zen 5 como dado publicado, sendo derivação

Também documentamos um erro que não foi da IA: o próprio Silberschatz (§12.2) escreve “6 gigabytes per second” para o SATA-3 — são 6 gigabits. A verificação contra fonte primária é necessária independentemente de quem escreveu o texto.